

电子科技大学

UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

# 专业学位硕士学位论文

MASTER THESIS FOR PROFESSIONAL DEGREE



论文题目 基于深度学习的极化 SAR 图像目标分类方法研究

专业学位类别	电子信息
学 号	202122011004
作者姓名	林小惟
指导教师	杨建宇 教授
学 院	信息与通信工程学院

分类号 \_\_\_\_\_ 密级 \_\_\_\_\_

UDC 注 1 \_\_\_\_\_

# 学位论文

基于深度学习的极化 SAR 图像目标分类方法研究

(题名和副题名)

林小惟

(作者姓名)

指导老师

杨建宇 教授

电子科技大学 成都

(姓名、职称、单位名称)

申请学位级别 硕士 专业学位类别 电子信息

专业学位领域 通信工程(含宽带网络、移动通信等)

提交论文日期 2024年4月16日 论文答辩日期 2024年5月27日

学位授予单位和日期 电子科技大学 2024年6月

答辩委员会主席 张伟

评阅人 曹宗杰/李冰

注 1：注明《国际十进分类法 UDC》的类号。

# **Research on Target Classification Method of Polarimetric SAR Images Based on Deep Learning**

A Master Thesis for Professional Degree Submitted to  
University of Electronic Science and Technology of China

Discipline: **Master of Engineering**

Author: **Lin Xiaowei**

Student ID: **202122011004**

Supervisor: **Prof. Yang Jianyu**

School: **School of Information and Communication  
Engineering**

## 独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

作者签名: 林小惟 日期: 2024 年 5 月 31 日

## 论文使用授权

本学位论文作者完全了解电子科技大学有关保留、使用学位论文的规定，同意学校有权保留并向国家有关部门或机构送交论文的复印件和数字文档，允许论文被查阅。本人授权电子科技大学可以将学位论文的全部或部分内容编入有关数据库进行检索及下载，可以采用影印、扫描等复制手段保存、汇编学位论文。

(涉密的学位论文须按照国家及学校相关规定管理，在解密后适用于本授权。)

作者签名: 林小惟 导师签名: 范教授

日期: 2024 年 5 月 31 日

## 摘要

极化合成孔径雷达（Polarimetric Synthetic Aperture Radar, PolSAR）凭借其全天候、全天时、多极化的成像特点而备受瞩目。极化 SAR 图像分类方法是解析极化 SAR 数据的关键技术之一，在军事和民用领域展现出重要的实用价值。

随着极化 SAR 技术的演进，高分辨、多极化的 SAR 图像数据日益增多，对极化 SAR 图像分类起到了积极作用，但也引入了新的挑战。一方面，单一极化特征不足以全面满足多元化地物分类需求，而多极化特征间的冗余信息反而影响分类精度，这要求目标分类方法能有效融合利用多极化特征。另一方面，极化 SAR 图像标注过程难以避免的样本错误标记导致分类性能下降，这要求目标分类方法具备标签噪声鲁棒能力。针对以上问题，本文基于深度学习方法展开了相关研究，主要创新点与贡献如下：

(1) 研究了极化 SAR 相关理论基础。首先，介绍了电磁波极化特性的常用数学表征方式。然后，导出描述目标散射特性的极化散射矩阵和二阶统计矩阵两种方法。最后，总结了极化相干与非相干目标分解原理及代表方法，并归纳了不同极化参数的物理含义，为后续研究建立理论基础。

(2) 针对多类型极化特征信息冗余导致的分类精度下降问题，提出了基于双通道注意力的极化 SAR 图像分类方法。通过构建双通道、多尺度特征融合结构，利用极化 SAR 图像不同极化类型、不同空间位置以及不同特征尺度下的特征相关性，实现了对多类型极化特征的互信息提取和融合利用，并在此基础上构建深度分类模型，有效提高了极化 SAR 图像的分类准确率。

(3) 针对标签噪声导致的分类性能下降问题，提出了基于混合模型噪声估计的极化 SAR 图像分类方法。基于有限混合模型理论，建立了噪声标签和准确标签混杂下的损失分布模型，获取极化 SAR 图像中噪声标签的分布估计。此外，通过结合极化伪彩图边缘信息提取方法，使分类模型利用边缘知识增强识别性能，有效提升了标签噪声下的极化 SAR 图像分类准确率。

利用实测极化 SAR 数据对本文提出的方法进行验证。结果表明，本文所提方法能够有效地应对极化 SAR 图像目标分类中存在的多极化特征信息融合利用和标签噪声下的稳健识别问题，有效提高了极化 SAR 图像的分类准确率。

**关键词：** 极化合成孔径雷达，图像分类，深度学习，多极化特征，标签噪声

## ABSTRACT

Polarimetric Synthetic Aperture Radar (PolSAR) has garnered significant attention for its all-weather, all-day, and multi-polarization imaging characteristics. Classification methods for PolSAR images are crucial techniques for analyzing PolSAR data and have demonstrated important practical value in both military and civilian domains.

As PolSAR technology evolves, the increasing availability of high-resolution, multi-polarization SAR image data has played a positive role in PolSAR image classification but has also introduced new challenges. On one hand, single-polarization features are insufficient to fully meet the diverse requirements of land cover classification, while the redundancy between multi-polarization features tends to impact classification accuracy. This necessitates target classification methods that can effectively integrate and utilize multi-polarization features. On the other hand, inevitable sample mislabeling during the PolSAR image annotation process leads to a decline in classification performance, requiring target classification methods to exhibit robustness against label noise. This thesis addresses the above issues through relevant foundational and methodological research based on deep learning methods, with the main innovations and contributions as follows:

(1) Investigating the theoretical foundations of PolSAR. Firstly, commonly used mathematical representations of electromagnetic wave polarization characteristics are introduced. Then, two methods for describing target scattering characteristics, namely polarimetric scattering matrix and second-order statistical matrix, are derived. Finally, the principles and representative methods of polarimetric coherent and incoherent target decomposition are summarized, along with the physical meanings of different polarization parameters, laying a theoretical foundation for subsequent research.

(2) To address the problem of decreased classification accuracy caused by redundant information from multiple types of polarized features, a polarized SAR image classification method based on dual-channel attention is proposed. By constructing a dual-channel, multi-scale feature fusion structure and utilizing the feature correlations of different polarization types, spatial positions, and feature scales in polarized SAR images, mutual information extraction and fusion of multiple types of polarized features are achieved. Subsequently, a deep classification model is constructed based on this approach, effectively improving the classification accuracy of PolSAR images.

---

## ABSTRACT

---

(3) To mitigate the decline in classification performance caused by label noise, a polarized SAR image classification method based on mixed model noise estimation is proposed. Based on the theory of finite mixture models, a loss distribution model under the mixture of noise labels and accurate labels is established to obtain the distribution estimation of noise labels in polarized SAR images. Additionally, by combining polarized pseudocolor edge information extraction methods, the classification model can utilize edge knowledge to enhance identification performance, thereby effectively improving the classification accuracy of PolSAR images under label noise.

The proposed methods are validated using actual PolSAR data. The results indicate that the methods proposed in this thesis can effectively address the issues of integrating multi-polarization feature information and robust recognition under label noise in PolSAR image classification, thereby improving the classification accuracy of PolSAR images.

**Keywords:** Polarimetric Synthetic Aperture Radar (PolSAR), image classification, deep learning, polarization feature, label noise

## 目 录

<b>第一章 绪 论 .....</b>	<b>1</b>
1.1 课题研究背景及意义 .....	1
1.2 国内外相关研究现状 .....	2
1.2.1 极化 SAR 特征表示 .....	2
1.2.2 极化 SAR 目标分类 .....	4
1.3 论文主要内容及章节安排 .....	7
<b>第二章 极化 SAR 相关理论概述 .....</b>	<b>9</b>
2.1 引言 .....	9
2.2 极化电磁波表示方式 .....	9
2.2.1 极化椭圆 .....	10
2.2.2 琼斯矢量 .....	11
2.2.3 Stokes 矢量 .....	12
2.3 极化散射数据表示方式 .....	12
2.3.1 极化散射矩阵和 Mueller 矩阵 .....	13
2.3.2 极化相干矩阵和协方差矩阵 .....	14
2.4 极化目标分解理论基础 .....	15
2.4.1 极化相干分解 .....	16
2.4.2 极化非相干分解 .....	18
2.5 本章小结 .....	20
<b>第三章 基于双通道注意力的极化 SAR 目标分类 .....</b>	<b>21</b>
3.1 引言 .....	21
3.2 注意力机制介绍 .....	21
3.2.1 通道注意力机制 .....	22
3.2.2 空间注意力机制 .....	23
3.2.3 混合注意力机制 .....	23
3.3 双通道注意力的极化 SAR 目标分类 .....	24
3.3.1 目标分类方法框架 .....	25
3.3.2 空间和通道注意力模块 .....	27
3.3.3 极化注意力修正模块 .....	29
3.3.4 多尺度学习模块 .....	30

3.3.5 目标分类模块 .....	31
3.4 实验结果与分析 .....	32
3.4.1 实验参数设置 .....	32
3.4.2 精度评价方法 .....	33
3.4.3 AIRSAR Flevoland 数据实验 .....	35
3.4.4 E-SAR Oberpfaffenhofen 数据实验 .....	40
3.5 本章小结 .....	44
<b>第四章 基于混合模型噪声估计的极化 SAR 目标分类 .....</b>	<b>45</b>
4.1 引言 .....	45
4.2 有限混合模型 .....	45
4.2.1 高斯混合模型 .....	46
4.2.2 贝塔混合模型 .....	47
4.3 混合模型噪声估计的极化 SAR 目标分类 .....	48
4.3.1 标签噪声问题建模 .....	49
4.3.2 目标分类算法框架 .....	49
4.3.3 噪声概率估计模型 .....	51
4.3.4 边界增强模块 .....	52
4.3.5 损失函数与优化 .....	54
4.4 实验结果与分析 .....	54
4.4.1 实验参数设置 .....	54
4.4.2 AIRSAR Flevoland 数据实验 .....	55
4.4.3 E-SAR Oberpfaffenhofen 数据实验 .....	61
4.4.4 本章小结 .....	66
<b>第五章 全文总结与展望 .....</b>	<b>68</b>
5.1 全文总结 .....	68
5.2 后续工作展望 .....	68
<b>致 谢 .....</b>	<b>70</b>
<b>参考文献 .....</b>	<b>71</b>
<b>攻读硕士学位期间取得的成果 .....</b>	<b>77</b>

# 第一章 绪论

## 1.1 课题研究背景及意义

合成孔径雷达（Synthetic Aperture Radar, SAR）是一种对地探测的主动式微波成像技术，通常通过搭载在飞机或卫星上来实现对地物目标的测量。相比于光学传感器，SAR 系统不受天气条件、云层、光照等影响，能够实现全天时、全天候的成像，即使在恶劣天气条件下也能保持较高的成像质量<sup>[1]</sup>。极化 SAR 在 SAR 的基础上，通过发射、接收不同极化方式的电磁波信号，实现对地物目标散射信息的探测。相比于基础的 SAR 系统，极化 SAR 具有更丰富的散射特征，蕴含更多的目标信息。目前，由于极化 SAR 的多极化特性，极化 SAR 技术已经成为合成孔径雷达技术中不可或缺的重要分支。在极化 SAR 的众多应用中，极化 SAR 图像解译工作已经成为其中最重要的研究方向之一，其目的是快速、准确地实现地物目标的分类识别，在军事目标探测、城市规划、灾害估计等多个军事民事领域已经得到了广泛应用<sup>[2,3]</sup>。

在解读极化 SAR 数据方面，极化 SAR 图像分类技术扮演着至关重要的角色。其核心在于特征提取和目标分类方法等技术的实施。可靠的地物目标分类结果依赖于合理且有效的特征提取工程和目标分类方法，才能充分体现出极化 SAR 复杂探测数据的重要价值。由于极化 SAR 的多极化成像特性，极化 SAR 数据中蕴含了丰富的目标散射信息，这些信息的应用则依赖于高效的极化特征表达技术。极化特征的准确表述构成了极化 SAR 分析的基础，并且是整个解译过程中至关重要的环节，对最终的分类结果具有重要的影响。利用合理的特征表示，能够使分类模型更加快速、准确的迭代到最优参数，取得优秀的分类结果；反之，不合理的特征表示即便是使用更加复杂的分类器模型，也很难达到出色的分类结果。极化 SAR 图像的目标分类也属于解译的关键步骤，其本质是为极化 SAR 图像中的每一个像素赋予准确的类别。目标分类算法的核心目标是建立一种非线性的判定机制，该机制能够根据样本的相似性特征将其划分到相应的类别中，分类器的设计关键就在于其有效区分同类和异类地物目标。

近年来，尽管极化 SAR 系统成像能力方面取得了持续进步与显著发展，但其图像解译技术方面发展却相对滞后，这种不平衡的状况限制了极化 SAR 系统在实际工程中的广泛应用。尽管极化 SAR 成像系统分辨率的不断提升与获取到的极化 SAR 数据量显著增长为图像解译工作带来了积极作用，但同时也引入了新的困难与挑战。具体而言，体现在：

(1) 极化 SAR 图像表现出高分辨率趋势, 带来更为详尽的地物特征信息。目前, 对极化 SAR 数据特征工程研究不断深入, 极化特征提取方法日渐增多, 这些方法从不同的角度对地物目标的散射特性进行描述。然而, 当前大多数的极化 SAR 图像分类算法仅仅采用了单一类型的极化特征。复杂的空间场景具有更复杂的几何结构和散射特性。单一类型的极化特征无法全面地描述目标的细节信息, 无法对目标信息进行全面概括。同时, 不同类型的极化特征间可能存在较强的相关性与冗余性, 且固定的极化特征表示方式无法在所有类型的地物目标和图像中取得满意的结果<sup>[4-7]</sup>。如何有效整合并应用这些多元化的极化特征参数, 以提升地物目标特征表示的准确性和完备性, 成为极化 SAR 图像解译中的难点。

(2) 极化 SAR 技术不断发展, 极化 SAR 数据集数量呈现爆发式增长。对极化 SAR 数据集的标注工作依赖专业知识或自动标注技术, 由于极化 SAR 的复杂成像特性, 标注工作中不可避免地由于人工错误标记、自动标注技术精度不足等问题出现错误标记的样本。错误标记样本的信息会对分类器的分类规则形成不同程度的影响, 导致分类准确率的下降<sup>[8-10]</sup>。如何在混杂有噪声样本的数据集下实现高准确率的分类结果是当前极化 SAR 图像解译领域的研究难点。

针对上述问题, 本文基于深度学习方法优势, 首先研究极化 SAR 多类型极化特征有效信息挖掘方法, 旨在降低多类型极化特征信息冗余, 为目标分类任务提供高质量的极化特征表示。在此基础上, 进一步研究标签噪声下鲁棒性的极化 SAR 目标分类方法, 实现混杂标签噪声数据集中可靠分类, 提升极化 SAR 系统的实用性。

## 1.2 国内外相关研究现状

极化 SAR 图像目标分类技术包含两个核心环节, 即极化特征表示和分类器设计, 本文内容围绕极化特征的表示方法和分类器的设计方法展开。因此, 本节将对以上两个关键技术进行现状分析。

### 1.2.1 极化 SAR 特征表示

由于极化 SAR 的多极化、多通道的成像机制, 极化 SAR 图像中蕴含了丰富的目标散射信息。将极化 SAR 原始散射数据转化为直观易懂且具有实用价值的地理信息是一项极具挑战的任务, 这依赖于准确的极化特征表示方式。

现有的大多数极化 SAR 数据特征表示方法都是以像素为最基本的处理单元, 依赖于每个单独像素点的固有特性实现特征提取与分类。根据表征目标属性意义差异, 现有极化特征可以分为以下三类:

### (1) 基于观测数据的物理特征

极化 SAR 图像的观测数据包括极化散射矩阵、多视处理后的相干矩阵和协方差矩阵等。这类特征利用简单的四则运算或组合变换对观测数据进行信息表示，主要有反射率、反射强度、幅度、相位等。1992 年，Rignot 等人<sup>[11]</sup>率先提出通过对极化协方差矩阵个元素取对数来实现极化 SAR 图像分割；1994 年，Pierce 等人<sup>[12]</sup>结合了极化散射矩阵和专家系统的知识集成技术，开展了对极化 SAR 图像分类研究；1988 年，Kong 等人<sup>[13]</sup>提出了采用极化散射矩阵中各通道的比例关系作为分类指标，用于极化 SAR 图像分类任务；2001 年，Lee 等人<sup>[14]</sup>运用散射矩阵计算得到相位差异信息，并结合最大似然算法对图像分类；2017 年，Ding 等人<sup>[6]</sup>提取了散射矩阵和相干矩阵的元素，组合形成特征向量，用于分类研究。

基于观测数据的物理特征虽易于获取且直观明了，但是表征信息相对浅显，未能深入解释地物目标内部具体的物理散射机制。这一类特征因为简便而被广泛使用，但是在提供深层次物理信息方面存在一定的局限性。

### (2) 基于目标分解的散射特征

极化目标分解理论通过从物理散射意义层面对极化 SAR 数据进行约束，来反映地物目标确切物理意义的散射特性，是极化 SAR 数据利用中最为经典且至关重要的理论之一。1970 年，Huynen 首次提出了目标分解理论<sup>[15,16]</sup>，为极化 SAR 特征表示方法研究奠定了理论基础。极化目标分解方法是使用多个散射基将极化 SAR 数据分解为多个具有不同物理意义的矩阵分类加权和的形式。根据处理的数据差异，可以分为极化相干分解和极化非相干分解两种形式，分别用于处理极化散射矩阵和极化相干矩阵或协方差矩阵。

极化相干分解针对散射矩阵数据，从物理层面进行约束，利用不同的基向量将散射矩阵分解为不同物理意义的矩阵分量加权和。典型的极化相干分解方法包括 Pauli 分解<sup>[17]</sup>、Krogager 分解<sup>[18]</sup>以及 Cameron 分解<sup>[19]</sup>等。Pauli 分解将散射矩阵分解为分别对应单次散射、方位角为 0° 和 45° 的二次散射效应的综合；Krogager 分解则是将散射矩阵分解为球形散射、二面角散射和螺旋型散射三类散射机制的组合形态；Cameron 分解在 Pauli 分解基础上进行拓展，提出以经过旋转调整后的最大散射分量作为主要分解特征。

极化非相干分解方法针对多视矩阵数据，将其分解为多个反映确切物理意义的参数加权和的形式。典型的非相干分解技术包括 Cloude 分解<sup>[20]</sup>、Freeman 分解<sup>[21]</sup>以及 Holm 分解<sup>[22]</sup>等。Cloude 分解立足于矩阵特征值理论，通过分析相关矩阵的最大特征值来推测地物目标的散射特性类别，并且引入了一系列具有重要意义的极化散射特征参数，如散射熵、各项异性指数和平均散射角等；Freeman 分

解是一种基于散射模型的分解技术，根据地物目标所表现出的不同散射机制，将极化 SAR 数据划分为三个基本散射类别：平面散射、二次散射和体散射；Holm 分解通过将散射矩阵分解为几个相互正交的散射分量，代表不同的散射机制：体散射，表面散射和两个斜面散射。

目标分解方法为极化 SAR 数据处理提供了一系列具有特定物理含义的极化特征，从不同的角度对地物目标散射特性进行描述，是极化 SAR 数据特征表示研究领域的核心方法之一。一般而言，每种目标分解方法可以提炼出 1 至 4 个极化特征参数，这些参数反映不同类型的散射机制。在实际复杂地理环境中，各种目标因自身结构和周围环境的影响会产生迥异的散射回波响应，即使是同种类型的地物目标，也可能因为观察角度、地形地貌、植被覆盖以及其他因素导致其散射特征不尽相同<sup>[23]</sup>。因此，仅仅依赖单一的极化特征描述手段往往不足以全面揭示地物目标的所有详细信息，这就要求在实际应用中综合运用多种目标分解方法，以便从多元化的角度展示并区分复杂地物的空间散射特性。

### (3) 基于空间图像的纹理特征

在极化 SAR 图像分类领域，空间纹理特征作为极化特征的补充表示，是对地物目标空间细节特性描述的重要特性之一。直方图统计、Gabor 滤波、小波变换等空间纹理特征提取方法在图像解译领域发挥了重要作用。Haralick 等人<sup>[24]</sup> 基于灰度共生概率的纹理特征来对 SAR 图像分类，并通过实验证实了方案可行性；2013 年，Uhlmann 等人<sup>[9]</sup> 基于 Puali 伪装图像集成颜色特征引入额外知识，结合随机森林分类器实现精细的地物目标分类，有效提升了分类性能；2015 年，Ji 等人<sup>[25]</sup> 采用局部二值模式以及 HSV 色彩空间的颜色属性，构建特征向量，应用于极化 SAR 图像分类。

尽管空间纹理特征作为直观简单易实现的补充特征为极化 SAR 图像分类带来了积极的作用，但是通常受限于预设尺寸大小，在特征面对空间尺度变换时存在相应的缺陷，无法灵活适应不同尺度下的地物特征变化。

以上方法集中于研究极化 SAR 图像中目标所体现的多元化散射特性以及关键的图像特征，结合合理的目标分类方法，能够在特定条件下取得良好的分类结果。而在多类型极化特征综合利用方面，鲜有相应的研究。

## 1.2.2 极化 SAR 目标分类

极化 SAR 图像分类方法作为极化 SAR 图像解译的关键步骤之一<sup>[26]</sup>，受到了国内外诸多研究学者的关注和重视。极化 SAR 图像分类任务本质是将图像中的每一个像素根据分类规则赋予一个类别标签，确定所属的地物类别。图1-1展示了极

化 SAR 图像数据处理以及目标分类方法的基本流程，整个流程包括极化 SAR 数据处理、极化特征表示、样本预处理、分类方法四个步骤。其中，目标分类方法是通过对输入极化 SAR 数据样本的学习，形成按照样本特征进行分类的规则，根据分类规则对剩下的测试样本完成目标分类的流程。根据训练过程中使用的有标记和无标记样本情况，可以分为有监督、无监督和半监督三种类型。

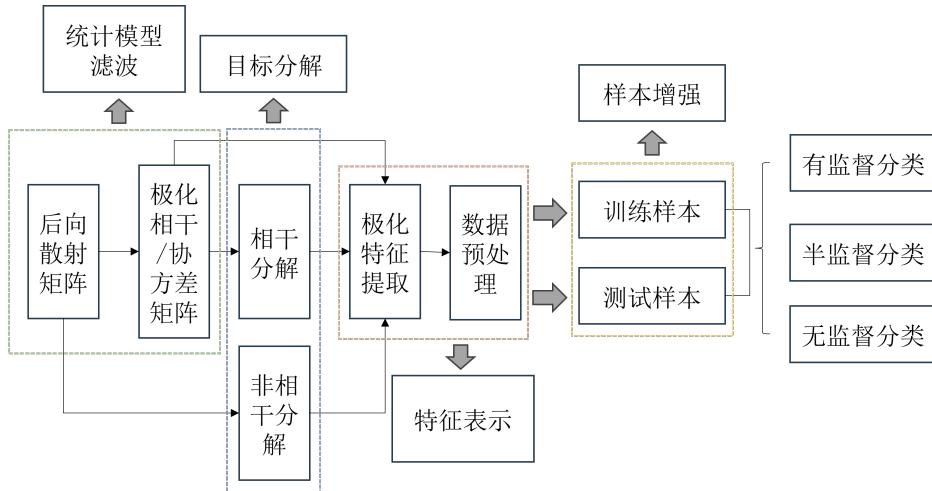


图 1-1 极化 SAR 图像目标分类流程

### 1.2.2.1 无监督分类方法

无监督极化 SAR 图像分类是在缺乏标记训练样本条件下，完成图像的目标分类任务。这类方法通常基于极化 SAR 图像本身的内在结构和特性，如散射机理分析、聚类算法（如 K-means、谱聚类、密度峰聚类等）。这些方法试图发现图像数据内在的自然群体结构，根据极化散射特性的相似性将图像划分成不同的类别，但无法直接提供类别名称，而是生成潜在的集群划分。

1989 年，Van Zyl 等人<sup>[27]</sup> 创新性地提出了基于入射和反射波相互作用关系的分类标准，首次将目标散射属性应用到分类方法；1997 年，Cloude 等人<sup>[20]</sup> 提出了极化熵 H 和平均散射角  $\bar{\alpha}$  的概念作为极化特征描述参数，并在  $H - \bar{\alpha}$  二维空间划定了 8 个反映散射机制的区域，用于区分不同的目标类别；1999 年，Lee 等人<sup>[28]</sup> 在 Cloude 的研究成果上深化了无监督学习方法，开创性地结合了地物目标散射特性和统计特性，为后续无监督研究提供了重要理论支撑。

2001 年，Ferro-Famil 等人<sup>[29]</sup> 在 Cloude 等人基础上进一步引入了各项异度性参数 A，并将  $H - \bar{\alpha}$  图上的区域细分至 16 个，捕捉更多的细节信息，从而提高分类精度；2003 年，Yamaguchi 等人<sup>[30]</sup> 结合散射总功率 SPAN 设计了无监督分类方法，提高分类过程的收敛性；2004 年，Lee 等人<sup>[31]</sup> 在 Freeman 的研究基础上，整

合了复 Wishart 分类方法，采用先模糊分类再精细化分类的粗略，通过迭代 Wishart 方法得到最终的分类结果。2017 年，Bi 等人<sup>[32]</sup>提出了一种融合目标分解理论和 K-Wishart 似然分类的无监督分类方案，首先依据 Pottier 和 Lee 的方法生成初步的分类结果，继而利用多元极化特征及 K-Wishart 分类方法中的最大似然方法对结果进行精细分类，从而实现更高精度的分类效果。

尽管无监督分类方法能够深入挖掘极化 SAR 数据所蕴含的目标统计分布规律和目标散射特性，但其在实践中受限于样本类别信息缺失，在面对同种物质表现出不同回波谱特性和不同物质却呈现相似回波谱特性的情形时，难以达到期望的分类性能。

### 1.2.2.2 有监督分类方法

相比于无监督分类方法，有监督的分类策略在指定分类规则过程中，得益于标记数据的辅助，能够进行更为精确的匹配训练，从而能够带来更为出色的分类结果。近年来，由于深度学习的自动挖掘数据鉴别特征和优越的分类性能，广泛的应用于自然语言处理、智能驾驶、信息检索等领域。由于其优越的性质，越来越多的研究将深度学习方法应用到遥感图像解译领域中，也获得了巨大的成果。

2014 年，Lv 等人<sup>[33]</sup>将深度信念网络（Deep Belief Network, DBN）应用到极化 SAR 图像分类中，并取得了优异的分类效果；2014 年，Xie 等人<sup>[34]</sup>利用堆叠式自编码器（Stacked Sparse Autoencoder, SSAE）来获取可鉴别特征，随后基于标签微调，实现了分类性能和区域分类视觉效果上的巨大提升。2016 年，Zhou 等人<sup>[35]</sup>使用一维向量来表征极化 SAR 数据的相干矩阵，并将其作为 CNN 的输入作为分类，开创性地将卷积网络分类方法引入到极化 SAR 图像分类中。2017 年，Zhang 等人<sup>[36]</sup>构建了一种复数卷积网络结构（Complex-valued CNN, CV-CNN），该模型将传统卷积网络中的核心组成模块——卷积层、池化层、激活函数以及全连接层等均推广至复数形式，还提出了一种专为复数域设计的反向传播优化策略，为后续的一系列设计复数域的分类算法奠定了技术基础。

### 1.2.2.3 半监督分类方法

半监督分类方法旨在结合监督学习和无监督学习方法，同时利用有标签样本数据和无标签样本数据对分类模型进行训练。实际场景中，要获取充足数量的高质量训练样本通常是非常困难的，深度网络训练过程仅有少量标记样本和大量无标记样本。因此，如何利用大量的无标签数据和少量的标记样本来辅助网络学习到更加准确的分类规则，已经成为一个研究重点。

2016 年，Liu 等人<sup>[10]</sup>采用图构建技术，通过选取特定的锚点来构造邻接矩阵，

旨在实现从有限标签样本到大规模无标签样本的信息扩散过程；2017年，Hou等人<sup>[37]</sup>基于字典学习和区域一致特性，学习到稀疏的高级特征之后结合无标签样本实现分类器的训练；2017年，Jie等人<sup>[38]</sup>基于超像素方法来应对极化SAR中存在的相干斑噪声的问题；2019年，Liu等人<sup>[39]</sup>和Liu等人<sup>[40]</sup>利用无标签样本数据，通过生成对抗网络学习到数据的分布特性，实现生成样本扩充训练集数量。

以上所提及的代表性方法均在极化SAR图像分类中取得了显著的成果，有效推动了极化SAR目标分类的研究。但目前主流研究广泛采用散射矩阵或相干矩阵作为网络输入，尚未充分挖掘和利用极化SAR图像数据内在的多类型极化特征所蕴含的全部信息，如何利用深度网络来探索有效的极化特征信息表示方式仍然需要进一步的研究。此外，现有极化SAR图像分类研究大多在理想的高质量、数量充足的训练集条件下完成，而针对训练样本中存在错误标记的标签噪声样本缺乏考虑，如何在混杂有噪声样本的数据集下实现高准确率的分类结果也需要进一步展开研究。

### 1.3 论文主要内容及章节安排

本文主题内容及各章安排如图1-2所示，针对极化SAR多类型极化特征信息冗余与标签噪声下目标分类问题，本文从极化SAR相关理论基础、多类型极化信息利用以及标签噪声下目标分类方法三个方面展开研究。本文共分为五个章节，各章节结构安排为：

第一章：绪论。阐述本文工作的研究背景与意义，并且对其中的极化特征表示、极化SAR目标分类方法进行国内外研究现状进行概括分析，最后给出全文的结构安排。

第二章：介绍极化SAR相关理论基础。首先，介绍了电磁波的极化特性及其数学表征方式。其次，导出了针对目标散射特性的极化散射矩阵和二阶统计矩阵两种描述方法。最后，总结了极化相干与非相干目标分解方法，并归纳了不同极化参数的物理含义，为本文的研究工作奠定理论基础。

第三章：介绍所提出的基于双通道注意力的极化SAR目标分类方法。首先，简要阐述多类型极化特征利用存在的相关问题。其次，分别介绍了通道、空间以及混合注意力方法的基础原理。随后，介绍提出的双通道注意力的极化SAR目标分类方法，并对方法中的模块细节、原理设计进行了相关阐述。最后，基于实测极化SAR数据集进行验证测试，根据实验结果从视觉和数值方面对提出方法性能进行评价。

第四章：介绍所提出的基于混合模型噪声估计的极化SAR图像分类方法。首

先，简要阐述极化 SAR 图像解译中存在的标签噪声问题及其为目标分类任务带来的影响。其次，简要介绍了有限混合模型基本原理，并分析了不同混合模型的优缺点。随后，重点叙述了所提出的基于混合模型与边界增强的极化 SAR 目标分类方法，介绍了混合模型概率估计原理以及边界增强模块详细执行步骤，并导出分类模型鲁棒损失优化函数。最后，基于实测极化 SAR 数据集对不同标签噪声源进行验证测试，根据实验结果从视觉和数值方面对提出方法性能进行评价。

第五章：对本文研究工作进行总结，并展望未来工作。

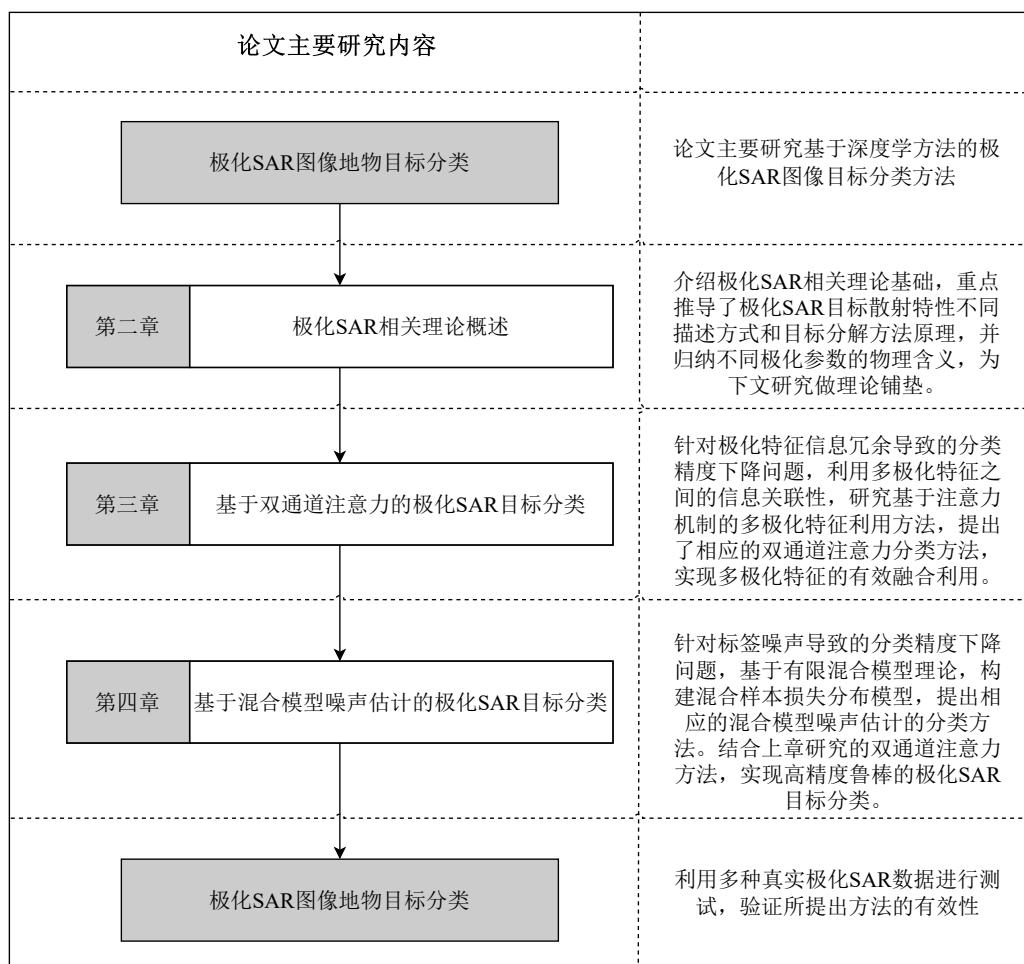


图 1-2 论文主体部分内容安排

## 第二章 极化 SAR 相关理论概述

### 2.1 引言

极化 SAR 技术通过发送和接收不同极化方式的电磁波，提供丰富的目标极化散射信息，具有全天时、全天候成像特点。因此，近年来，极化 SAR 在城市规划、军事探测、灾害检测、农作物监控等多个领域有着广泛的应用<sup>[2,41,42]</sup>。极化 SAR 数据具有丰富的极化特征描述方式，如何有效、全面地利用这些极化特征，增强目标散射特性的表征能力，是极化 SAR 图像分类任务中的关键任务<sup>[43–45]</sup>。本章将系统阐述极化 SAR 基本理论，内容涵盖极化电磁波数学表述方式、多种描述极化散射特征的理论与方法、目标分解理论原理及其代表性分解方法的具体实施步骤和计算流程。

### 2.2 极化电磁波表示方式

电场与磁场的相互作用产生电磁波。在电磁波传播过程中，电场与磁场振荡平面始终保持垂直，并且都与电磁波的传播方向相垂直，如图2-1所示：

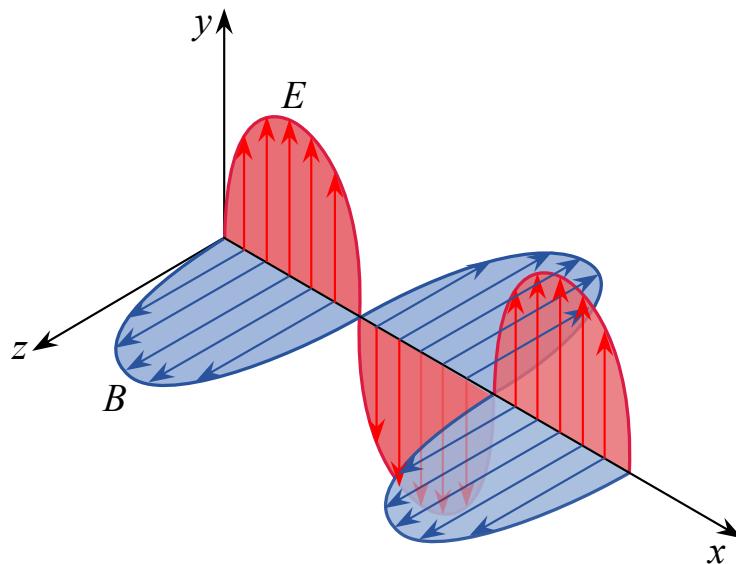


图 2-1 电磁波传输过程示意图<sup>[46]</sup>

极化是电磁波的基本特性之一，是指在固定的空间点处，电场振荡方向随着时间的变化方式。在笛卡尔坐标系中，设定电磁波的传播方向为  $z$  轴正方向，电场与磁场的关系可以使用麦克斯韦方程组表示<sup>[1,47]</sup>：

$$\begin{cases} \nabla \times H(z, t) = \varepsilon \frac{\partial E(z, t)}{\partial t} \\ \nabla \times E(z, t) = -\mu \frac{\partial H(z, t)}{\partial t} \\ \nabla \cdot H(z, t) = 0 \\ \nabla \cdot E(z, t) = 0 \end{cases} \quad (2-1)$$

对方程组(2-1)第二个等式两边取旋度，有：

$$\nabla \times (\nabla \times E) = -\mu \frac{\partial}{\partial t} (\nabla \times H) \quad (2-2)$$

通过矢量恒等式  $\nabla \times (\nabla \times E) = \nabla(\nabla \cdot E) - \nabla^2 E$  和方程组(2-1)第四个等式可以得出电磁波的波动方程：

$$\nabla^2 E(z, t) - \mu \varepsilon \frac{\partial^2 E(z, t)}{\partial t^2} = 0 \quad (2-3)$$

极化 SAR 系统与地面目标之间的距离满足远场条件，可以将极化 SAR 工作过程中收发的电磁波近似为平面波。通过波动方程，可以得到平面波的表达式：

$$E(z, t) = \begin{bmatrix} E_x(z, t) \\ E_y(z, t) \\ 0 \end{bmatrix} = \begin{bmatrix} E_{0x} \cos(\omega t - kz + \delta_x) \\ E_{0y} \cos(\omega t - kz + \delta_y) \\ 0 \end{bmatrix} \quad (2-4)$$

其中， $E_{0x}$ ,  $E_{0y}$ ,  $\delta_x$  和  $\delta_y$  分别表示电场在  $x$  与  $y$  方向上的幅度和初始相位， $k$  表示传播常量。

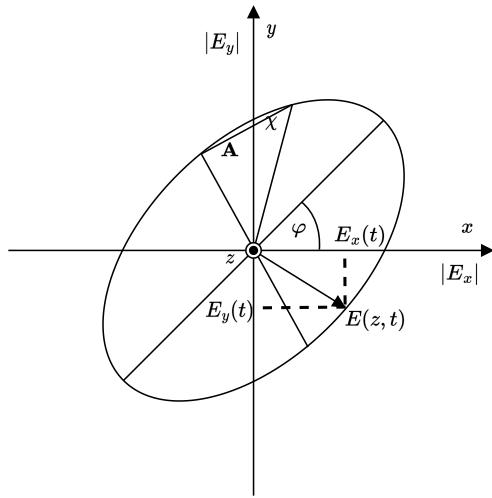
### 2.2.1 极化椭圆

在空间中某个固定的点处电场矢量端点的轨迹可以用来描述电磁波的极化状态。对于某个时刻  $t$ ，由公式(2-4)可得：

$$\left( \frac{E_x(z, t)}{E_{x0}} \right)^2 - 2 \left( \frac{E_x(z, t)E_y(z, t)}{E_{x0}E_{y0}} \right) \cos(\delta) + \left( \frac{E_y(z, t)}{E_{y0}} \right)^2 = \sin^2(\delta) \quad (2-5)$$

其中， $\delta = \delta_x - \delta_y$ ,  $-\pi \leq \delta \leq \pi$ 。

由公式(2-5)在  $z_0$  处的运动轨迹可以得到极化椭圆，如图2-2所示。对于任意一个极化椭圆。可以通过椭圆幅度  $A$ , 椭圆方向角  $\chi \in [-\frac{\pi}{4}, \frac{\pi}{4}]$  和椭圆孔径  $\phi \in [-\frac{\pi}{2}, \frac{\pi}{2}]$

图 2-2 极化椭圆示意图<sup>[1]</sup>

进行唯一表示:

$$A = \sqrt{|E_{x_0}|^2 + |E_{y_0}|^2} \quad (2-6)$$

$$\tan 2\phi = \frac{2 |E_{x_0}| |E_{y_0}|^2}{|E_{x_0}|^2 - |E_{y_0}|^2} \cos(\delta) \quad (2-7)$$

$$\sin 2\chi = \frac{2 |E_{x_0}| |E_{y_0}|^2}{|E_{x_0}|^2 + |E_{y_0}|^2} \sin(\delta) \quad (2-8)$$

根据电场矢量的旋转方向, 可以将极化电磁波分为左旋和右旋两种类型。当椭圆方向角  $\chi > 0$  时, 表示左旋极化波; 当椭圆方向角  $\chi < 0$  时, 表示右旋极化波。

## 2.2.2 琼斯矢量

为了简化平面电磁波极化状态的描述方式, 还可以通过琼斯矢量的形式表示。将公式(2-4)使用复数的形式表示为:

$$E(z, t) = \begin{bmatrix} E_{0x} \cos(\omega t - kz + \delta_x) \\ E_{0y} \cos(\omega t - kz + \delta_y) \end{bmatrix} = \operatorname{Re} \left\{ \begin{bmatrix} E_{0x} e^{j\delta_x} \\ E_{0y} e^{j\delta_y} \end{bmatrix} e^{j\omega t} e^{-jkz} \right\} \quad (2-9)$$

其中,  $\operatorname{Re}(\cdot)$  表示取实部。琼斯矢量可以定义为:

$$E_{\text{Jones}} = \begin{bmatrix} E_x \\ E_y \end{bmatrix} = \begin{bmatrix} E_{0x} e^{j\delta_x} \\ E_{0y} e^{j\delta_y} \end{bmatrix} \quad (2-10)$$

极化椭圆描述的极化波状态与琼斯矢量表示是等价的，可以使用椭圆极化的描述参数来表示琼斯矢量：

$$E_{\text{Jones}} = A e^{ia} \begin{bmatrix} \cos \phi \cos \chi - i \sin \phi \sin \chi \\ \sin \phi \cos \chi + i \cos \phi \sin \chi \end{bmatrix} \quad (2-11)$$

其中， $\alpha$  表示绝对相位项。琼斯矢量可以通过更加简洁的矩阵形式表示，定义为：

$$E_{\text{Jones}} = A e^{ia} \begin{bmatrix} \cos \phi & -\sin \phi \\ \sin \phi & \cos \phi \end{bmatrix} \begin{bmatrix} \cos \chi \\ i \sin \chi \end{bmatrix} \quad (2-12)$$

### 2.2.3 Stokes 矢量

与琼斯矢量使用两个复数表示电磁波的极化状态不同，Stokes 矢量使用  $[g_0, g_1, g_2, g_3]$  四个实数从电磁波功率的角度来描述电磁波的极化状态，Stokes 参数定义如下：

$$\begin{cases} g_0 = |E_x|^2 + |E_y|^2 \\ g_1 = |E_x|^2 - |E_y|^2 \\ g_2 = 2 |E_x| |E_y| \cos \delta \\ g_3 = 2 |E_x| |E_y| \sin \delta \end{cases} \quad (2-13)$$

其中， $E_x$  和  $E_y$  分别表示电场矢量在 x 轴和 y 轴上的幅度； $\delta$  表示电场矢量在 x 轴和 y 轴上的相位差； $g_0$  表示电磁波总功率； $g_1$  表示水平或垂直极化分量的功率； $g_2$  表示  $\pm 45^\circ$  线性极化分量的功率； $g_3$  表示左右旋极化分类的功率之和。

可以使用极化椭圆参数表示公式(2-13)，具体如下：

$$g = \begin{bmatrix} A^2 \\ A^2 \cos(2\varphi) \cos(2\tau) \\ A^2 \sin(2\varphi) \cos(2\tau) \\ A^2 \sin(2\tau) \end{bmatrix} \quad (2-14)$$

## 2.3 极化散射数据表示方式

极化 SAR 系统通过发射水平和垂直两种不同极化方式的电磁波，对目标进行探测，当电磁波遇到目标后，部分被目标体吸收，另外一部分通过目标辐射，形成反射回波。由于散射回波因目标的散射特性而异，因此可以通过分析回波的特性来推断目标的特征。为了能够表征目标的极化散射特性，需要引入不同的参数

来描述各个极化通道散射回波在幅度相位上的差异。

### 2.3.1 极化散射矩阵和 Mueller 矩阵

极化 SAR 系统从发射的不同极化形式的电磁波信号，到以不同的极化方式接收经过目标反射的电磁波，目标的反射过程可以看做电磁波对应琼斯矢量的线性转换的过程。为了描述这个线性转换的过程，引入极化散射矩阵<sup>[48]</sup>，又称为 Sinclair 矩阵，简写为  $\mathbf{S}$ ，通常使用  $2 \times 2$  的复数矩阵表示，具体如下：

$$\mathbf{S} = \begin{bmatrix} S_{\text{HH}} & S_{\text{HV}} \\ S_{\text{VH}} & S_{\text{VV}} \end{bmatrix} \quad (2-15)$$

其中，H 和 V 分别表示水平和垂直的极化方式， $S_{XY}(X,Y=H,V)$  表示发射 X 极化波、接收 Y 极化波的后向散射系数，在满足单站互易条件下， $S_{\text{HV}} = S_{\text{VH}}$ 。此时，极化散射矩阵可以表示为如下形式：

$$\mathbf{S} = \begin{bmatrix} S_{\text{HH}} & S_{\text{HV}} \\ S_{\text{HV}} & S_{\text{VV}} \end{bmatrix} \quad (2-16)$$

以上的极化散射矩阵适用于表述完全极化波对应的琼斯矢量的入射与散射之间的线性关系，但是通常情况下，入射与散射的电磁波都是部分极化电磁波，这种情况下，需要引入 Mueller 矩阵<sup>[49]</sup> 来进行表示它们之间的关系。

Mueller 矩阵是一个  $4 \times 4$  的矩阵，简写为  $\mathbf{M}$ ，具体表示如下：

$$\mathbf{M} = \mathbf{R} (\mathbf{S} \otimes \mathbf{S}^*) \mathbf{R}^{-1} \quad (2-17)$$

其中， $\mathbf{S}$  是 Sinclair 矩阵， $\mathbf{R}$  是转换系数矩阵，具体如下：

$$\mathbf{R} = \begin{bmatrix} 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & -1 \\ 0 & 1 & 1 & 0 \\ 0 & i & -i & 0 \end{bmatrix} \quad (2-18)$$

从公式(2-17)和公式(2-18)可以看出， $\mathbf{M}$  实际上是经过  $\mathbf{S}$  运算得到，因此  $\mathbf{M}$  与  $\mathbf{S}$  属于一一对应的关系，但是  $\mathbf{S}$  相比于  $\mathbf{M}$  还多具备了绝对的相位信息。

### 2.3.2 极化相干矩阵和协方差矩阵

在极化 SAR 系统成像过程中，目标的散射回波通常会受到周围环境中其他散射体产生的杂波的干扰。为了减少散射杂波的影响，实践中尝尝采用矢量化分解对极化散射矩阵  $\mathbf{S}$  进行处理，导出描述二阶统计特性的极化相干矩阵和极化协方差矩阵。

通常利用正交的矩阵基来对极化散射矩阵进行矢量化分解，矢量化过程表示如下：

$$\mathbf{S} = \begin{bmatrix} S_{\text{HH}} & S_{\text{HV}} \\ S_{\text{HV}} & S_{\text{VV}} \end{bmatrix} \Rightarrow \mathbf{K}_4 = \mathbf{V}(\mathbf{S}) = \frac{1}{2} \text{Trace}(\mathbf{S}\Psi) = [k_0, k_1, k_2, k_3]^T \quad (2-19)$$

其中， $\mathbf{V}(\cdot)$  表示矢量化操作， $\text{Trace}(\cdot)$  表示矩阵求迹， $\Psi$  表示  $2 \times 2$  的复单位矩阵， $T$  表示矩阵转置。最常用的有两组标准基，分别是 Lexicographic 基  $\Psi_L$  和 Pauli 基  $\Psi_P$ ，具体如下：

$$\Psi_L = \left\{ \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 2 \\ 0 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 0 \\ 2 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix} \right\} \quad (2-20)$$

$$\Psi_P = \left\{ \sqrt{2} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \sqrt{2} \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}, \sqrt{2} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \sqrt{2} \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix} \right\} \quad (2-21)$$

基于以上两组基，分别得到目标散射矢量：

$$\mathbf{k}_{4L} = [S_{\text{HH}}, S_{\text{HV}}, S_{\text{VH}}, S_{\text{VV}}] \quad (2-22)$$

$$\mathbf{k}_{4P} = \frac{1}{\sqrt{2}} [S_{\text{HH}} + S_{\text{VV}}, S_{\text{HH}} - S_{\text{VV}}, S_{\text{HV}} + S_{\text{VH}}, i(S_{\text{HV}} - S_{\text{VH}})] \quad (2-23)$$

由单站互易定理可知  $S_{\text{HV}} = S_{\text{VH}}$ ，可以将公式(2-22)和(2-23)简写为：

$$\begin{aligned} \mathbf{k}_{3L} &= [S_{\text{HH}}, \sqrt{2}S_{\text{HV}}, S_{\text{VV}}] \\ \mathbf{k}_{3P} &= \frac{1}{\sqrt{2}} [S_{\text{HH}} + S_{\text{VV}}, S_{\text{HH}} - S_{\text{VV}}, 2S_{\text{HV}}] \end{aligned} \quad (2-24)$$

通过计算散射矢量  $\mathbf{k}_{3L}$  与其复共轭转置矢量  $\mathbf{k}_{3L}^H$  的内积可以得到极化协方差矩阵  $\mathbf{C}$ ，具体表示如下：

$$\mathbf{C} = \langle \mathbf{k}_{3L} \cdot \mathbf{k}_{3L}^H \rangle = \begin{bmatrix} \langle |S_{\text{HH}}|^2 \rangle & \langle \sqrt{2}S_{\text{HH}}S_{\text{HV}}^* \rangle & \langle S_{\text{HH}}S_{\text{VV}}^* \rangle \\ \langle \sqrt{2}S_{\text{HV}}S_{\text{HH}}^* \rangle & \langle 2|S_{\text{HV}}|^2 \rangle & \langle \sqrt{2}S_{\text{HV}}S_{\text{VV}}^* \rangle \\ \langle S_{\text{VV}}, S_{\text{HH}}^* \rangle & \langle \sqrt{2}S_{\text{VV}}, S_{\text{HV}}^* \rangle & \langle |S_{\text{VV}}|^2 \rangle \end{bmatrix} \quad (2-25)$$

同理，通过计算散射矢量  $\mathbf{k}_{3P}$  与其复共轭转置矢量  $\mathbf{k}_{3P}^H$  的内积可以得到极化相干矩阵  $\mathbf{T}$ ，具体表示如下：

$$\begin{aligned}\mathbf{T} &= \langle \mathbf{3P} \cdot \mathbf{3P}^{*H} \rangle \\ &= \frac{1}{2} \begin{bmatrix} \langle |S_{HH} + S_{VV}|^2 \rangle & \langle (S_{HH} + S_{VV})(S_{HH} - S_{VV})^* \rangle & \langle 2(S_{HH} + S_{VV})S_{HV}^* \rangle \\ \langle (S_{HH} - S_{VV})(S_{HH} + S_{VV})^* \rangle & \langle |S_{HH} - S_{VV}|^2 \rangle & \langle 2(S_{HH} - S_{VV})S_{HV}^* \rangle \\ \langle 2S_{HV}(S_{HH} + S_{VV})^* \rangle & \langle 2S_{HV}(S_{HH} - S_{VV})^* \rangle & \langle 4|S_{HV}|^2 \rangle \end{bmatrix} \quad (2-26)\end{aligned}$$

其中， $\langle \cdot \rangle$  表示取总体平均， $(\cdot)^*$  和  $(\cdot)^T$  分别表示复共轭和矩阵转置。

极化协方差矩阵  $\mathbf{C}$  与极化相干矩阵  $\mathbf{T}$  都具备半正定的 Hermitain（即埃尔米特）特性，两者之间可以相互转换，计算过程如下式所示：

$$\mathbf{C} = \mathbf{U}^H \mathbf{T} \mathbf{U} = \mathbf{U}^{-1} \mathbf{T} \mathbf{U} \quad (2-27)$$

$$\mathbf{T} = \mathbf{U} \mathbf{C} \mathbf{U}^H = \mathbf{U} \mathbf{C} \mathbf{U}^{-1} \quad (2-28)$$

其中， $\mathbf{U}$  表示单位转换矩阵，具体可以表示为：

$$\mathbf{U} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 0 & 1 \\ 1 & 0 & -1 \\ 0 & \sqrt{2} & 0 \end{bmatrix} \quad (2-29)$$

## 2.4 极化目标分解理论基础

极化散射矩阵全面的描述了目标的散射特征，可以从中获取到目标表面粗糙度、对称性以及取向性等信息，为深层次地探索目标特性提供了数据支撑。但是，仅仅基于测量到的散射数据并无法直接获取丰富的信息，还需要进一步对测量的散射矩阵进行数据处理，进而从其中提取出能表征目标特征的极化描述。为了更清晰的描述不同目标的极化特性，可以将散射矩阵通过不同的散射模型作为基分解为几个矩阵的线性组合，由于这些基础散射模型具有不同的物理意义，分解矩阵可以表示目标的不同散射特性，为分类识别任务提供更加充分、全面的极化信息。根据处理数据的不同，极化目标分解方法可以分类相干分解和非相干分解两种类型。极化目标分解根据分解的数据分为相干分解和非相干分解两种类别：相干分解的对象是极化散射矩阵，要求目标具有稳定的散射性质和相干的散射波；非相干分解的对象是极化相干矩阵或极化协方差矩阵，要求目标具有非相干散射波，散射的特征随时间变化，探测目标可以是分布式目标。

### 2.4.1 极化相干分解

极化相干分解的基本思想是通过不同的基础散射模型，将测量得到的散射矩阵分解成多个散射机制之和，如下式所示：

$$\mathbf{S} = \sum_{k=1}^N a_k \mathbf{S}_k \quad (2-30)$$

其中， $\mathbf{S}$  表示极化散射矩阵， $\mathbf{S}_k$  表示分解得到的经典目标的散射矩阵， $a_k$  表示对应的权值。

经典的极化相干分解方法有 Pauli 分解<sup>[17]</sup>、Krogager 分解<sup>[18]</sup>、Cameron 分解<sup>[19]</sup>、球坐标分解<sup>[50]</sup> 等。下面将介绍 Pauli 分解和 Krogager 分解的基本原理。

#### 2.4.1.1 Pauli 分解

Pauli 分解方法是使用 Pauli 基对极化散射矩阵进行分解，分解过程如下式所示：

$$\mathbf{S} = \begin{bmatrix} S_{\text{HH}} & S_{\text{HV}} \\ S_{\text{VH}} & S_{\text{VV}} \end{bmatrix} = a\mathbf{S}_a + b\mathbf{S}_b + c\mathbf{S}_c + d\mathbf{S}_d \quad (2-31)$$

其中， $a, b, c, d$  均是权重系数， $\mathbf{S}_a, \mathbf{S}_b, \mathbf{S}_c, \mathbf{S}_d$  表示 Pauli 基，具体如下式所示：

$$\mathbf{S}_a = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \mathbf{S}_b = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}, \mathbf{S}_c = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \mathbf{S}_d = \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix} \quad (2-32)$$

权重系数使用向量的形式，可以表示为：

$$\mathbf{K} = \begin{bmatrix} a & b & c & d \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} S_{\text{HH}} + S_{\text{VV}} & S_{\text{HH}} - S_{\text{VV}} & S_{\text{HV}} + S_{\text{VH}} & i(S_{\text{VH}} - S_{\text{HV}}) \end{bmatrix}^T \quad (2-33)$$

满足单站互易条件时，可以简化为：

$$\mathbf{SS} = \begin{bmatrix} a & b & c \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} S_{\text{HH}} + S_{\text{VV}} & S_{\text{HH}} - S_{\text{VV}} & 2S_{\text{HV}} \end{bmatrix}^T \quad (2-34)$$

对于 Pauli 分解的每个分量的物理解释如表2-1所示。

表 2-1 Pauli 分解

Pauli 基	散射类型	物理描述
$\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$	奇次散射	球体、平坦平面或三面角反射器
$\begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$	偶次散射	二面角反射器
$\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$	$\frac{\pi}{4}$ 偶次散射	与水平 $\frac{\pi}{4}$ 倾角的二面角

#### 2.4.1.2 Krogager 分解

Krogager 分解是将极化散射矩阵  $\mathbf{S}$  分解为球散射、二面角散射以及螺旋体散射三个散射分量的加权和，具体如下：

$$\begin{aligned} \mathbf{S} &= e^{j\varphi} \left\{ e^{j\varphi_S} k_S \mathbf{S}_{sphere} + k_D \mathbf{S}_{dipole(\theta)} + k_H \mathbf{S}_{helix(\theta)} \right\} \\ &= e^{j\varphi} \left\{ e^{j\varphi_S} k_S \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} + k_D \begin{bmatrix} \cos 2\theta & \sin 2\theta \\ \sin 2\theta & -\cos 2\theta \end{bmatrix} + k_H e^{\pm j2\theta} \begin{bmatrix} 1 & \pm j \\ \pm j & -1 \end{bmatrix} \right\} \quad (2-35) \end{aligned}$$

其中， $k_s$ 、 $k_D$ 、 $k_H$  分别表示各个分量的权值，也被称作能量； $\theta$  表示取向角； $\varphi$  表示散射矩阵的绝对相位。

当电磁波以左旋圆极化方式发射，右旋圆极化接收时，Krogager 分解可以表示为：

$$\begin{aligned} \mathbf{S}_{(R,L)} &= \begin{bmatrix} \mathbf{S}_{RR} & \mathbf{S}_{RL} \\ \mathbf{S}_{LR} & \mathbf{S}_{LL} \end{bmatrix} \\ &= e^{j\varphi} \left\{ e^{j\varphi_S} k_S \begin{bmatrix} 0 & j \\ j & 0 \end{bmatrix} + k_D \begin{bmatrix} e^{j2\theta} & j \\ j & -e^{-j2\theta} \end{bmatrix} + k_H \begin{bmatrix} e^{j2\theta} & 0 \\ 0 & 0 \end{bmatrix} \right\} \quad (2-36) \end{aligned}$$

其中，Krogager 的参数可以表示为：

$$\begin{aligned} k_S &= |\mathbf{S}_{RL}|, & \varphi = \frac{1}{2} (\varphi_{RR} + \varphi_{LL} - \pi) \\ \theta &= \frac{1}{4} (\varphi_{RR} - \varphi_{LL} + \pi), & \varphi_S = \varphi_{RL} - \frac{1}{2} (\varphi_{RR} + \varphi_{LL}) \end{aligned} \quad (2-37)$$

从公式(2-37)可以看出，目标的左右旋散射特性可以由  $\mathbf{S}_{RR}$  和  $\mathbf{S}_{LL}$  确定。当目标为左螺旋体时：

$$|\mathbf{S}_{RR}| \geq |\mathbf{S}_{LL}| \Rightarrow \begin{cases} k_D^+ = |\mathbf{S}_{LL}| \\ k_H^+ = |\mathbf{S}_{RR}| - |\mathbf{S}_{LL}| \end{cases} \quad (2-38)$$

类似地，当目标为右螺旋体时：

$$|\mathbf{S}_{RR}| \leq |\mathbf{S}_{LL}| \Rightarrow \begin{cases} k_D = |\mathbf{S}_{RR}| \\ k_H = |\mathbf{S}_{LL}| - |\mathbf{S}_{RR}| \end{cases} \quad (2-39)$$

Krogager 分解每个分量的物理解释如表2-2所示。

表 2-2 Krogager 分解

Krogager 基	散射类型	物理描述
$\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$	球面散射	球体、平坦平面或三面角反射器
$\begin{bmatrix} \cos 2\theta & \sin 2\theta \\ \sin 2\theta & -\cos 2\theta \end{bmatrix}$	二面角散射	二面角反射器
$\begin{bmatrix} 1 & \pm j \\ \pm j & -1 \end{bmatrix}$	螺旋体散射	不对称结构

## 2.4.2 极化非相干分解

对于“非确定性”的非相干目标，具有动态的散射特性，因此需要使用统计的方法来对其目标散射特性进行研究，通常是使用二阶统计量的方法展开。非相干分解主要是将极化协方差矩阵  $\mathbf{C}$  或者极化相干矩阵  $\mathbf{T}$  进行分解，使用多个典型的散射模型之和的形式表示。

$$\mathbf{C} = \sum_{k=1}^N p_k \mathbf{C}_k \quad (2-40)$$

$$\mathbf{T} = \sum_{k=1}^N q_k \mathbf{T}_k \quad (2-41)$$

其中， $p_k$  和  $q_k$  均表示每个散射模型分量的权重系数。

经典的非相干分解方法包括 Cloude 分解<sup>[20]</sup>、Freeman 分解<sup>[21]</sup>、Huynen 分解<sup>[51]</sup>、Yamaguchi 分解<sup>[52]</sup>、Holm 分解<sup>[22]</sup> 和 van Zyl 分解<sup>[53]</sup> 等。下面将介绍 Cloude 分解和 Freeman 分解的原理。

### 2.4.2.1 Cloude 分解

Cloude 分解是一种矩阵特征空间分解方法，是对极化相干矩阵  $\mathbf{T}$  进行特征分解，得到三组特征值与对应的特征向量。具体如下式所示：

$$\mathbf{T} = \mathbf{U}\Lambda\mathbf{U}^H = \mathbf{U} \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_3 \end{bmatrix} \mathbf{U}^H \quad (2-42)$$

其中， $\Lambda$  表示矩阵  $\mathbf{T}$  的三个特征值组成的对角矩阵，并且满足  $\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq 0$ ， $\mathbf{U}$  表示三个特征值对应的特征向量构成的矩阵， $H$  表示取复共轭转置。

由以上的特征值与特征向量，Cloude 分解定义了平均散射角  $\bar{\alpha}$ 、极化熵  $H$  以及极化反熵  $A$  这三个用于描述目标统计的散射机制的量，具体如下表示：

$$\bar{\alpha} = \sum_{i=1}^3 P_i \alpha_i \quad (2-43)$$

$$H = \sum_{i=1}^3 P_i \log_3 P_i \quad (2-44)$$

$$A = \frac{\lambda_2 - \lambda_3}{\lambda_2 + \lambda_3} \quad (2-45)$$

其中， $\alpha_i$  表示从特征值  $\lambda_i$  中得到的散射角， $P_i = \frac{\lambda_i}{\sum_j \lambda_j}$ 。

从 Cloude 分解的三个散射分类计算式可以看出，平均散射角  $\bar{\alpha}$  描述了散射角从  $0^\circ$  到  $90^\circ$  变化过程中，散射特性从单次散射到二面角散射的连续变化的过程；极化熵  $H$  描述了目标散射特性的随机性，当  $H = 1$  时，目标是一个随机噪声，当  $H = 0$  时，目标的散射特性唯一，相当于一个相干目标；极化反熵  $A$  是对极化熵的补充量，通常用来作为极化熵难以区分目标的指标量。

Cloude 分解每个分量的物理解释如表2-3所示。

表 2-3 Cloude 分解

Cloude 参数	参数表达	物理描述
Entropy	$H = \sum_{i=1}^3 P_i \log_3 P_i$	散射目标由各向性散射至完全随机散射的随机性
Mean Alpha Angle	$\bar{\alpha} = \sum_{i=1}^3 P_i \alpha_i$	由表面散射至二面角散射的平均随机性
Anisotropy	$A = \frac{\lambda_2 - \lambda_3}{\lambda_2 + \lambda_3}$	主散射体之外的两个较弱散射分量的强弱关系

### 2.4.2.2 Freeman 分解

Freeman 和 Durden 基于 van Zyl 的目标分解工作，进一步提出了一种非相干的三分量分解方法，将极化协方差矩阵  $\mathbf{C}$  使用单次散射、偶次散射和体散射三种散

射机制的加权和表示。具体表示如下：

$$\mathbf{C} = f_s \mathbf{C}_s + f_d \mathbf{C}_d + f_v \mathbf{C}_v \quad (2-46)$$

其中，

$$\mathbf{C}_s = \begin{bmatrix} |\beta|^2 & 0 & \beta \\ 0 & 0 & 0 \\ \beta^* & 0 & 1 \end{bmatrix}, \quad \mathbf{C}_d = \begin{bmatrix} |\alpha|^2 & 0 & \alpha \\ 0 & 0 & 0 \\ \alpha^* & 0 & 1 \end{bmatrix}, \quad \mathbf{C}_v = \begin{bmatrix} 1 & 0 & 1/3 \\ 0 & 2/3 & 0 \\ 1/3 & 0 & 1 \end{bmatrix} \quad (2-47)$$

其中  $\beta$  表示单次散射参数， $\alpha$  表示偶次散射参数； $\mathbf{C}_s$ 、 $\mathbf{C}_d$ 、 $\mathbf{C}_v$  分别表示单次散射模型、偶次散射模型和体散射模型的协方差矩阵分量； $f_s$ 、 $f_d$ 、 $f_v$  表示三种散射模型对应的分解系数。

Freeman 分解每个分量的物理解释如表2-4所示。

表 2-4 Freeman 分解

Freeman 基	散射类型	典型散射体
$\begin{bmatrix}  \beta ^2 & 0 & \beta \\ 0 & 0 & 0 \\ \beta^* & 0 & 1 \end{bmatrix}$	单次散射	一阶 Bragg 表面散射体
$\begin{bmatrix}  \alpha ^2 & 0 & \alpha \\ 0 & 0 & 0 \\ \alpha^* & 0 & 1 \end{bmatrix}$	偶次散射	二面角散射器
$\begin{bmatrix} 1 & 0 & \frac{1}{3} \\ 0 & \frac{2}{3} & 0 \\ \frac{1}{3} & 0 & 1 \end{bmatrix}$	体散射	植被冠状层偶极子

## 2.5 本章小结

本章详细介绍了极化电磁波和极化散射数据的理论基础。首先，阐述了电磁波极化的三种描述方法：极化椭圆、用于描述完全极化波的琼斯矢量，以及用于描述部分极化波的 Stokes 矢量。其次，介绍了用于描述目标散射特征的方法，包括极化散射矩阵以及二阶统计矩阵。然后，详尽阐述了多种极化目标分解方法的基本原理，并总结归纳了各种目标分解参数的物理含义。本章旨在为后续章节中极化 SAR 图像目标分类方法研究提供理论支撑。

## 第三章 基于双通道注意力的极化 SAR 目标分类

### 3.1 引言

极化 SAR 通过以不同的极化方式发射和接收电磁波信号，从而实现对地物目标探测，并提供丰富的后向散射信息。通过使用四种极化方式（HH、HV、VH、VV）进行探测，可以获得包含目标散射特性的散射矩阵。使用具有不同物理含义的散射基进行进一步解析，可以获取代表目标不同散射意义的目标分解特征。不同的极化特征从不同的角度描述地物目标的散射特性。挖掘极化 SAR 数据中的有效极化信息一直是遥感探测领域的难点与重点之一。通过采用适合于极化 SAR 数据特性的特征提取技术，可以使极化特征具有良好的类内相聚、类间远离的可分性，从而提升系统对目标特性的感知能力，成为极化 SAR 图像解译研究中的关键步骤之一。

根据文献 [5–7]，没有一个单一特征能在所有分类中均取得完美的表现，每个方法提取的特征具有其长处以及特征见具有互补性。而目前在极化 SAR 目标分类研究中，主要存在以下问题：首先，现有的部分极化 SAR 分类方法直接采用相干矩阵作为输入，却忽略了目标分解特征的表示方式<sup>[35,54]</sup> 提供的目标物理散射信息。其次，同一目标具有的多个极化特征也意味着存在较强的相关和冗余，且固定的极化特征表示方式无法应用在多元的目标分类场景中，导致目标分类性能受到限制<sup>[55]</sup>。

针对上述问题，本章提出了一种基于双通道注意力的极化 SAR 目标分类方法。该方法以注意力机制为基础，通过利用极化散射特征与极化目标分解特征之间的差异性与互补性，构建了两种类型特征之间的融合表征关系，从而增强了极化信息的表征性能，并提高了分类任务的准确率。实验部分通过两组实测极化 SAR 数据验证本方法的有效性与优越性。

### 3.2 注意力机制介绍

注意力机制是机器学习和深度学习中一种关键的技术，其主要目标是在处理信息时实现对输入数据的加权关注，以便网络模型能够更有效地捕捉与任务相关的信息。基于注意力机制的信息提取在自然语言处理、计算机视觉等领域获得了广泛的应用<sup>[56,57]</sup>。注意力机制使用不同的权重来表示输入特征的不同的重要程度，根据关注的角度差异，可以分为通道注意力、空间注意力和混合注意力三种类型。

### 3.2.1 通道注意力机制

输入深度网络的特征一般使用多维数据表示，通道注意力专注于挖掘不同通道间的关键信息，通过自适应地调整通道之间的权重，使网络模型能够更加聚焦于对后续任务有益的特征通道，从而提升模型的性能和泛化能力。压缩和激励网络（Squeeze-and-Extraction Networks, SENet）<sup>[56]</sup>是最具代表性的通道注意力实现模型。图3-1为 SENet 的组成结构图，该方法由压缩和激励两个阶段构成。在压缩阶段，通过全局池化操作对输入多维特征进行压缩，将每个通道的信息整合成单一的数值，用于全局感受野的建模。对于维数是  $H \times W \times C$  的输入特征  $\mathbf{u}_c$ ，压缩操作  $\mathbf{F}_{sq}$  将其压缩为  $1 \times 1 \times C$  维，具体如下式所示：

$$\mathbf{z} = \mathbf{F}_{sq}(\mathbf{u}_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u(i,j) \quad (3-1)$$

其中， $\mathbf{z}$  表示具有全局感受野的通道特征图。

在激励阶段，利用全连接层和激活函数，学习得到每个通道的权重。得到的权重向量用来对原始输入特征图中的每个通道进行加权，形成加权的特征图。具体如下式所示：

$$\mathbf{s}_c = \mathbf{F}_{ex}(\mathbf{z}, \mathbf{W}) = \sigma(g(\mathbf{z}, \mathbf{W})) = \sigma(\mathbf{W}_2 \sigma * (\mathbf{W}_1 \mathbf{z})) \quad (3-2)$$

其中， $\sigma$  表示 ReLu 激活函数<sup>[58]</sup>， $\mathbf{W}_1 \in \mathbb{R}^{\frac{C}{r} \times C}$  且  $\mathbf{W}_2 \in \mathbb{R}^{C \times \frac{C}{r}}$ 。

模型最终通过权重向量  $\mathbf{s}_c$  来对输入进行重标定得到：

$$\tilde{\mathbf{x}}_c = F_{scale}(\mathbf{u}_c, \mathbf{s}_c) = \mathbf{s}_c \mathbf{u}_c \quad (3-3)$$

其中， $\tilde{\mathbf{X}} = [\tilde{\mathbf{x}}_1, \tilde{\mathbf{x}}_2, \dots, \tilde{\mathbf{x}}_C]$ ， $F_{scale}(\mathbf{u}_c, \mathbf{s}_c)$  表示  $s_c$  与特征图  $\mathbf{u}_c \in \mathbb{R}^{H \times W}$  的通道级乘积。

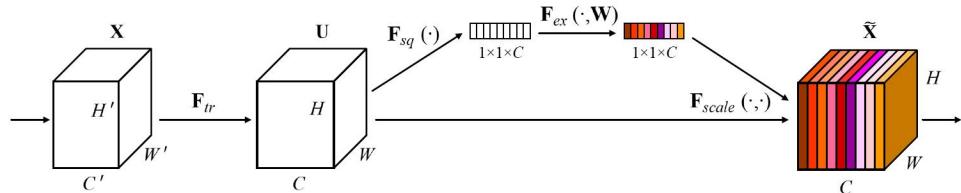


图 3-1 SENet 结构图<sup>[56]</sup>

### 3.2.2 空间注意力机制

空间注意力机制是深度学习处理图像和空间数据中的注意力机制方法。其主要目的是通过对输入数据的不同空间位置引入不同的权重，赋予模型具备灵活关注对下游任务重要的区域的能力，提升模型对空间结构的感知能力。空间注意力模块（Spatial Attention Module, SAM）<sup>[59]</sup> 是一个经典的运用空间注意力机制的方法。如图3-2所示，SAM 的主要思想是首先利用最大池化层和平均池化层获得两个全局的特征图，然后通过拼接操作将两个特征图进行拼合，再利用一个  $7 \times 7$  的卷积核将拼合的特征图转化成单通道的特征，最后使用 sigmoid 激活函数<sup>[60]</sup> 得到空间注意力权值，并与原始输入进行相乘得到最终大小与输入相同的输出。空间注意力的计算公式如下式所示：

$$\begin{aligned} M_s(\mathbf{F}) &= \sigma(f^{7 \times 7}([AvgPool(\mathbf{F}); MaxPool(\mathbf{F})])) \\ &= \sigma(f^{7 \times 7}(\mathbf{F}_{avg}; \mathbf{F}_{max})) \end{aligned} \quad (3-4)$$

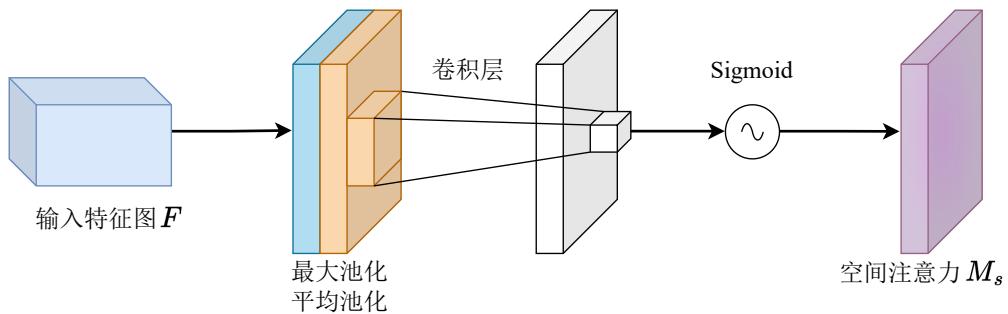


图 3-2 SAM 结构图<sup>[59]</sup>

### 3.2.3 混合注意力机制

混合注意力机制是综合多个注意力模块来处理数据的方法，通过对多个不同类型的注意力机制的融合，来增强深度网络模型对输入数据的建模能力，以更加灵活、全面地捕获输入数据的关键信息。卷积块注意力模块（Convolutional Block Attention Module, CBAM）<sup>[59]</sup> 是一个综合了通道和空间注意力机制的经典混合注意力方法。如图3-3所示，CBAM 的主要网络架构有串联的通道注意力模块和空间注意力模块构成。通过依次使用通道和空间注意力模块，分别在通道和空间维度学习数据的关键信息，增强模型对输入数据的感知能力。其中，上一小节已经介

绍了空间注意力模块的计算流程，而通道注意力机制的计算公式可以表示如下：

$$\begin{aligned} \mathbf{M}_c(\mathbf{F}) &= \sigma(MLP(AvgPool(\mathbf{F})) + MLP(MaxPool(\mathbf{F}))) \\ &= \sigma\left(\mathbf{W}_1\left(\mathbf{W}_0\left(\mathbf{F}_{avg}^c\right)\right) + \mathbf{W}_1\left(\mathbf{W}_0\left(\mathbf{F}_{max}^c\right)\right)\right) \end{aligned} \quad (3-5)$$

其中， $\sigma$  表示 sigmoid 函数， $MLP$  表示多层感知机， $\mathbf{W}_0 \in \mathbb{R}^{C/r \times C}$ 、 $\mathbf{W}_1 \in \mathbb{R}^{C \times C/r}$  均是多层感知机的权重参数。

因此，CBAM 的计算流程可以表示为：

$$\mathbf{F}' = \mathbf{M}_c(\mathbf{F}) \otimes \mathbf{F} \quad (3-6)$$

$$\mathbf{F}'' = \mathbf{M}_s(\mathbf{F}') \otimes \mathbf{F}' \quad (3-7)$$

其中， $\otimes$  表示逐元素乘法。

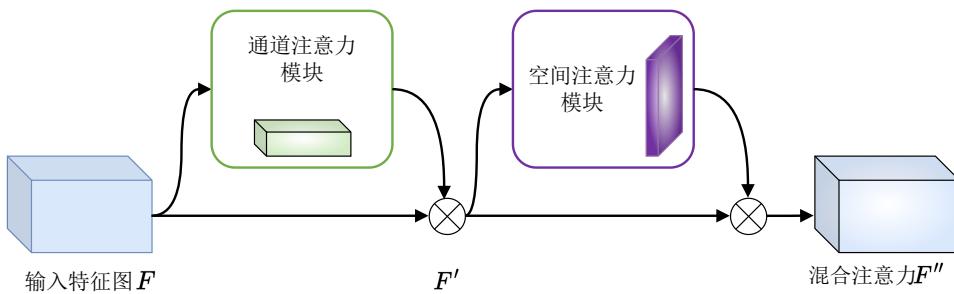


图 3-3 CBAM 结构图 [59]

### 3.3 双通道注意力的极化 SAR 目标分类

注意力机制方法已广泛应用于图像处理领域，尤其在计算机视觉和深度学习任务中。这些方法通过在网络结构中引入注意力机制，对图像中特定区域进行加权关注，使模型能够更加关注关键的信息，从而提升分类性能。区别于光学图像，极化 SAR 图像具有独特的数据特征，包括复杂的多通道信息和多维度的散射机制，直接将通用的注意力机制方法应用于极化 SAR 图像处理任务中无法取得理想的效果。本章充分考虑了极化 SAR 图像数据特点，基于后向散射信息与目标分解信息的差异性与互补性，提出了专适用于极化 SAR 图像的目标分类方法，即基于双通道注意力的极化 SAR 目标分类方法。该方法充分挖掘两类极化特征的差异信息与互补信息，以提供更加全面、充分的极化信息表示方式，从而提升分类准确率。

### 3.3.1 目标分类方法框架

如图3-4所示，展示了基于双通道注意力的极化 SAR 目标分类算法示意图。该方法构建了端到端的极化特征校准与分类网络结构，以挖掘多类型极化特征中的隐藏信息为目的，实现两类型极化特征的信息提取与有效融合，增强极化特征的可表征性能。

该方法主要分为极化特征校准模块与分类器模块，分别用于多类型极化特征细化以及目标分类任务。其主要思路是：首先，为了充分挖掘两类不同类型极化特征的有效信息，设计双通道网络结构，在两个独立的通道中依次利用注意力方法增强有效信息而抑制无关冗余信息。其次，利用极化注意力调整模块，基于两类型特征的互补特性，对空间和通道注意力图进行联合动态修正，充分挖掘两类极化特征之间的互补信息。之后，考虑到极化 SAR 图像具有较大的空间尺寸，设计多尺度学习方法，旨在聚合不同尺寸的极化特征。最后，将重新调整的极化特征进行拼接，形成注意力增强的极化特征输入到分类器网络，得到目标分类结果。值得注意的是，该方法中的极化特征校准模块可以作为一个即插即用的插件式模块，应用到其他下游的目标检测、分类识别任务中。

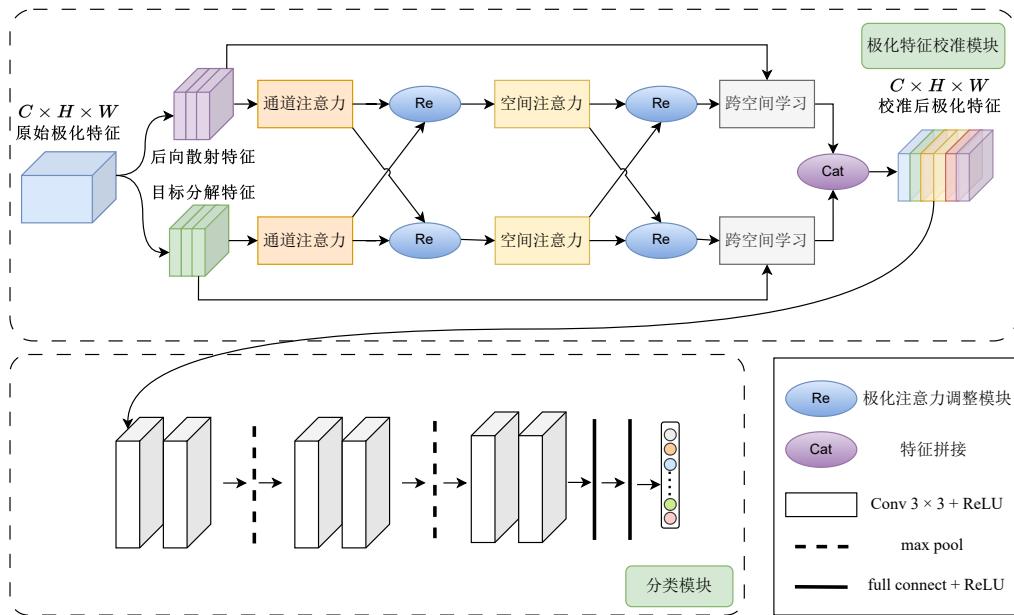


图 3-4 基于双通道注意力的极化 SAR 分类方法示意图

极化特征校准模块输入结构呈现两个独立通道形式，分别输入具有目标完备后向散射信息的极化相干矩阵和具有不同物理散射特性的极化目标分解特征。两路分支输入特征如下所示：

(1) 通道 1：后向散射特征

根据公式(2-26), 极化相干矩阵  $T$  非主对角线元素均是复数, 而主对角线元素均是实数, 并且关于主对角线共轭对称。因此, 可以使用矩阵的上三角 6 个元素代表极化相干矩阵, 考虑到复数性质, 使用一个包含 9 个元素的一维数组表示极化相干矩阵, 具体如下式所示:

$$\mathbf{V} = [T_{11}, T_{22}, T_{33}, \operatorname{Re}(T_{12}), \operatorname{Re}(T_{13}), \operatorname{Re}(T_{23}), \operatorname{Im}(T_{12}), \operatorname{Im}(T_{13}), \operatorname{Im}(T_{23})] \quad (3-8)$$

其中,  $\operatorname{Re}$  与  $\operatorname{Im}$  分别表示取实部与取虚部运算。 $\mathbf{V}$  包含了地物目标完备的后向散射信息, 将  $\mathbf{V}$  作为通道 1 的输入。

## (2) 通道 2: 目标分解特征

不同的极化目标分解特征从不同的物理层面反映了目标的散射特性, 通道 2 选择多种经典的极化目标分解特征作为输入, 分别为 Pauli 分解、Cloude 分解、Freeman 分解、Krogager 分解、Huynen 分解共计 32 维目标分解参数。具体特征参数如表3-1所示。

表 3-1 通道 2 使用的极化目标分解特征参数表

分解方法	特征参数	物理意义	特征维数
Pauli	$ a ^2,  b ^2,  c ^2$	奇次、偶次、二面角散射	3
Cloude	$H, \alpha, A$	散射熵、平均散射角、反熵	3
	$\lambda_1, \lambda_2, \lambda_3$	极化相干矩阵特征值	3
Freeman	$P_s, P_d, P_v, P_r$ $f_s, f_d, f_v$	表面散射、体散射、二次散射、同极化比 Freeman 系数	4
Krogager	$ k_s ^2,  k_d ^2,  k_h ^2$ $A_0, B_0 + B, B_0 - B$	球、双平面、螺旋散射能量 对称、非对称、不规则性信息	4
Huynen	$C, D, E$ $F, G, H$	线性、弯曲、扭转性信息 螺旋、沾合、方向信息	3
Van Zyl	$f_v, f_d, f_s$	体散射、二次散射、表面散射系数	3

为了高效的提取单独通道内的有效极化信息, 使用空间和通道注意力方法对输入的极化特征进行细化, 以激发有效的重要信息而抑制无关的冗余信息, 以加权的方式对输入极化特征进行校准。空间与通道注意力模块的具体网络结构及计算流程将在3.3.2小节中介绍。

为了有效融合两类极化特征, 挖掘双通道内不同特征的互补信息, 设计了极化注意力修正模块, 以极化信息一致性为引导, 通过残差连接的形式, 实现由一类极化信息到另一类极化信息的融合修正。极化注意力修正模块的具体网络结构及计算流程在3.3.3小节中介绍。

鉴于极化 SAR 目标具有空间尺寸差异大的特点, 为了聚合不同尺寸的极化特

征，设计了多尺度学习模块，以不同卷积核大小分的卷积层提取不同尺寸的空间信息，结合全局平均池化以及非线性函数映射操作，实现多尺度的极化特征学习。多尺度学习模块的具体网络结构及计算流程在3.3.4小节中介绍。

最后，通过特征拼接，将校准后的两类型极化特征进行聚合后作为分类器模块输入，完成目标分类。

综合以上算法描述，图3-5对本章算法结合分类器进行目标分类的整体流程进行总结。

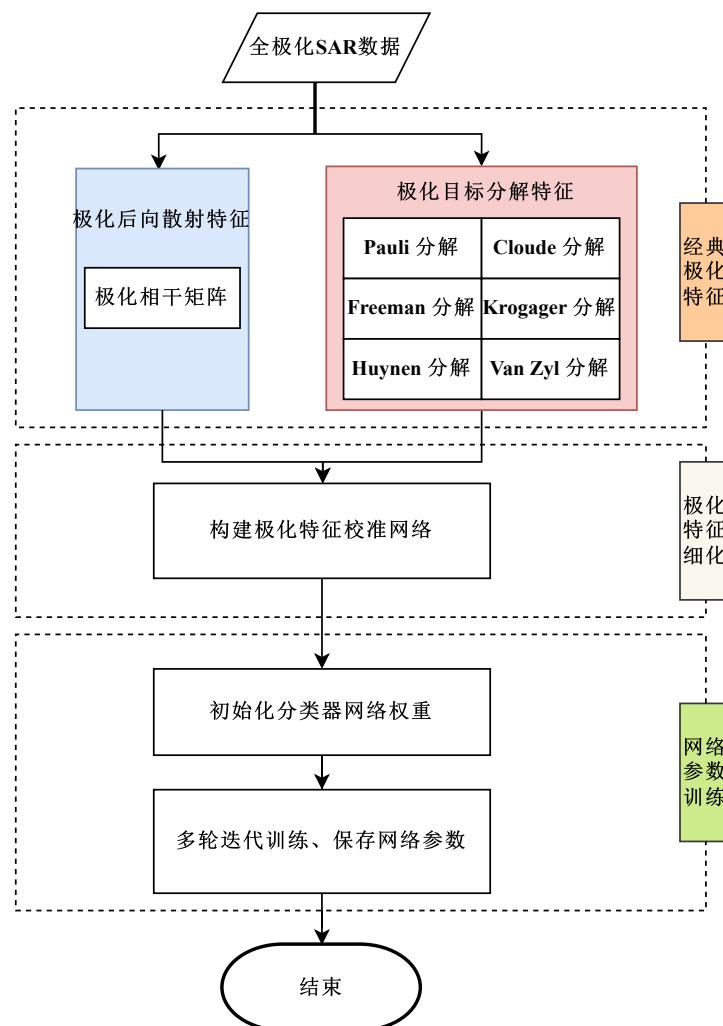


图 3-5 双通道注意力极化 SAR 目标分类算法流程图

### 3.3.2 空间和通道注意力模块

注意力方法通过强调或抑制输入特征中的不同部分，在深度学习领域，被广泛应用到各种任务中。本文通过引入空间和通道注意力方法，旨在对输入的极化

信息动态调整关注度，提升模型对关键信息的感知能力。图3-6为本方法中的空间注意力模块网络结构。空间注意力方法采用卷积操作来获取全局信息，从而赋予其更多的非线性捕捉能力，更好的拟合不同空间位置之间的复杂相关性，显著减少参数量和计算量。计算公式如下所示：

$$\mathbf{A}_s = \sigma(f^{7 \times 7}(\text{AvgPool}(\mathbf{S}); \Gamma(\text{MaxPool}(\mathbf{S})))) \quad (3-9)$$

其中， $f^{7 \times 7}$  表示卷积核大小为  $7 \times 7$  的卷积操作； $\sigma$  表示 Sigmoid 激活函数。空间注意力通过最大池化和平均池化两个池化操作得到大小为  $2 \times H \times W$  的特征图，最大池化从图像中提取强的局部信息，平均池化提取全局平均统计特征。对特征图采用卷积运算，转换为  $1 \times H \times W$  的单一通道特征，再利用 Sigmoid 激活函数将通道特征图转为对应的空间注意力图  $A_s$ ，最后计算注意力图  $A_s$  与原始输入特征的乘积得到空间注意力信息。计算公式如下：

$$\mathbf{S}_s = \mathbf{A}_s \otimes \mathbf{S} \quad (3-10)$$

其中， $\otimes$  表示逐元素乘积。通过空间注意力方法，在空间维度进行有效信息激发而抑制无效信息，得到空间注意力图校准的极化特征  $S_s$ 。

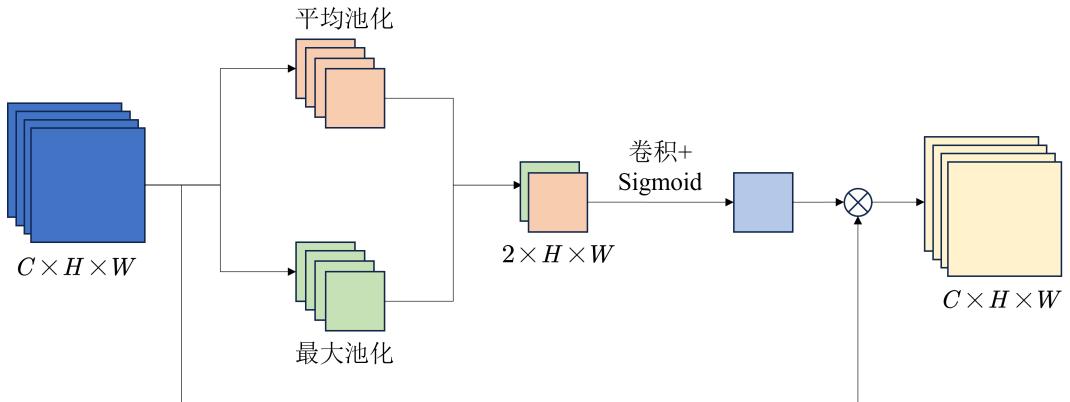


图 3-6 空间注意力模块结构

相比于空间注意力方法使用卷积层层与激活函数的注意力提取方法，通道注意力方法通过全连接和加和操作，完成对通道维度信息的提取。全局最大池化与平均池化操作对输入特征图的空间依赖性进行拆解，并通过逐个学习每个通道生成反映各个通道重要性的特征图。随后，将得到的两个  $C \times 1 \times 1$  的特征图进行拼接后使用全连接和加和运算后，再使用 Sigmoid 激活函数，形成一维的通道注意力图，用于表示不同通道特征图的重要性。计算如下式所示：

$$\mathbf{A}_c = \sigma(\Gamma(\text{AvgPool}(\mathbf{S})) + \Gamma(\text{MaxPool}(\mathbf{S}))) \quad (3-11)$$

其中， $\sigma$  表示 Sigmoid 激活函数； $\Gamma$  表示两层神经网络。将通道注意力图与输入极化特征相乘，得到通道注意力图校准的极化特征。计算公式如下：

$$\mathbf{S}_C = \mathbf{A}_C \otimes \mathbf{S} \quad (3-12)$$

其中， $\otimes$  表示逐元素乘法。

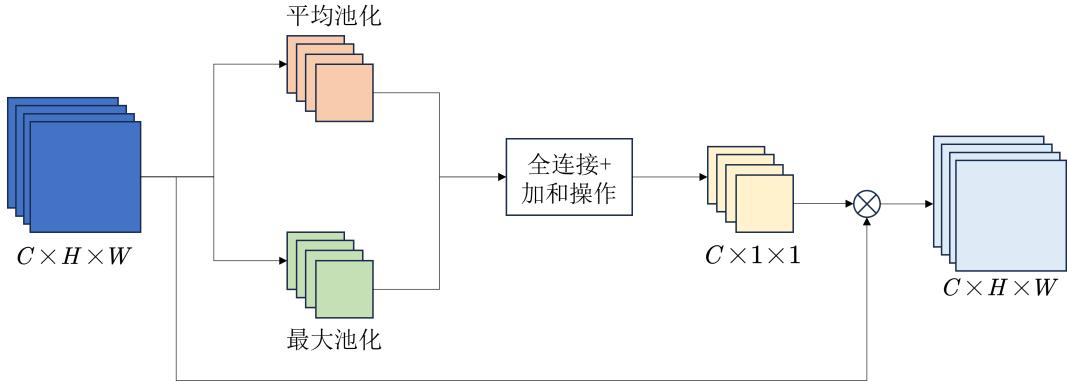


图 3-7 通道注意力模块结构

### 3.3.3 极化注意力修正模块

基于双通道注意力架构对极化 SAR 输入特征提取空间、通道注意力特征图，对于同一类型目标，校准后的两种类型极化信息存在一致性与互补性。为了保持特征一致性和挖掘极化互补信息，图3-8展示的极化注意力修正模块，以极化信息一致性为引导，对输入的极化特征进行动态调整，增强特征一致性。极化注意力修正模块利用极化特征估计特征映射的位置相关关系，自适应地控制两类注意力图的空间位置信息。以双通道的注意力图  $\mathbf{S}_1 \in R^{H \times W}$  与  $\mathbf{S}_2 \in R^{H \times W}$  为输入，该模块的计算流程可以表示为：

$$\mathbf{S}'_2 = f^{1 \times 1}(\mathbf{S}_2) \quad (3-13)$$

$$\mathbf{S}'_1 = \text{Ref}(\mathbf{S}'_2, \phi(\mathbf{S}_1)) \quad (3-14)$$

$$\mathbf{S}_{out} = \mathbf{S}'_1 + \mathbf{S}_1 \quad (3-15)$$

其中， $\mathbf{S}_{out}$  表示模块最终输出，运算  $\phi(\cdot)$  表示在特征  $\mathbf{S}_1$  引导下估计  $\mathbf{S}_2$  的位置相关矩阵，描述了两路特征的空间对应关系， $\text{Ref}(\cdot)$  表示根据位置相关矩阵调整  $\mathbf{S}_2$ ，运算  $\phi(\cdot)$  采用类似 softmax 运算操作计算归一化相关矩阵值，具体可以表示为：

$$\Phi_i(j) = \frac{\exp\left(\theta(S_i)^T \cdot \varphi(S_j)\right)}{\sum_j \exp\left(\theta(S_i)^T \cdot \varphi(S_j)\right)} \quad (3-16)$$

其中,  $i$  是指相关矩阵中某个位置的索引,  $j$  是枚举所有位置的索引。 $\Phi_i(j)$  描述了空间位置  $i$  与位置  $j$  之间的对应关系。 $\theta(\cdot)$  与  $\varphi(\cdot)$  均使用卷积核大小为  $1 \times 1$  的卷积层实现。

对于输入注意力特征图位置索引  $i$  处的特征单元, 以对应位置的相关元素  $\Phi_i$  为引导, 修正过程可以表示为:

$$\mathbf{S}'_{1i} = \sum_j \Phi_i(j) \cdot \mathbf{S}'_2(j) \quad (3-17)$$

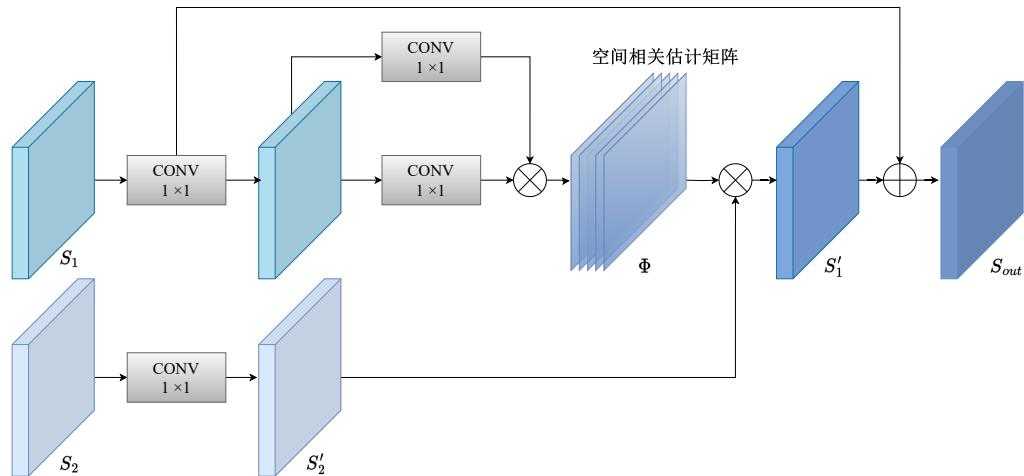


图 3-8 极化注意力修正模块网络结构示意图

### 3.3.4 多尺度学习模块

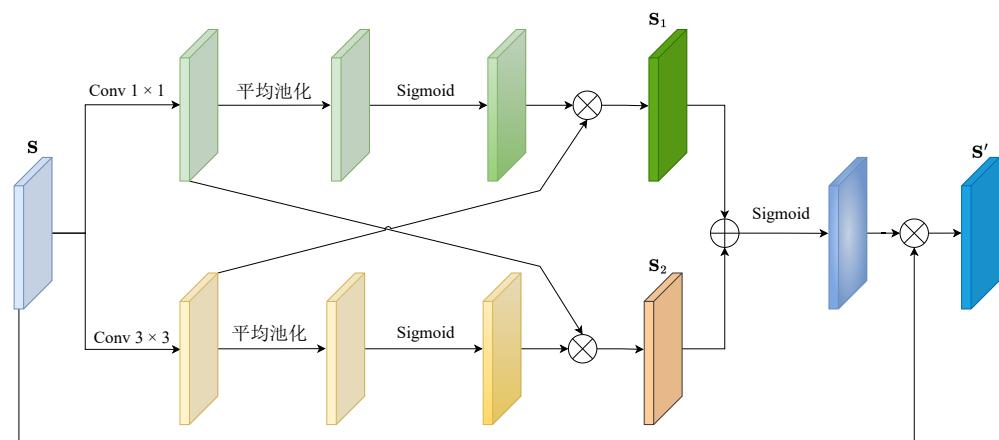


图 3-9 多尺度学习模块网络结构示意图

多尺度学习模块的网络结构如图3-9所示, 提供了一种不同空间维度方向的极化信息聚合方法, 以实现多尺度下的极化特征聚合。引入两个分支的张量, 分别

代表了  $1 \times 1$  分支的输出和  $3 \times 3$  分支的输出。通过二维全局平均池化对  $1 \times 1$  分支的输出进行操作，以编码其中的全局极化空间信息，用于对全局信息进行编码和建模远程依赖关系。二维全局池化操作可以表达为：

$$z_c = \frac{1}{H \times W} \sum_j^H \sum_i^W x_c(i, j) \quad (3-18)$$

$1 \times 1$  分支特征图在进行二维全局平均池化后，采用自然非线性函数 Softmax 进行二维高斯映射，以拟合线性变换并提升计算效率。通过将上述并行处理的输出进行矩阵点积运算，并与结果相乘，得到了第一个空间注意力图。类似地，利用二维全局平均池化对  $3 \times 3$  分支进行全局空间信息的编码。这会生成每组内输出特征的两个空间权重值的集合，随后使用 Sigmoid 函数将其映射为相应空间位置的权重关系，突出显示所有像素的全局上下文信息。计算公式如下：

在以上二维全局平均池化的输出处采用二维高斯映射的自然非线性函数 Softmax 来拟合线性变换，进而提升计算效率。通过将上述并行处理的输出与矩阵点积运算相乘，得出了第一个空间注意力图。同样利用二维全局平均池化在  $3 \times 3$  分支编码全局空间信息，将每组内的输出特征映射计算为生成的两个空间权重值的集合，然后使用 Sigmoid 函数映射成空间位置对应的权重关系。通过捕获像素级的成对关系，突出显示所有像素的全局上下文信息。计算公式如下：

$$\mathbf{S}_1 = f^{4 \times 1}(\mathbf{S}) \times \text{AvgPool}(f^{3 \times 3}(\mathbf{S})) \quad (3-19)$$

$$\mathbf{S}_2 = f^{3 \times 3}(\mathbf{S}) \times \text{AvgPool}(f^{4 \times 1}(\mathbf{S})) \quad (3-20)$$

$$\mathbf{S}' = \sigma(\mathbf{S}_1 + \mathbf{S}_2) \quad (3-21)$$

其中， $\sigma$  表示 sigmoid 函数。

### 3.3.5 目标分类模块

在双通道注意力极化信息提取器（Dual Attention Polarization Information Extractor, DP）的基础上，构建端到端的极化 SAR 信息提取与目标分类网络（DP Convolutional Neural Network, DP-CNN）。从输入的高维原始极化特征出发，利用 DP 模块可以获得全局信息并且嵌入到分类器中。原始极化特征中有价值的信息被激发，而没有价值的信息被抑制。当具备了重新校正的极化特征之后，输入到目标分类器模块，通过卷积网络结构，实现对输入特征的分类。校准后的极化特征输入到图3-4展示的分类模块中。分类器采用类似 VGG 结构的卷积神经网络架构，其中包含三个带有 ReLU 激活函数的  $3 \times 3$  卷积层、两层最大池化函数、两层全连接网络以及一层 SoftMax 激活层。

以交叉熵损失函数<sup>[61]</sup>为目标，通过反向传播算法训练模型参数。DP-CNN 方法将输入的原始极化特征  $x$  映射为预测概率  $p \in \mathbb{R}^C$ ，其中， $C$  表示类别的个数。 $x$  对应的中心像素预测标签可以通过选择概率最高的类别，即向量  $p$  的最大值索引来预测。其计算公式如下：

$$L = -\sum_{i=1}^n p(x_i) \log(q(x_i)) \quad (3-22)$$

其中， $p(x)$  表示真实值分布概率， $q(x)$  表示模型预测分布概率。交叉熵值的变化与模型的训练效果密切相关，优越的训练效果会让预测概率分布逐渐趋近于真实值概率分布，相应的交叉熵值会逐渐减少。

整个模型的损失计算流程可以表示为：

- (1) 神经网络分类器最后一层输出每个样本类别的属性值向量；
- (2) 利用 Softmax 函数将属性值向量映射为样本属于每一类的预测概率向量；
- (3) 地面真值标签的 one hot 编码与样本预测概率向量进行交叉熵损失函数运算，并依据损失值进行反向传播优化。

## 3.4 实验结果与分析

本节将详细阐述验证实验所依托的软件件设施配置以及关键的超参数设置。在此基础上，对验证实验所使用的极化 SAR 数据集进行简要介绍，并对本章所提出的双通道注意力目标分类方法进行性能评估。

### 3.4.1 实验参数设置

本章实验所使用的计算环境为一台 CPU 为 Intel Core i7-8700K 和配备了 NVIDIA GPU (GeForce RTX 3090, 24G) 的计算机设备。操作系统采用 Ubuntu 20.04 LTS。深度学习框架选择 PyTorch，版本为 1.9.0，同时依赖 CUDA 深度神经网络库 (cuDNN) 版本 8.0.5。在科学计算方面，实验使用 NumPy 库，版本为 1.19.5。

学习率作为深度学习模型训练的关键参数之一，其值的选择对于模型的收敛速度至关重要。在训练过程中，如果学习率设置的过大或者过小，均会可能给模型的分类准确度产生负面影响。通常情况下，在模型的训练初始阶段，采用较大的学习率能够使模型快速收敛到最优点附近。随着训练的执行，逐渐减小学习率，以更加精确地接近最优点。在本章所采用的模型中，初始学习率为  $3 \times 10^{-4}$ ，在训练至第 30 至 60 个 epoch 期间，学习率经过衰减变为原值的 0.1 倍。这里的 epoch 表示训练集中素有样本完成一次正向传递和反向传播的过程，本章中模型训练的 epoch 设置为 100。Batch size 表示每次训练中选择的样本数量，其值的大小会影响

网络的优化速度和执行效率。在本章模型中，batch size 被设置为 64。实验中，使用大小为  $15 \times 15$ ，步长为 1 的滑动窗口对输入图像进行随机截取，选取出 1% 的中心带标签样本作为训练集，而其余的样本作为测试集。

为了对本章提出的极化信息提取方法进行全面地评估和对比，从两个对比维度选择了多种替代方案进行比较：一是对特征输入的改变，二是对极化特征校准模块的替换。首先，验证了不同极化特征表示对目标分类任务的影响。对比方法包括仅使用极化相干矩阵中的元素结合 CNN 分类方法（记为 CNN-T）、仅使用极化目标分解特征结合 CNN 分类方法（记为 CNN-P）、以及基于散射特征和分解特征简单叠加结合 CNN 的分类方法（记为 CNN-F）。这旨在验证本章方法在极化特征表示方面的有效性。其次，对极化特征校准模块进行替换。利用基于压缩和激励网络结合 CNN 分类方法（记为 CNN-SE）和基于空间通道注意力结合 CNN 分类方法（记为 CNN-CBAM）作为不同的对比方法。这旨在验证本章方法在极化特征表示方面的有效性。

最后，还与目前广泛应用的极化 SAR 图像目标分类方法进行对比，来验证所提出算法的优越性，其中主要包括一种基于 Wishart 分布的自动编码器分类方法（Wishart Auto Encoder, WAE）<sup>[62]</sup>、一种基于 Wishart 分布的自动卷积编码器分类方法（Wishart Auto Convolutional Encoder, WCAE）<sup>[62]</sup>、一种复数卷积神经网络（Complex-valued Convolutional Neural Network, CV-CNN）分类算法<sup>[36]</sup>、一种基于极化编码卷积神经网络（Polarimetric Convolutional Network, PCN）分类算法<sup>[54]</sup>、一种极化特征驱动的卷积神经网络（Polarimetric Feature driven Convolutional Neural Network, SF-CNN）分类方法<sup>[63]</sup>。以上五种算法均是近年来表现优异的算法，所有对比实验中的参数设置与相关文献保持一致。

### 3.4.2 精度评价方法

精度评价是对实际数据和模型分类结果进行比较的重要步骤，旨在确定分类模型的准确性，是衡量分类结果可靠性的关键指标。混淆矩阵（Confusion Matrix）通常作为遥感图像分类准确性能的评判指标，并且可以通过混淆矩阵计算得到多种常用的评价参数指标，包括生产者精度（Producer Accuracy, PA）、使用者精度（User Accuracy, UA）、总体分类准确率（Overall Accuracy, OA）、平均分类准确率（Average Accuracy, AA）、Kappa 系数等。

如表3-2所示， $c$  类样本混淆矩阵是一个  $c \times c$  的矩阵，其中  $c$  表示数据集的类别数量。混淆矩阵的行表示实际类别，列表示预测类别。其中，每个元素  $(i, j)$  表示实际属于类别  $i$  的样本被预测为类别  $j$  的数量。混淆矩阵主对角线元素表示被正

确分类的样本，非主对角线表示分类错误的样本。

表 3-2 c 类样本混淆矩阵示意

		地面真实类别				
		第 1 类	第 2 类	…	第 c 类	预测样本数
预测类别	第 1 类	$n_{11}$	$n_{12}$	…	$n_{1c}$	$n_{1+}$
	第 2 类	$n_{21}$	$n_{22}$	…	$n_{2c}$	$n_{2+}$
	:	:	:	…	:	:
		第 c 类	$n_{c1}$	$n_{c2}$	…	$n_{cc}$
地面真值样本数		$n_{+1}$	$n_{+2}$	…	$n_{+c}$	$N$

在极化 SAR 图像分类结果精度评价中，可以基于混淆矩阵定义以下指标：

#### 1. 总体分类准确率 (OA):

OA 表示模型正确分类的样本数量占总样本数的比例，衡量分类模型的总体性能水平，计算公式如下：

$$OA = \sum_{i=1}^c \frac{n_{ii}}{N} \quad (3-23)$$

#### 2. 生产者精度 (PA):

PA 是指针对某个具体类别，模型正确预测该类别的样本数占该类别预测样本数的比例，衡量模型对特定类别的分类准确度，计算公式如下：

$$PA = \frac{n_{ii}}{n_{+i}} \quad (3-24)$$

#### 3. 使用者精度 (UA):

UA 是指针对某个具体类别，模型正确预测该类别的样本数占该类别实际样本数的比例，衡量模型对特定类别的分类准确度，计算公式如下：

$$UA = \frac{n_{ii}}{n_{i+}} \quad (3-25)$$

#### 4.Kappa 系数:

Kappa 系数是一种通过多元统计方法来评价分类精度的指标，旨在量化分类模型的性能相对于完全随机分类的优越性。该系数通过考察混淆矩阵的对角线元素以及总体分布情况，提供了对分类结果误差的全局度量。计算公式如下：

$$Kappa = \frac{N \sum_{i=1}^c n_{ii} - \sum_{i=1}^c n_{i+} n_{+i}}{N^2 - \sum_{i=1}^n n_{i+} n_{+i}} \quad (3-26)$$

Kappa 系数的大小可以用来表示分类的精度性能，表3-3描述了 Kappa 系数与模型的分类精度的映射关系。

表 3-3 Kappa 统计值与分类精度映射关系

Kappa 系数	分类精度
<0	较差
0-0.2	差
0.2-0.4	正常
0.4-0.6	好
0.6-0.8	较好
0.8-1	非常好

### 3.4.3 AIRSAR Flevoland 数据实验

实验数据集选择 NASA/JPL 于 1989 年在 Flevoland 区域采集得到的全极化数据<sup>[36]</sup>。该数据集是荷兰的一个农业区域遥感数据，作为基准数据集广泛应用于极化 SAR 土地覆盖目标分类研究中。该图像大小为  $1024 \times 750$  像素，共有 15 种农作物类别，包括茎豆、豌豆、森林、苜蓿、小麦、甜菜、土豆、裸土、草、油菜籽、大麦、水和少量建筑物。各个农作物目标类别之间的差异较小，相似性较强，因此分类难度较大，容易出现错分漏分的现象。图3-10(a)和图3-10(b)分别展示了 AIRSAR Flevoland 数据集的 Pauli 分解伪彩色图像以及对应的地面真值标签图像。表3-4展示了该数据集中每个类别带标签的样本数量。

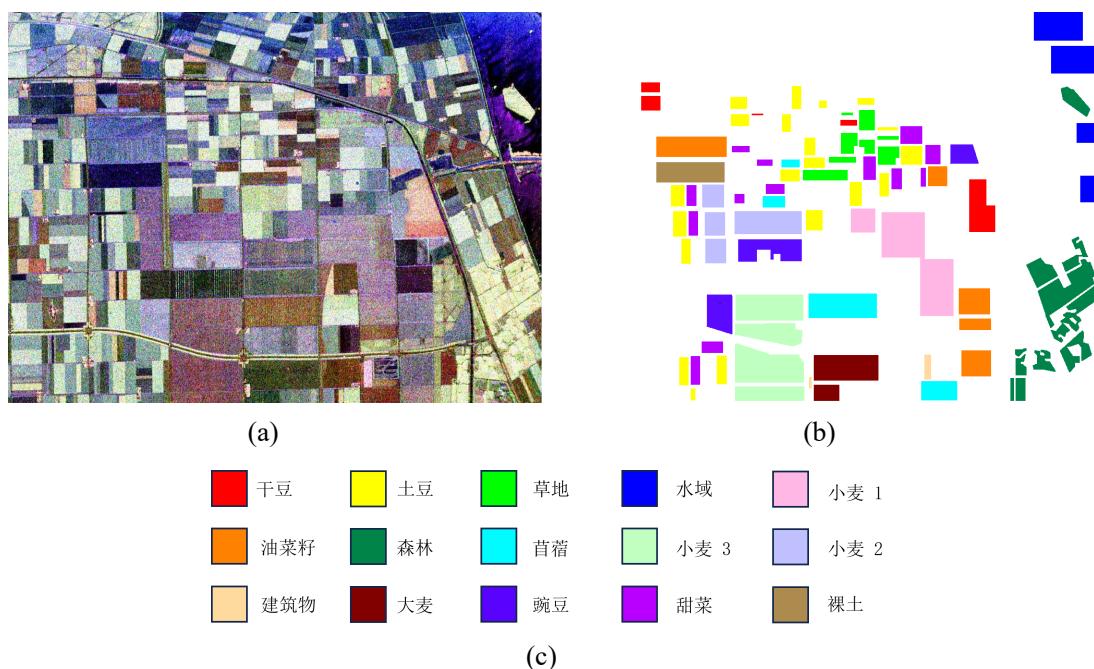


图 3-10 Flevoland 地区实验数据集。(a)Pauli 分解伪彩色图像；(b) 实验数据地面真值；(c) 颜色与类别对应关系

表 3-4 Felvoand 地区实验数据集有标签样本数量

类别	干豆	大麦	裸土	土豆	甜菜	小麦 1	豌豆	苜蓿
数目	6338	7595	5109	16156	10033	11159	9582	10181
类别	草地	小麦 2	油菜籽	小麦 3	建筑物	森林	水域	
数目	7058	16386	13863	22241	735	18044	13232	

图3-11展示了各个对比方法的可视化分类结果，其中每个分类结果图下方依次为 A、B、C 区域的局部放大图。根据图3-11(a)，仅使用散射特征的分类方法，在草地（区域 A）、油菜籽（区域 B）和土豆（区域 C）都有较多的错分样本，这是因为只使用了散射特征而忽略了目标分解特征，没有全面综合利用所有的极化信息导致的。图3-11(b)展示了仅使用目标分解特征的分类结果，在草地、油菜籽、土豆区域也存在大量的错分样本，这可能是由于没有综合使用极化信息导致的，相干矩阵代表的散射特征是极化 SAR 中最基本、重要的特征。图3-11(c)展示的简单叠加散射特征与目标分解特征的分类结果，该方法的分类结果几乎与前两种方法相同，仍然在草地、油菜籽区域存在大量错分样本，这反映了直接简单堆叠使用极化特征带来的准确率提升有限。图3-11(g)与图3-11(h)展示了使用经典注意力方法的分类结果图，相比于直接叠加特征，并没有带来明显的分类性能提升，少量的错分孤立点与草地中错分的块状区域依然存在，这表明不考虑极化 SAR 数据特征的特征细化方法并不能为极化 SAR 分类任务带来优势。图3-11(i)展示了基于双通道注意力方法的分类结果，可以看出本方法分类结果更加平滑，错分像素减少，特别是是在小麦、油菜籽区域，类间错分孤立点相对减少，这也验证了本章方法结合散射特征和目标分解特征的有效性，证明本章方法提取的极化信息表示是优越的。

为了进一步探索极化信息提取模块的性能，引入 t-SNE (t-distributed Stochastic Neighbor Embedding)<sup>[64]</sup> 特征分布图作为衡量极化信息提取模块的可视化评估指标。t-SNE 是一种非线性降维技术，能够有效地将高维数据映射到二维或三维空间，以便更直观地观察样本在特征空间的分布。

图3-12展示了不同方法特征特征使用 t-SNE 可视化的分布情况。根据图3-12(a)、图3-12(b)和图3-12(c)所展示的仅散射特征、仅分解特征和直接堆叠特征三种不同的特征分布情况，可以看出大多数类别相互之间有交叠的情况，并且类内的样本分布较为散乱，因而容易造成类间错分的情况，导致分类性能优先。而图3-12(d)和图3-12(e)展示的使用经典的注意力信息提取方法的特征分布图，可以看出经典的注意力方法由于没有考虑极化 SAR 的数据特性，不同类别之间的重叠情况依然存在，并且类内样本特征分布散乱，证明了在信息提取时不考虑极化 SAR 数据特征对分类模型的性能提升是有限的。根据图3-12(f)所展示的基于双通

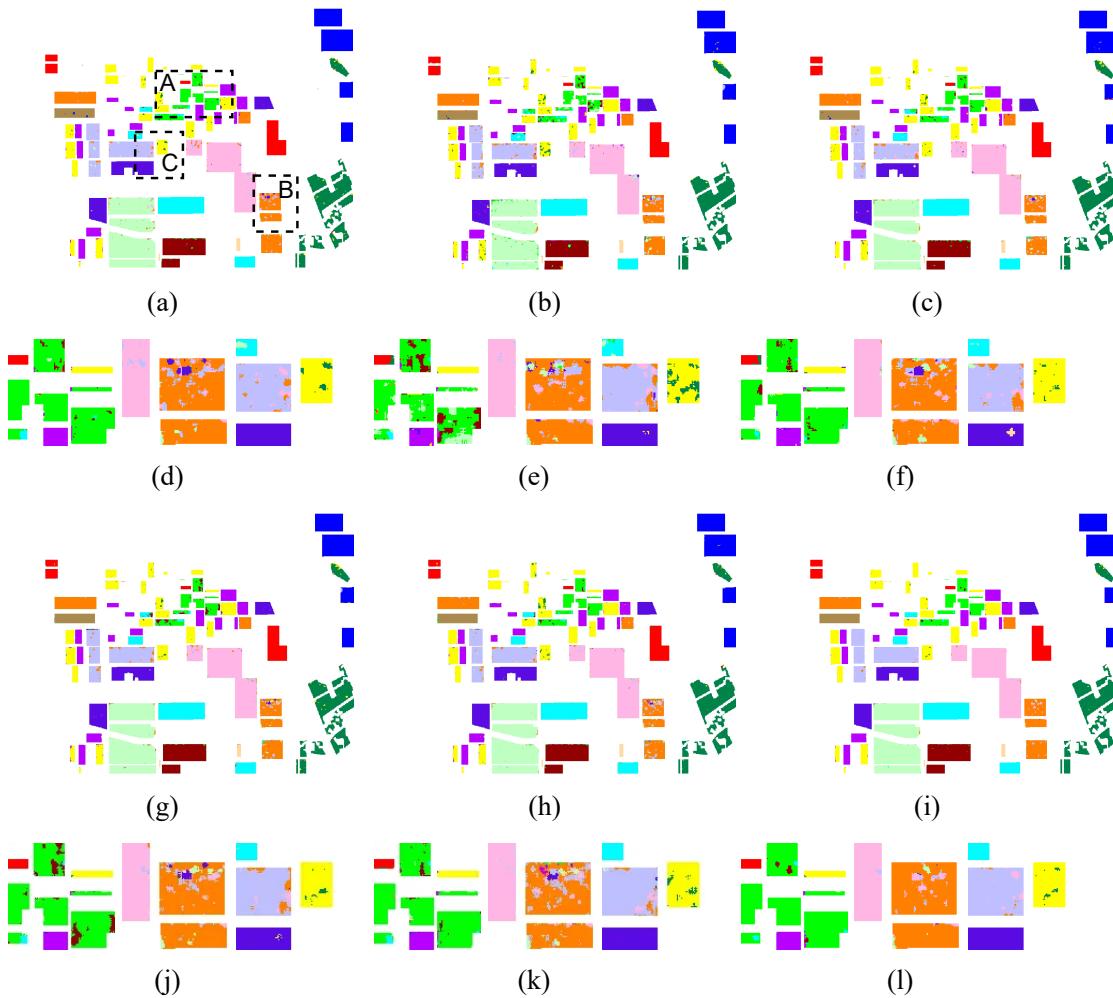


图 3-11 AIRSAR Flevoland 地区数据分类可视化结果图。(a)CNN-T; (b)CNN-P; (c)CNN-F; (d)CNN-T 局部误差图; (e)CNN-P 局部误差图; (f)CNN-F 局部误差图; (g)CNN-SE; (h)CNN-CBAM; (i) 本章方法; (j)CNN-SE 局部误差图; (k)CNN-CBAM 局部误差图; (l) 本章方法局部误差图

道注意力的极化信息提取方法的特征分布图，可以看到相比于其他的特征分布情况，类间的交叠现象有了明显的改善，同时类内样本特征分布更加紧凑，提升类间可分性，进而带来分类性能上的提升。

表3-5展示了不同方法的分类数值结果。仅使用散射特征的分类方法，在草地和建筑物区域的分类准确率较低，分别为 89.41% 和 91.17%，这可能是因为仅使用相干矩阵作为极化特征的分类方法，并不能完全反应这两类地物目标的散射特性，导致分类准确率较低。仅使用目标分解特征作为特征的分类方法，在干豆区域达到了 99.66% 的准确率，这是因为目标分解特征中包含有具体物理意义的极化表征，但是在建筑物油菜籽区域的分类准确率较低，仅有 90.2%，反映了目标分

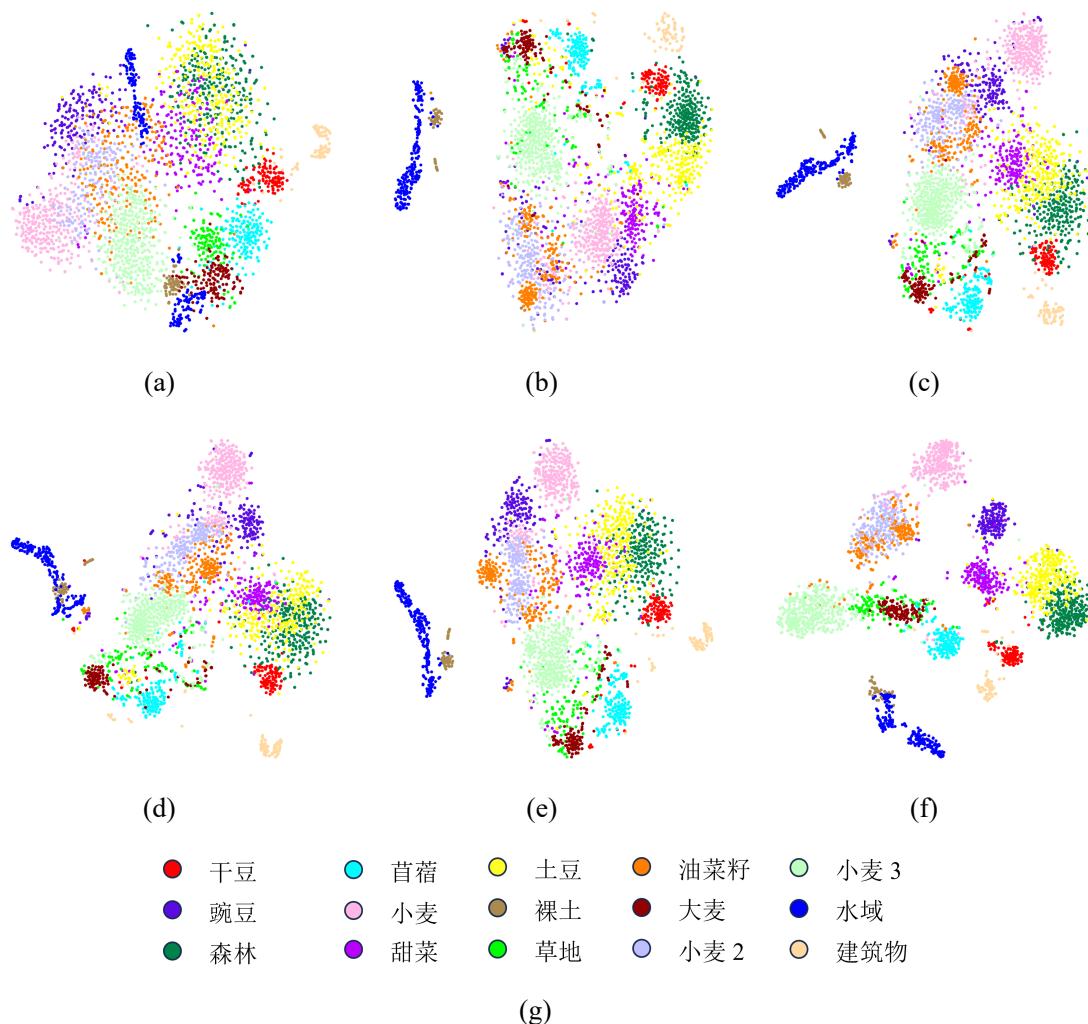


图 3-12 AIRSAR Flevoland 地区数据不同方法特征分布。(a)CNN-T; (b)CNN-P; (c)CNN-F; (d)CNN-SE; (e)CNN-CBAM; (f) 本章方法; (g) 颜色与类别对应关系

解特征与散射特征相互补充，都是必不可少的极化特征表示方法。直接堆叠极化特征的分类方法在分类总体准确率、平均准确率以及大麦等区域准确率反而下降，这表明了直接堆叠极化特征导致特征维数增加，分类器无法有效分清两种类型的主次关系，导致分类准确率有所下降。经典的注意力方法 CNN-SE 与 CNN-CBAM 的 OA 指标分别为 96.76% 和 96.13%，相比于前面的方法仅有不足 1% 的提升，表明该方法直接应用于极化 SAR 领域性能提升有限。而本章方法在大多数的类别都具有最高的分类准确率，OA、AA 与 Kappa 分别达到 98.47%、98.65% 和 98.53%，相比于其他方法分别提升了 1.71%、3.12% 和 2.46%，表明了基于双通道注意力的极化信息提取方法对于极化 SAR 目标分类具有优势，验证了本章方法的有效性与

优越性。

表 3-5 AIRSAR Flevoland 地区数据分类数值结果 (%)

序号	类别	CNN-T	CNN-P	CNN-F	CNN-SE	CNN-CBAM	CNN-DP
1	建筑物	91.17	90.2	94.01	<b>99.79</b>	94.14	98.83
2	油菜籽	94.33	91.78	89.78	94.54	92.32	<b>98.29</b>
3	甜菜	96.57	96.62	96.99	97.92	95.74	<b>98.92</b>
4	干豆	99.26	<b>99.66</b>	98.86	97.08	98.83	99.58
5	豌豆	96.72	97.03	96.54	99.8	95.72	<b>99.25</b>
6	森林	98.13	97.37	96.42	98.85	98.61	<b>99.08</b>
7	苜蓿	96.03	95.96	95.07	96.11	95.48	<b>97.86</b>
8	土豆	96.61	97.03	97.54	97.33	95.59	<b>99</b>
9	裸土	95.02	97.19	98.44	98.51	96.8	<b>99.67</b>
10	草地	89.41	93.11	92.32	96.19	94.25	<b>97.81</b>
11	大麦	93.63	95.45	87.34	95.64	89.34	<b>97.7</b>
12	水域	99.94	99.7	99.66	93.3	99.83	<b>99.99</b>
13	小麦 1	97.53	96.74	97.36	97.27	97.6	<b>97.92</b>
14	小麦 2	93.62	94.48	94.21	<b>97.53</b>	92.25	96.53
15	小麦 3	96.88	97.05	98.06	94.85	98.51	<b>99.36</b>
OA		96.4	96.41	95.9	96.76	96.13	<b>98.47</b>
AA		95.68	95.93	95.51	96.98	95.67	<b>98.65</b>
Kappa		96.07	96.08	95.53	96.48	95.77	<b>98.53</b>

表3-6为各目标分类算法的性能对比结果，可以看出，本章方法在 AA、OA 和 Kappa 评价指标上性能均优于各项对比方法，表明本章方法在极化 SAR 目标分类任务中具有优越的性能。

表 3-6 AIRSAR Flevoland 地区数据各分类方法的性能对比 (%)

分类方法	OA	AA	Kappa
WAE	89.97	89.98	89.43
WCAE	86.21	86.08	85.07
CV-CNN	95.58	96.08	95.18
PCN	95.59	96.94	94.08
SF-CNN	97.02	97.63	96.77
CNN-DP	<b>98.47</b>	<b>98.65</b>	<b>98.53</b>

图3-13展示了本章方法分类结果对应的混淆矩阵。结果表明，混淆矩阵的主对角线元素具有相对较高的数值，模型正确分类的情况占据了主导地位，说明本章方法在本数据集上的优秀分类性能。

	干豆	豌豆	森林	苜蓿	小麦	甜菜	土豆	裸土	草地	油菜籽	大麦	小麦 2	小麦 3	水域	建筑物	
干豆	5889	0	23	0	0	0	1	0	1	0	0	0	0	0	0	0
豌豆	0	8827	0	0	0	59	1	0	0	7	0	0	0	0	0	0
森林	1	1	14183	0	0	0	120	0	1	2	3	0	2	2	0	0
苜蓿	0	0	0	9152	0	0	0	0	171	4	6	0	19	0	0	0
小麦	0	8	0	0	16560	5	0	0	0	199	0	132	7	0	0	0
甜菜	3	2	4	4	4	9651	43	0	25	11	5	0	4	0	0	0
土豆	16	0	108	0	0	23	4666	0	0	0	0	0	1	0	0	0
裸土	0	0	0	0	0	0	0	2986	0	1	0	0	0	9	0	0
草地	10	0	0	37	0	5	1	0	5748	0	52	0	24	0	0	0
油菜籽	0	0	0	0	65	4	0	0	0	1780	0	104	32	0	0	0
大麦	0	0	6	0	0	0	0	0	131	2	6874	0	6	17	0	0
小麦 2	0	0	0	0	126	2	0	0	0	215	0	10009	17	0	0	0
小麦 3	0	0	0	0	10	0	0	0	4	89	1	29	20548	0	0	0
水域	0	0	0	0	0	0	1	0	0	0	0	0	0	1798	0	0
建筑物	1	0	0	0	0	0	1	0	0	0	1	0	1	0	337	0

图 3-13 本章方法在 Flevoland 图像中分类结果混淆矩阵图

### 3.4.4 E-SAR Oberpfaffenhofen 数据实验

该数据集是通过 E-SAR 机载平台在德国 Oberpfaffenhofen 地区拍摄获取到的 L 波段极化 SAR 数据<sup>[62]</sup>。该数据集经过多视处理，具有高质量的全极化信息，是极化 SAR 目标分类研究的经典数据集之一。数据集在方位向和距离向具有  $3m \times 3m$  的分辨率，大小为  $1300 \times 1200$ ，包含建筑物、林地、开放区域三种类型的地物目标，每类包含样本数量依次为 269184、388503、779962。图3-14(a)展示了该数据集的 Pauli 伪彩色图像，图3-14(b)展示了该数据集的人工标记的地面真值参考图，地面真值图中黑色的区域表示未标记的区域。

图3-15展示了不同方法的分类结果可视化图像。根据图3-15(a)展示的仅使用极化相干矩阵为特征的分类结果图，尽管在开放区域的分类效果较好，但是在建筑物（区域 A、区域 B、区域 C）存在大量被错分的样本，将建筑物区域样本错误分类为开放区域，并且错分的现象较为严重。这可能是因为仅使用极化相干矩阵作为特征时并没有完全利用其他的目标分解特征导致的，说明了综合考虑极化 SAR 图像中的其他极化特性和辅助特征的在分类任务中的重要性。相比之下，图3-15(b)与图3-15(c)在建筑物区域中的错分样本相对较少，但是在各类区域中也存在着部分错分的样本。其中将开放区域中的少数像素分类为建筑物的错分情况依然存在，这反映了极化目标分解特征提供的反映目标物理散射特性的信息为分类任务带来了一定的优势，是极化 SAR 图像中的重要的基本特征。图3-15(d)和图3-15(e)展示了基于经典注意力方法的特征表示分类结果，从结果图中可以看出，分类效果仅有微小的变化，错分像素相对减少但是依然存在，这可能是极化 SAR

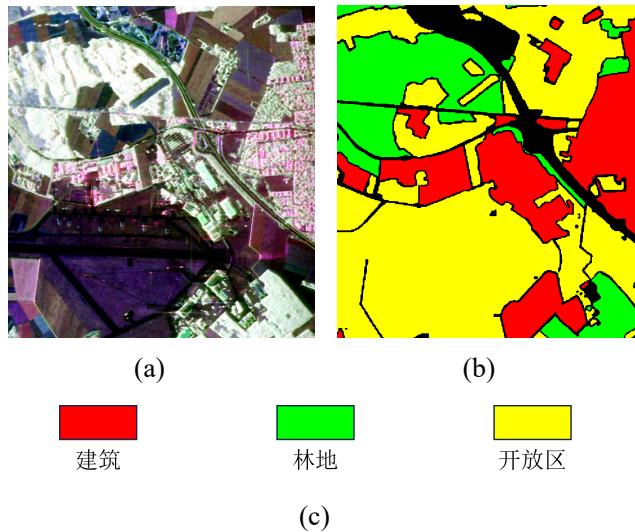


图 3-14 E-SAR Oberpfaffenhofen 区域数据。(a)Pauli 分解伪彩色图像; (b) 实验数据地面真值; (c) 颜色与类别对应关系

图像与光学图像存在较大的差异，经典的注意力方法并没有考虑极化 SAR 图像的数据特征特点。图3-15(f)展示了基于本章提出的双通道注意力极化信息提取方法的分类结果图，从图中可以看出，在建筑物区域的错分样本明显减少区域内部分类更加平滑，并且每个类中的小块错误区域数量也相对减少，整体分类结果得到明显改善，证明了本章方法的有效性。

图3-16展示了不同方法数据特征使用 tSNE 可视化的分布情况。根据图3-16(a)、图3-16(b)、图3-16(c)展示的仅散射特征、仅分解特征和直接堆叠的三种特征分布情况，可以看出三种特征分布情况并没有本质性的差异，尽管都可以看出各类之间存在不同的分布情况，但是也能清晰看出，类间存在分布交叠的部分，这也导致了部分样本的错分情况。根据图3-16(d)和图3-16(e)展示的使用经典注意力信息提取方法的特征分布图，可以看出虽然类间交叠的情况有细微改善，但是依然有大量的特征存在交叠，这也映照了分类结果改善不大的结果。图3-16(f)展示了使用本章方法的特征分布情况，可以看出类间交叠的情况得到优化，各类之间分布间距增大，增强了类间可分性，进而带来分类性能的提升。

表3-7展示了各个方法的分类数值结果。仅使用散射特征时，在建筑物区域的分类准确率仅为 76.68%，这可能是因为建筑物区域目标散射回波差异性大，导致仅使用散射特征时，不能完全表征建筑物目标的特性，进而导致在建筑物区域可分性较低。仅使用目标分解特征相比于 CNN-T 分类性能得到小幅度提升，OA 达到 88.97%，这是因为目标分解特征包含的具体物理散射特性对建筑物区域分类提升明显。与仅使用目标分解特征相比，直接堆叠极化特征在平均准确率指标反而

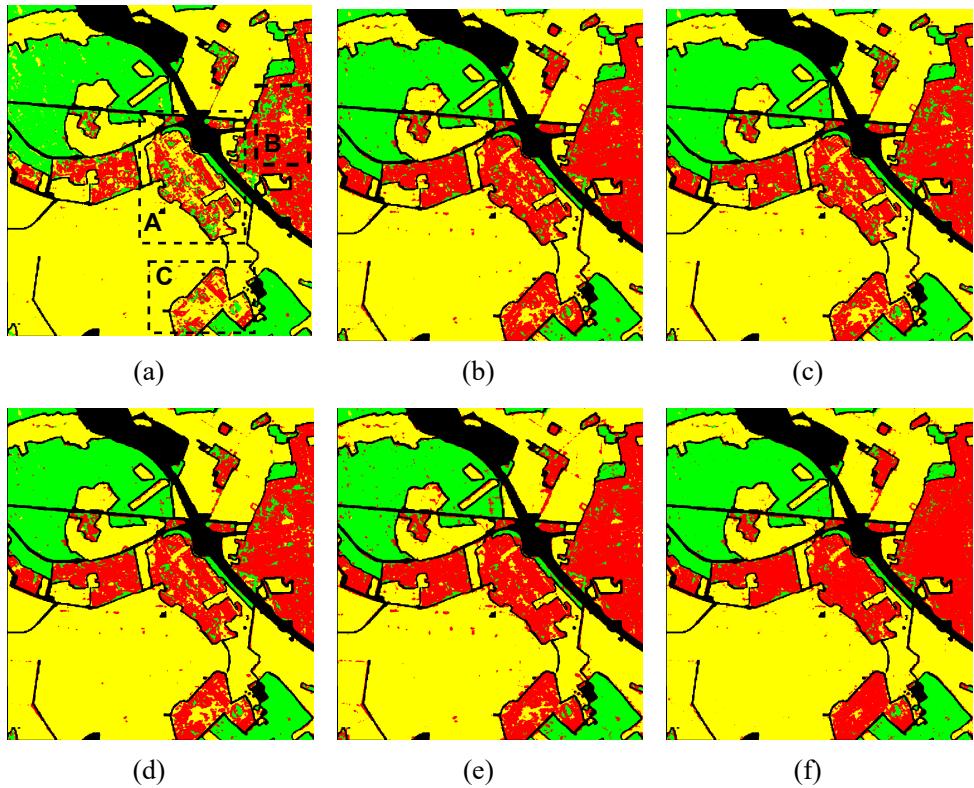


图 3-15 E-SAR Oberpfaffenhofen 地区数据分类可视化结果图。(a)CNN-T; (b)CNN-P; (c)CNN-F; (d)CNN-SE; (e)CNN-CBAM; (f) 本章方法

表 3-7 E-SAR Oberpfaffenhofen 地区数据分类数值结果 (%)

序号	类别	CNN-T	CNN-P	CNN-F	CNN-SE	CNN-CBAM	本章方法
1	建筑	76.68	83.9	80.1	80.42	83.92	<b>90.47</b>
2	林地	90.35	91.99	90.5	91.44	91.61	<b>92.61</b>
3	开放区域	89.83	90.04	91.37	91.63	91.41	<b>96.78</b>
	OA	86.56	88.97	88.52	89.13	90.27	<b>94.39</b>
	AA	85.62	88.64	87.32	87.83	88.98	<b>93.28</b>
	Kappa	81.63	83.51	82.73	83.58	85.24	<b>90.4</b>

下降 0.45%，这可能是由于该方法仅仅是对两类的特征进行简单的堆叠，堆叠后的特征维数过高，分类模型对于高维特征输入无法有效利用两种不同类型特征间的主次关系。而经典注意力方法 CNN-SE 与 CNN-CBAM 的 OA 分别为 89.13% 和 90.27%，分类准确率提升不足 1%，微弱的准确率提升与计算量的增加表明对极化 SAR 特征优化性能有限。本章方法在 OA、AA、Kappa 系数等指标达到了 94.39%、93.28% 和 90.4%，相比于对比方法分别提升了 4.12%、4.3% 和 5.16%，表明本章方法能有效利用多类型极化特征，提升分类准确度。

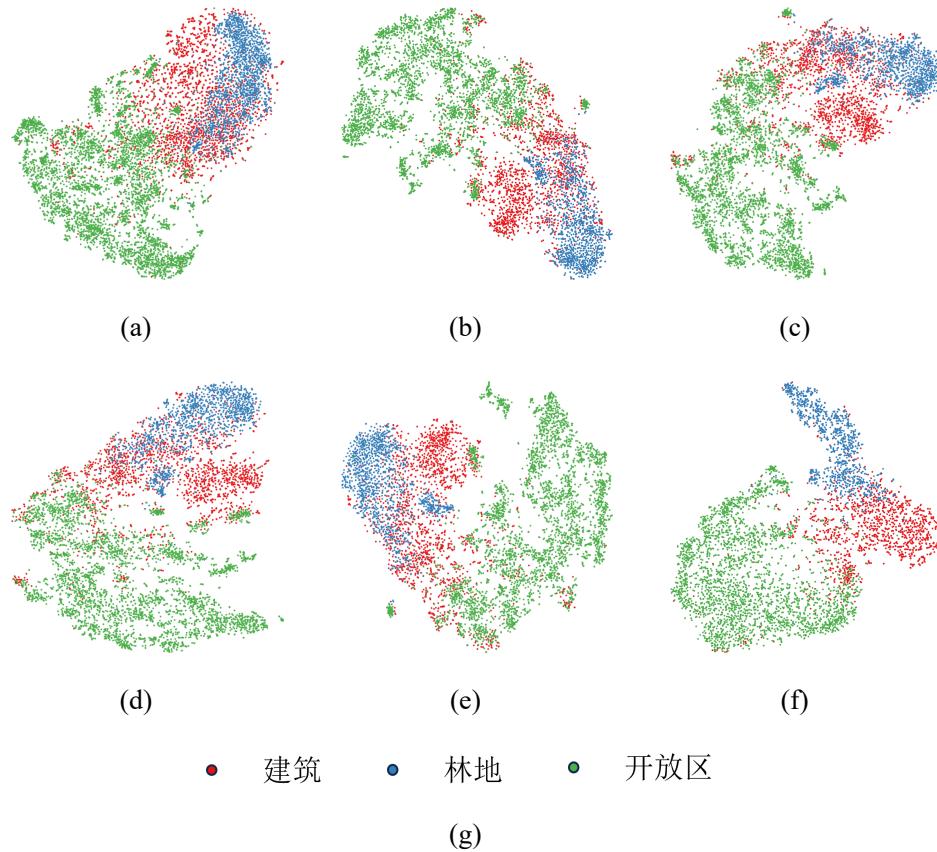


图 3-16 E-SAR Oberpfaffenhofen 地区数据地区数据不同方法特征分布。(a) CNN-T; (b) CNN-P; (c) CNN-F; (d) CNN-SE; (e) CNN-CBAM; (f) 本章方法

表 3-8 E-SAR Oberpfaffenhofen 地区数据各分类方法的性能对比 (%)

分类方法	OA	AA	Kappa
WAE	84.55	78.09	73.57
WCAE	87.71	86.78	80.31
CV-CNN	90.21	90.11	85.15
PCN	90.88	87.95	81.62
SF-CNN	89.13	88.16	83.58
CNN-DP	<b>94.39</b>	<b>93.28</b>	<b>90.40</b>

表3-8为各目标分类算法的性能对比结果，可以看出，本章方法在 AA、OA 和 Kappa 评价指标上性能均优于各项对比方法，表明本章方法在极化 SAR 目标分类任务中具有优越的性能。

图3-17展示了本章方法分类结果对应的混淆矩阵。结果表明，混淆矩阵的主对角线元素具有相对较高的数值，模型正确分类的情况占据了主导地位，说明本章方法在本数据集上的优秀分类性能。

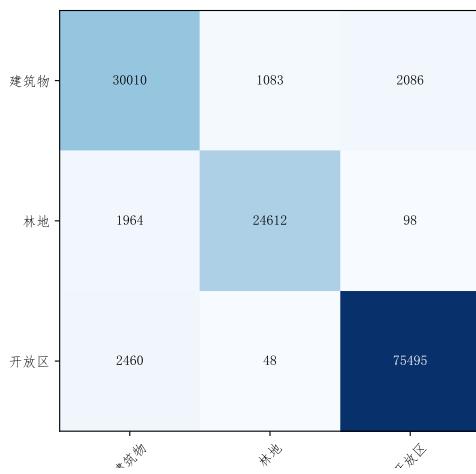


图 3-17 本章方法在 E-SAR Oberpfaffenhofen 图像中分类结果混淆矩阵图

### 3.5 本章小结

本章针对多类型极化特征信息冗余问题，提出了基于双通道注意力的极化 SAR 目标分类方法。首先，构建后向散射特征通道和目标分解特征通道的双通道结构，结合空间、通道注意力机制，实现对两种类型极化特征中有效信息的激发而抑制无关信息。然后，为了充分挖掘两类极化特征之间的关联信息，设计了基于散射特征一致性的注意力修正方法，对注意力特征进行动态校正。其次，通过多尺度特征学习模块，聚合不同空间尺寸的极化特征，增强模型对不同空间尺度的特征的感知能力。最后，将经过双通道注意力校准后的极化特征输入到分类器，得到最终的分类结果。在两组真实极化 SAR 数据集进行性能测试，并视觉分类效果和数据量化准确率两个层面进行性能评估，结果表明本章提出的目标分类方法能够更加全面地利用多类型极化特征信息，提升极化 SAR 图像目标分类精度。

## 第四章 基于混合模型噪声估计的极化 SAR 目标分类

### 4.1 引言

近年来，随着极化 SAR 成像技术的不断发展，获取到的极化 SAR 图像数量呈现爆炸式增长趋势。区别于光学图像，由于极化 SAR 的复杂成像机制，极化 SAR 图像不可避免受到相干斑噪声影响，图像中部分类别边缘及内部存在类别模糊与特征信息不可靠的问题。同时，极化 SAR 的标注工作往往依赖专家知识，很可能因为人工标注错误、自动标注辅助技术误差、地面覆盖类型不准确等因素出现错误标记的情况，引入标签噪声<sup>[8,65]</sup>。

目前主流的极化 SAR 图像目标分类方法均采用有监督或半监督的学习方式，让分类器先学习部分标记样本的分类规则，然后对剩余未标记样本进行分类识别。但在实际应用场景中，错误标记样本的存在会影响分类器学习的规则，导致分类准确率下降的问题。现有的多数极化 SAR 图像分类方法都是在理想的训练集中完成模型训练，很少有考虑标签噪声问题。因此研究对标签噪声的极化 SAR 图像分类方法具有重要的价值与意义。

针对标签噪声导致的分类精度下降问题，本章提出了一种基于混合模型噪声估计的极化 SAR 图像分类方法。首先，根据噪声样本与准确样本的损失函数分布差异特性，基于混合模型理论对样本损失分布进行拟合，以估计样本属于噪声的概率。其次，根据极化 SAR 图像标签噪声更多存在于类别边界区域特性，通过捕获类别边界区域，增强边界内部样本的分类损失，使分类模型能够有效利用边缘知识增强识别性能。最后，基于改进的自学习优化损失函数，训练过程中引入模型的分类结果来增加权衡项，对真值标签依赖进行动态修正，完成模型参数的鲁棒性优化过程。

### 4.2 有限混合模型

目前针对极化 SAR 图像分类的机器学习方法，尤其是以深度卷积神经网络（Deep Convolutional Neural Network, DCNN）为基础的深度学习方法取得了显著的成果<sup>[40,66,67]</sup>。这些方法具有强大的端到端的拟合能力，在含标签噪声样本集上训练时，总是先学习简单的分类规则，之后再花足够的时间来对错误信息进行过拟合<sup>[68]</sup>。相比于干净的标记样本，随机标记的错误样本需要更长的时间来学习，这意味着有噪声样本在训练的前期阶段具有更高的损失，这使得干净样本与噪声样本可以通过损失值的分布情况进行区分。由于对观测值的建模能力，有限混合模

型适用于估计干净样本与噪声样本的损失分布估计的场景。

有限混合模型（Finite Mixture Model, FMM）是一种用于描述观测数据生成过程的概率模型<sup>[69]</sup>。该模型假设观测的数据是由有限个概率分布组合而成的混合分布，而每个成分分布对应一个潜在的类别，混合模型需要考虑这些类别之间的不同权重。

在有限混合模型中，假设观测数据来自于 K 个不同的成分，每个成分对应一个概率分布。对于一维数据而言，有限混合模型的概率密度函数可以表示为：

$$f(x) = \sum_{k=1}^K \pi_k \cdot f_k(x) \quad (4-1)$$

其中， $f_k(x)$  表示第  $k$  个成分分布的概率密度函数， $\pi_k$  表示对应成分的权重，并且满足  $\sum_{k=1}^K \pi_k = 1$ 。表示该数据的分布是由多个成分分布的加权和。

#### 4.2.1 高斯混合模型

高斯混合模型（Gaussian Mixture Model, GMM）是一种将一个复杂的概率分布建模为多个高斯分布的线性组合的概率模型<sup>[70]</sup>。相比于单一的高斯概率密度函数，GMM 能够更加灵活地适应多峰的数据。GMM 的核心思想是将观察到的数据视为多个高斯分布组成的混合体，每个高斯分布为一个组分量，而所有的分量的加权和形成了整个的混合模型。

对于一个服从高斯分布的连续随机变量  $x$ ，其概率密度函数（PDF）可以表示为：

$$p(x) = \frac{1}{(2\pi)^{1/2} \sigma} \exp \left[ -\frac{1}{2} \left( \frac{x - \mu}{\sigma} \right)^2 \right] = \mathcal{N}(x; \mu, \sigma^2) \quad (4-2)$$

$$(-\infty < x < \infty; \sigma > 0)$$

记作  $x \sim \mathcal{N}(\mu, \sigma^2)$ ，其中， $\mu, \sigma^2$  分别表示  $x$  的均值与方差。

对于由多个高斯变量随机混合形成的部分，记为高斯混合分布。服从高斯混合分布的连续随机变量  $x$  的概率密度函数可以表示为：

$$p(x) = \sum_{m=1}^M \frac{c_m}{(2\pi)^{1/2} \sigma_m} \exp \left[ -\frac{1}{2} \left( \frac{x - \mu_m}{\sigma_m} \right)^2 \right]$$

$$= \sum_{m=1}^M c_m \mathcal{N}(x; \mu_m, \sigma_m^2) \quad (4-3)$$

$$(-\infty < x < \infty; \sigma_m > 0; c_m > 0)$$

其中， $c_m$  表示不同混合分类的权重并且满足  $\sum_{m=1}^M c_m = 1$ 。

在上述的高斯混合分布中，涉及到一组参数，用  $\Theta = \{c_m, \mu_m, \Sigma_m\}$  表示。其中， $c_m$  表示每个分布的权重， $\mu_m$  表示均值， $\Sigma_m$  表示协方差矩阵。在考虑包含多个混合分类的情况下，这一组参数可以用来描述整个混合分布的特征。要获得对混合分布参数的准确描述，需要根据一组假设来确定这些参数的值，通过最佳的参数，来匹配观测到的数据，进而更加准确的反映真实数据的特征。图4-1展示了二分量的 GMM 模型概率密度函数示意图：

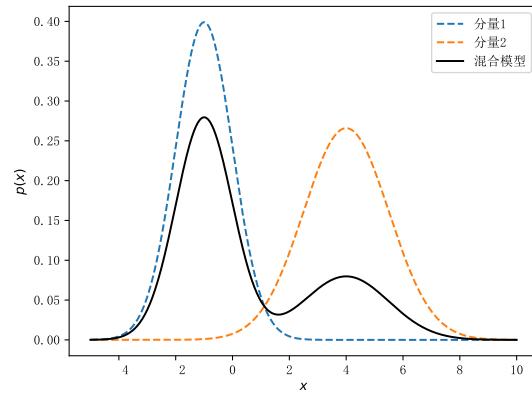


图 4-1 二分量的高斯混合模型概率密度函数示意图

高斯混合模型具有其原理简单、对异常值不敏感等有点，已经成为当前最为普遍使用的混合模型。但是在真实场景下，数据具有非高斯性、非线性等特点，使用高斯混合模型并不能完备地描述这些数据的分布特点，例如倾斜数据、拖尾数据、有界数据等。

#### 4.2.2 贝塔混合模型

贝塔混合模型（Beta Mixture Model, BMM）是一种概率模型，将复杂的概率分布建模为多个贝塔分布的线性组合。贝塔分布是一个定义在区间  $[0, 1]$  上的概率分布，通常用于描述在二项分布的贝叶斯估计中<sup>[71]</sup>。

对于一个服从贝塔分布的连续随机变量  $x$ ，其概率密度函数（PDF）可以表示为：

$$p(x; \alpha, \beta) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)} \quad (4-4)$$

其中， $B(\alpha, \beta)$  为贝塔分布的概率密度函数，具体表示为：

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)} \quad (4-5)$$

其中， $\alpha$  和  $\beta$  是贝塔分布的参数， $\Gamma$  表示伽玛函数。对于由多个贝塔分布随机混合形成的部分，记为贝塔混合分布。服从贝塔混合分布的连续随机变量  $x$  的概率密度函数可以表示为：

$$\begin{aligned} p(x) &= \sum_{m=1}^M c_m \frac{x^{\alpha_m-1}(1-x)^{\beta_m-1}}{B(\alpha_m, \beta_m)} \\ &= \sum_{m=1}^M c_m \text{Beta}(x; \alpha_m, \beta_m) \\ (0 < x < 1; c_m > 0; \sum_{m=1}^M c_m = 1; \alpha_m, \beta_m > 0) \end{aligned} \quad (4-6)$$

其中， $c_m$  表示不同混合分类的权重，满足  $\sum_{m=1}^M c_m = 1$ 。

在贝塔混合分布中，参数集为  $\Theta = \{c_m, \alpha_m, \beta_m\}$ 。其中， $c_m$  表示每个贝塔分布的权重， $\alpha_m$  和  $\beta_m$  分别表示每个贝塔分布的形状参数。为了描述整个混合分布的特征，需要通过一组假设，从观测到的数据中确定这些参数的值。这一过程旨在使混合分布的参数最佳匹配观测到的数据，以更准确地反映实际数据的特征。图4-2展示了二分量的 BMM 模型概率密度函数示意图：

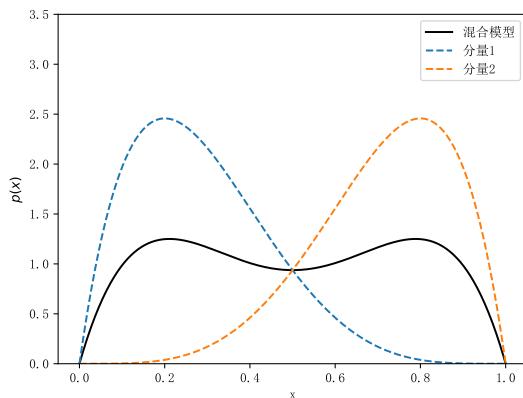


图 4-2 二分量的贝塔混合模型概率密度函数示意图

贝塔混合模型具有灵活性，能够使用更加多样的复杂数据，并通过参数共享提升模型泛化性能，适用于广泛的应用领域。但是其在参数估计方面具有较高的计算复杂度，且在据量过小时容易陷入过拟合问题，导致泛化能力降低，影响模型性能。

### 4.3 混合模型噪声估计的极化 SAR 目标分类

近年来，各种应对于标签噪声问题的鲁棒性学习方法层出不穷，文献 [72, 73] 指出，尽管基于深度网络模型的分类网络具有对噪声标签的记忆能力，但在训练

过程中是先学习主要的分类规则，然后才开始记忆噪声的分类模式。本章对此进行了进一步的研究，提出了一个端到端的标签噪声条件下的极化 SAR 图像目标分类方法。

### 4.3.1 标签噪声问题建模

给定一个包含  $N$  个类别的干净 PolSAR 数据的训练集，表示为：

$$(X, Y^{(c)}) = \{(x_1, y_1^{(c)}), \dots, (x_N, y_N^{(c)})\} \quad (4-7)$$

该数据来源于分布  $D = X \times Y$ 。假设存在一个函数  $\mathcal{F}: Y^{(c)} \rightarrow Y^{(n)}$ ，该函数向标签  $Y^{(c)}$  引入噪声，将  $\mathcal{F}$  应用于  $(X, Y^{(c)})$  得到一个带有噪声的训练数据集，表示为：

$$(X, Y^{(n)}) = \{(x_1, y_1^{(n)}), \dots, (x_N, y_N^{(n)})\} \quad (4-8)$$

其中  $Y^{(n)}$  是原始干净标签  $Y^{(c)}$  和被污染的标签  $Y^{(n)} \neq Y^{(c)}$  的组合。

假定标签  $y_i^{(c)}$  被噪声函数污染成  $y_i^{(n)}$ ，存在对称噪声源与非对称噪声源两种类型。对称噪声源模型是将真实标签以相同的概率随机翻转到其他类别，服从均匀分布，表达式如下：

$$P(y_i = y_i^{(n)} | y_i^{(c)}) = \frac{1}{N-1} \quad (4-9)$$

非对称噪声源模型是按照根据某种固定的规则进行标签映射操作，将真实标签以随机概率翻转到其他的某个类别。图4-3展示了两种类型噪声源的噪声转移矩阵示意图。

从干净分布  $D$  中随机选择一个测试集  $(X_T, Y_T)$ 。目标是使用带有噪声的数据集  $(X, Y^{(n)})$  训练一个分类器模型  $M: X \rightarrow Y$ ，以确保对干净测试集  $(X_T, Y_T)$  的鲁棒性泛化，并且在训练过程中无法访问原始的干净标签  $Y_c$ 。

### 4.3.2 目标分类算法框架

在极化 SAR 图像目标分类中，标签噪声的存在通常会导致传统分类方法性能下降，基于卷积网络的模型往往也会陷入过拟合的问题，学习到错误的分类规则。针对标签噪声问题，本章提出了基于混合模型噪声估计的极化 SAR 图像分类方法，其算法框架如图4-4所示。区别于传统的交叉熵损失优化方法，本章方法基于混合模型理论对样本损失函数分布建模，以获取训练样本属于噪声的概率。为了降低边界标签噪声样本对模型训练的影响，增强对边界样本的有效信息利用，通过 Sobel 算子对极化 SAR 图像的 Pauli 伪彩图进行边界提取并膨胀，增强属于膨胀边

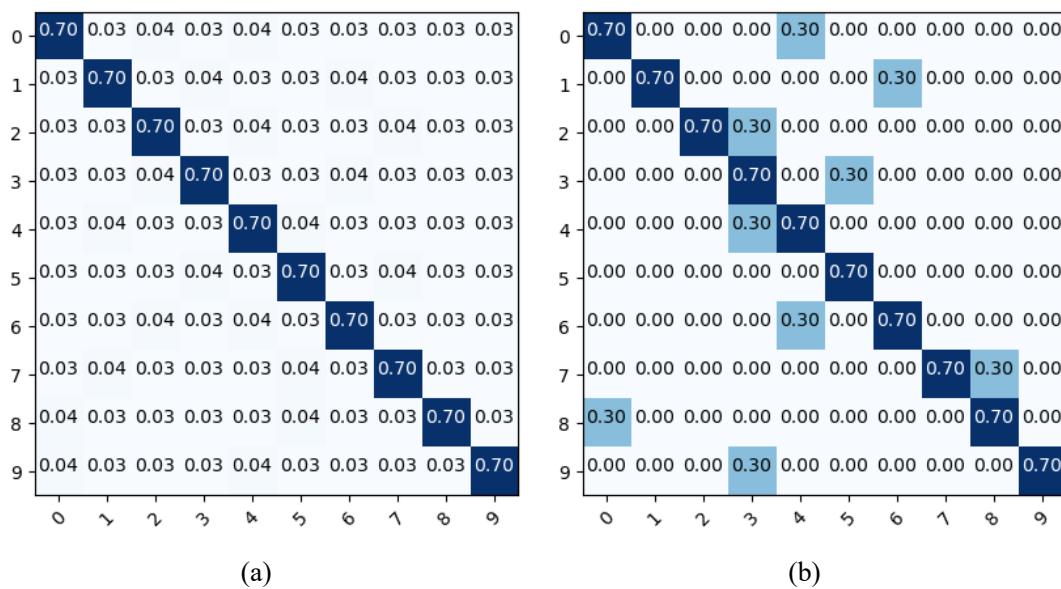


图 4-3 30% 比例噪声转移矩阵示意图。(a) 对称噪声 (b) 非对称噪声

界内的样本分类损失。最后，基于改进的自学习优化损失函数，结合模型对样本的分类结果与标记类别，对噪声标签进行动态权衡校正，实现模型的鲁棒性训练。

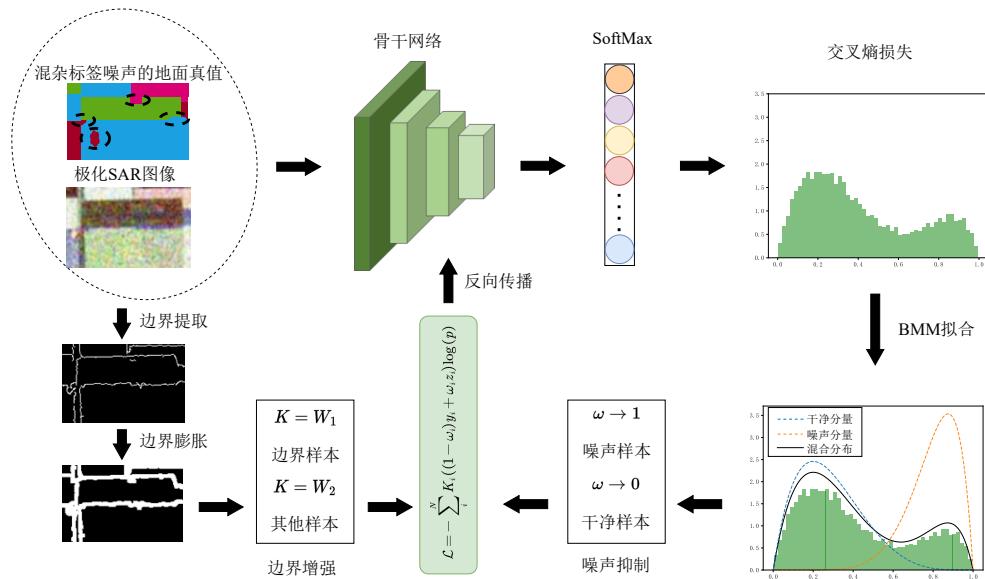


图 4-4 基于混合模型估计的目标分类算法框架图

结合上述算法框架，本章基于混合模型的极化 SAR 图像分类方法可以表示为以下步骤：

(1) 极化特征输入。极化特征具有多种表示形式,选择合适的极化特征对于分类任务具有重要意义。本章研究属于极化 SAR 图像分类问题,将第三章提出的

双通道注意力极化信息提取方法作为本算法的前置模块，用于极化特征表示，并输入到后续网络。

(2) 鉴别特征提取与分类。利用卷积神经网络，对输入的极化特征进行特征提取。通过多个堆叠的卷积、池化与激活操作，主干网络学习到极化特征的高级表征。随后，利用全连接层与激活函数，将主干网络的输出映射到不同的类别，得到对样本的预测类别。

(3) 噪声概率估计。计算每个样本预测类别与标签的交叉熵损失，并基于贝塔混合模型拟合样本损失分布。利用损失值来更新迭代混合模型参数，基于更新后的模型参数计算样本噪声概率。

(4) 边界样本增强。利用 Sobel 算子对极化 SAR 图像的 Pauli 伪彩图进行边界提取并膨胀，对膨胀边界内部的训练样本进行损失函数加权增强，以提高模型对边界信息的学习能力。

(5) 自学习损失函数优化。基于自学习损失函数，利用估计的样本噪声概率，动态调整模型预测与标签真值的权重。利用改进的自学习损失函数计算损失值后，通过反向传播更新模型参数，实现模型的训练优化。

综合上述算法描述，算法流程图如图4-5所示，下面对各个模块进行详细介绍。

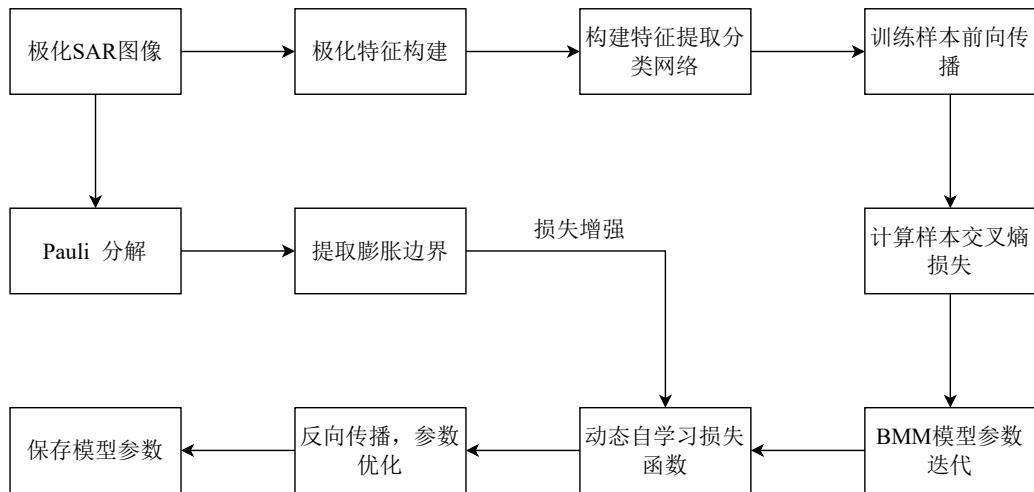


图 4-5 基于混合模型估计的目标分类算法流程图

### 4.3.3 噪声概率估计模型

在混合标签噪声数据集训练过程中，深度网络模型通常先学习干净样本特征，然后较长时间才能适应随机嘈杂标签。意味着训练早期，噪声样本相比于干净样本具有更高损失，可以认为训练过程中损失的分布是由于干净样本分布与噪声样本

分布叠加形成<sup>[68]</sup>。因此，利用二分量混合模型来对样本损失分布进行拟合，完成样本噪声概率估计。

贝塔混合模型具有对二元概率随机变量更加灵活的拟合特性<sup>[74]</sup>，用于拟合混合样本的损失值分布。对于给定的样本  $(x, y)$ ，其中  $x, y, \hat{y}$  分别表示 PolSAR 数据、相应的地面真实标签和  $x$  的分类器预测，交叉熵损失的标准化表示为  $\mathcal{L}_{CE}(\hat{y}, y) = \ell$ 。根据公式(4-4)与公式(4-4)，混合标签噪声损失概率密度函数可以表示为：

$$p(\ell) = \lambda_c \cdot p(\ell | \text{clean}) + \lambda_n \cdot p(\ell | \text{noisy}) \quad (4-10)$$

其中， $p(\ell | \text{clean})$  与  $p(\ell | \text{noisy})$  分别表示干净/噪声样本损失分布，具体表示如下：

$$p(\ell | \text{clean}) = \frac{\Gamma(\alpha_c + \beta_c)}{\Gamma(\alpha_c)\Gamma(\beta_c)} \ell^{\alpha_c-1} (1 - \ell)^{\beta_c-1} \quad (4-11)$$

$$p(\ell | \text{noisy}) = \frac{\Gamma(\alpha_n + \beta_n)}{\Gamma(\alpha_n)\Gamma(\beta_n)} \ell^{\alpha_n-1} (1 - \ell)^{\beta_n-1} \quad (4-12)$$

其中， $\alpha_{c/n}, \beta_{c/n} > 0$  表示干净/噪声样本的贝塔分布参数， $\Gamma(\cdot)$  是伽玛函数， $\lambda_c$  和  $\lambda_n$  分别表示混合系数，表示两个分量的组合系数。

参数集  $\Theta = \{c_{c/n}, \alpha_{c/n}, \beta_{c/n}\}$  描述了整个混合分布的特征。使用最大期望 (Expectation Maximization, EM) 算法，实现混合模型的参数更新迭代。首先，在 E 步中，固定混合系数，损失值  $\ell$  的后验概率  $Q_k(\ell) = p(k | \ell)$  基于贝叶斯规则进行更新，即

$$Q_k(\ell) = \frac{\lambda_k p(\ell | \alpha_k, \beta_k)}{\sum_{j=0}^1 \lambda_j p(\ell | \alpha_j, \beta_j)} \quad (4-13)$$

其中， $j = 0(1)$  表示干净 (噪声) 类别。

然后，在 M 步中，基于更新的  $Q_k(\ell)$ ，通过加权版本的矩方法估计  $\alpha_k$  和  $\beta_k$ 。基于更新后的贝塔模型参数，结合公式(4-13)可以根据样本损失分布，获得输入样本属于噪声概率  $\omega$ ，即：

$$\omega = Q_1(\ell) = \frac{\lambda_1 p(\ell | \alpha_1, \beta_1)}{\sum_{j=0}^1 \lambda_j p(\ell | \alpha_j, \beta_j)} \quad (4-14)$$

#### 4.3.4 边界增强模块

由于错误标记的噪声样本更多出现在类别交替的边界部分，模型需要对属于边界样本付出更多的关注度。为了加强对边界样本注意力关注和细节增强，对 Pauli 彩图进行 Sobel 算子卷积和展开运算，生成距离边界  $d$  以内的掩膜像素，并

将其作为辅助边界损失的目标。对于输入的图像  $I(x,y)$ , Sobel 算子使用两个  $3 \times 3$  的卷积核与输入图像进行卷积操作，分别计算垂直和水平梯度近似。这两个卷积核如下所示：

$$\mathbf{K}_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} \quad (4-15)$$

$$\mathbf{K}_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \quad (4-16)$$

其中， $\mathbf{K}_x$  和  $\mathbf{K}_y$  分别表示水平和垂直方向的卷积核。卷积操作的结果分别用  $\mathbf{G}_x$  和  $\mathbf{G}_y$  表示，其计算过程如下：

$$\mathbf{G}_x = I * K_x = \sum_{i=-1}^1 \sum_{j=-1}^1 I(x+i, y+j) \cdot K_x(i, j) \quad (4-17)$$

$$\mathbf{G}_y = I * K_y = \sum_{i=-1}^1 \sum_{j=-1}^1 I(x+i, y+j) \cdot K_y(i, j) \quad (4-18)$$

其中，\* 表示卷积操作。通过以上两个卷积操作，得到图像每个像素点的水平和垂直梯度。图像在该相处点出的梯度强度和方向可以通过下式计算：

$$G = \sqrt{\mathbf{G}_x^2 + \mathbf{G}_y^2} \quad (4-19)$$

$$\theta = \arctan\left(\frac{\mathbf{G}_y}{\mathbf{G}_x}\right) \quad (4-20)$$

其中， $G$  表示梯度强度， $\theta$  表示梯度方向。

通过 Sobel 算子提取到 Pauli 彩图边界后，为了增强对边界区域的细节感知，通过对边界以距离  $d$  进行展开操作，得到膨胀的掩膜边界  $\mathcal{B}$ 。对于每个输入样本  $x_i$ ，定义边界样本加权系数  $k$ ，具体表示为：

$$k_i = \begin{cases} W_1 & x_i \in \mathcal{B} \\ W_2 & others \end{cases} \quad (4-21)$$

其中， $W_1$  与  $W_2$  表示实验超参数。

### 4.3.5 损失函数与优化

面对标签噪声问题时，损失函数的精心选择对于引导模型学习训练过程变得极为重要。传统的交叉熵损失完全依赖于分类模型预测类别与给定的训练集标签值进行计算损失，对于训练集中样本标签存在错误时会引导模型参数拟合错误的规则，会鼓励模型学习到错误的信息。为了处理标签噪声问题，本章方法结合边界增强系数，通过在标准交叉熵损失中引入感知项来辅助调整训练目标。具体而言，损失函数表达式为：

$$\ell_B = \sum_{i=1}^N k_i((1 - \omega_i)y_i + \omega_i z_i)^T \log(h_i) \quad (4-22)$$

其中， $k_i$  表示边界系数， $N$  表示样本数量， $y_i$  与  $z_i$  分别表示样本标签值与分类模型预测值， $\omega_i$  在损失函数中作为权重调整对样本标签值和模型预测值之间的权衡。

如果设置权重  $\omega$  为固定值，并不能有效防止噪声样本的过拟合情况。本章将噪声预测概率与动态损失函数相结合，通过样本属于噪声的概率来动态调整样本标签和模型预测分类的依赖程度。结合 BMM 模型的噪声概率预测，通过将式  $\omega$  设置为由公式(4-13)得到的噪声概率  $p(\ell | \text{noisy})$ ，并且在每一个训练轮次结束后使用每个样本的交叉熵损失更新 BMM 模型参数，进而更新对应的噪声概率。因此干净的样本的噪声概率  $1 - \omega_i$  接近 1，更多的依赖于真值标签，而属于噪声样本的损失则由模型分类结果  $z_i$  和预测噪声概率来决定。

## 4.4 实验结果与分析

本节将详细阐述验证实验所依托的软件件设施配置以及关键的超参数设置，并对本章提出的混合模型噪声估计的目标分类方法进行性能评估。

### 4.4.1 实验参数设置

本章实验所使用的计算环境为一台 CPU 为 Intel Core i7-8700K 和配备了 NVIDIA GPU (GeForce RTX 3090, 24G) 的计算机设备。操作系统采用 Ubuntu 20.04 LTS。深度学习框架选择 PyTorch，版本为 1.9.0，同时依赖 CUDA 深度神经网络库 (cuDNN) 版本 8.0.5。在科学计算方面，实验使用 NumPy 库，版本为 1.19.5。学习率、batch-size 等超参数设置与第三章实验参数相同。边界膨胀距离  $d$  设置为 5 像素，边界增强系数  $W_1$  与  $W_2$  分别设置为 1.5 与 1.0。

实验中，使用两组真实极化 SAR 数据集分别是荷兰 Flevoland 区域<sup>[36]</sup> 和德国 Oberpfaffenhofen 地区数据<sup>[62]</sup> 来验证本章方法的有效性，并利用常规的性能指标总体分类准确率 (OA)、各个类别分类准确率和 Kappa 系数对分类结果进行数值

量化。同时对分类的可视化结果进行视觉评估。在给定的极化 SAR 标准数据集中，一部分像素是没有标签的，所以在计算分类准确率的时候只统计数据集中那些有标签的样本被正确分类的百分比，并认为该指标可以表征数据集中整体的分类性能。

实验中，随机从数据集中选择 1% 的样本作为训练集，其余的 99% 样本作为测试集。为了方便，将本章提出的基于混合模型与边界增强的分类方法简记为 BEL，同时将结合上章极化信息提取方法 DP 作为本章前置模块的方法记为 BEL+DP，3.3.5 小节中介绍的特征分类器作为本章方法的主干网络。为了模拟实际场景中出现的对称噪声标签和非对称噪声标签的两种情况，本节实验通过设置噪声转移矩阵的方法，分别在以上两个数据集中合成对应类型的标签噪声。同时，对比了两种噪声源下不同噪声比例对各个方法分类准确率的影响。为了验证本章方法的优越性，选择了多种替代的分类方案进行比较，主要是通过与目前经典的以及优越的分类方法进行对比，包括支持向量机方法（记为 SVM）<sup>[75]</sup>、基于 Wishart 分布的分类方法（记为 Wishart）<sup>[76]</sup> 和鲁棒的半监督学习方法（记为 RSL）<sup>[37]</sup>。

## 4.4.2 AIRSAR Flevoland 数据实验

### 4.4.2.1 对称标签实验

图4-6展示了 10% 噪声比例下对称标签噪声的噪声转移矩阵，每个类别正确标记的概率为 90%，10% 的标签噪声均匀地分布在其他类别中。

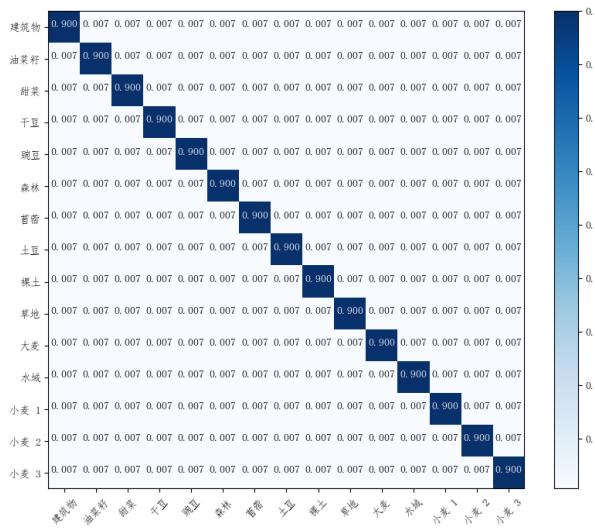


图 4-6 AIRSAR Flevoland 数据 10% 对称噪声转移矩阵

图4-7展示了不同实验方法在 10% 对称噪声类型下分类结果图，其中每个分类结果图下方依次为 A、B、C 区域的局部放大图。根据图4-7(a)、图4-7(b)展示的

SVM 与 Wishart 分类器的分类结果，在大多数的类别中都存在着严重的错分情况，这可能是由于这两类分类器都无法有效地应对标签噪声的影响，错误的信息对分类规则噪声严重的负面影响，进而导致分类性能下降的现象。而图4-7(c)展示的在交叉熵损失函数优化的 CNN 分类器的分类结果，可以看到小麦区域和干豆存在大量的错分情况，将小麦错分为水域，将干豆区域错分为土豆，这是因为这两类目标本身散射特性比较接近，容易造成错分，同时该分类模型并没有对标签噪声进行处理，模型过拟合学习到了错误的类别信息，导致错分的情况。图4-7(g)展示了使用鲁棒分类方法的分类结果，可以看到大量连续错分的情况得到改善，但是在草地等区域出现了小块的错分样本，将草地错分为大麦，这可能是草地覆盖区域较小，又存在噪声的情况，导致有效的训练样本数量不足，同时 RSL 方法是将判断为噪声的样本直接丢弃也丢失了一部分信息，在这一块区域中的分类性能有限。图4-7(h)与图4-7(i)均是本章提出的标签噪声下鲁棒性分类方法的分类结果图，从图中可以直观看出分类效果得到提升，错分的情况大大减少，仅有少数的错分情况，并且使用极化信息提取器后在油菜籽区域的错分情况也得到视觉上的改善，这也验证了本章方法的有效性。

表4-1展示了不同分类方法在 10% 对称标签噪声比例下的分类数值结果。SVM 与 Wishart 分类方法由于无法有效应对标签噪声的影响，绝大多数类别的分类准确率都低于 60%，存在严重的错分的情况，总体分类准确率较低，分别为 58.98% 和 49.78%。基于交叉熵损失的 CNN 分类器在油菜籽、干豆、草地等区域分类准确率较低，但是在其他类别上的分类准确率有了一定的提升，这可能是因为深度网络模型本身对于标签噪声的一定的鲁棒性能，会先学习特征简单的样本，再去学习错误的样本信息，OA 仅为 69.83%。鲁棒性分类学习方法 RSL 由于对判断为噪声的样本进行了丢弃，在大多数类别上准确率取得了不错的成果，且 OA 提升至 86.13%，但是在建筑物区域的分类准确率较低，这可能是因为建筑物区域本身样本有限，添加噪声之后导致有效的训练样本不足，进而导致了在该类别上的分类准确率较低的情况。BEL 与 BEL+DP 分类准确率相比于其他方法有了较大的提升，两个方法占据了所有类别和所有指标的最大值，OA 分别为 95.25% 与 96.36%。BEL+DP 方法在油菜籽、甜菜等区域中分类准确率稍低于 BEL 方法，不足 1% 的差距，但是在建筑物、甜菜等区域中的分类准确率高于 BEL 方法超过 1%，验证了极化信息表征对该场景下性能提升的有效性。通过以上分析证明，本章提出的 BEL 方法对标签噪声的有效性与优越性。

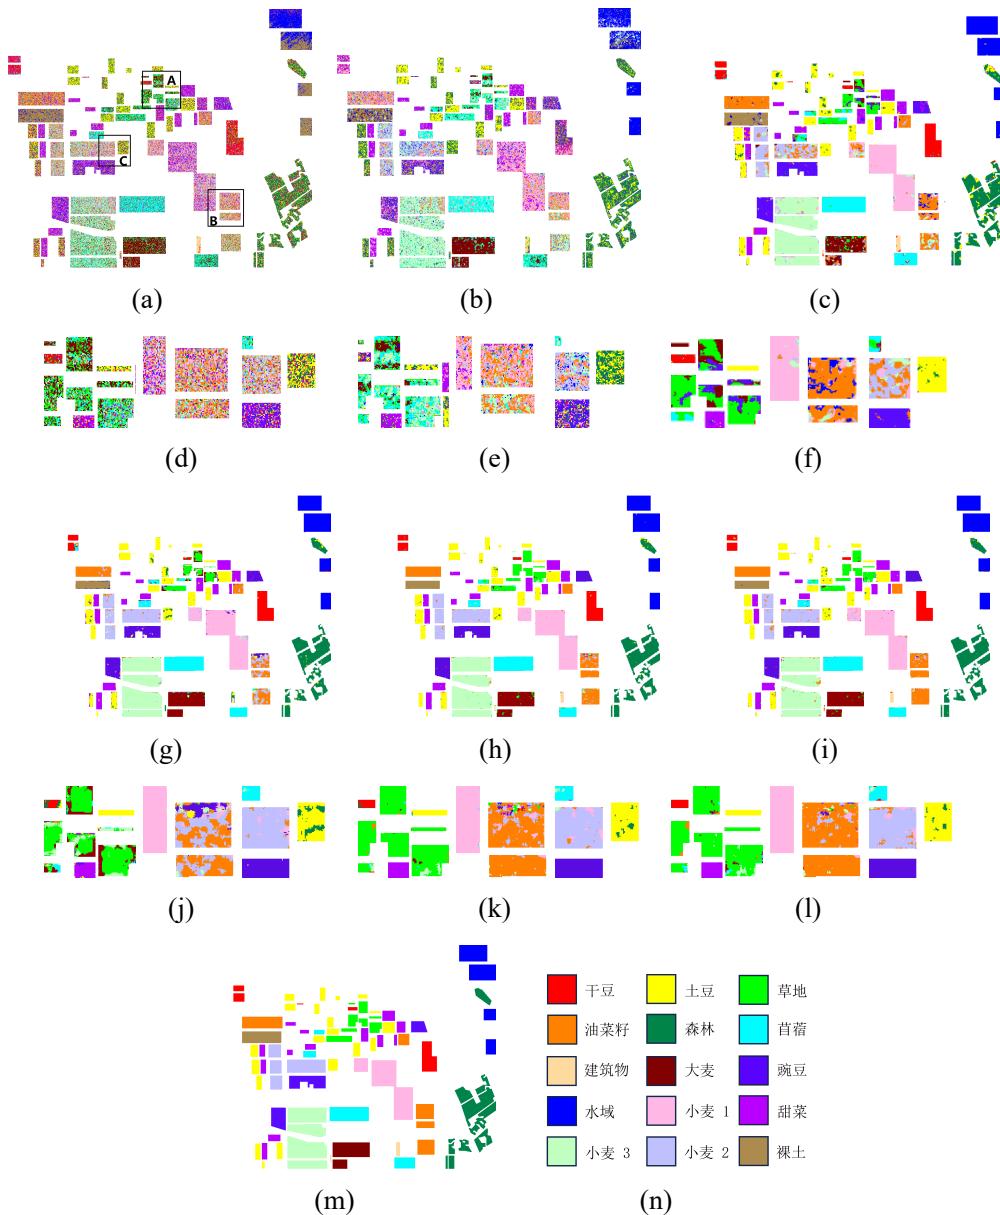


图 4-7 AIRSAR Flevoland 地区数据对称标签噪声下分类可视化结果图。

(a)SVM; (b)Wishart; (c)CNN; (d)SVM 局部误差图; (e)Wishart 局部误差图;  
 (f)CNN 局部误差图; (g)RSL; (h)BEL; (i)BEL + DP; (j)RSL 局部误差图;  
 (k)BEL 局部误差图; (l)BEL + DP 局部误差图; (m)地面真值; (n)颜色与类  
 别对应关系

#### 4.4.2.2 非对称标签实验

图4-8展示了 10% 噪声比例下非对称标签噪声的噪声转移矩阵，每个类别正确标记的概率为 90%，10% 的标签噪声随机映射到另外的一个类别中。

图4-9展示了 10% 非对称标签噪声下不同对比方法的分类结果，其中每个分类

序号	类别	SVM	Wishart	CNN	RSL	BEL	BEL + DP
1	建筑物	37.26	32.64	65.07	79.52	86.38	<b>87.75</b>
2	油菜籽	31.35	15.58	33.32	66.64	<b>92.01</b>	90.27
3	甜菜	74.17	9.87	77.49	<b>99.01</b>	95.67	97.28
4	干豆	14.61	14.02	58.6	74.63	<b>96.92</b>	96.62
5	豌豆	50.2	22.9	79.68	96.39	<b>99.11</b>	98.8
6	森林	66.31	41.52	83.57	94.34	96.8	<b>97.7</b>
7	苜蓿	62.92	17.71	59.63	80.53	96.19	<b>98</b>
8	土豆	53.54	26.89	72.74	83.1	95.49	<b>98.42</b>
9	裸土	64.25	11.36	80.46	<b>95.05</b>	91.02	93.12
10	草地	19.64	17.27	55	80.43	87.65	<b>91.66</b>
11	大麦	80.89	10.48	79.28	89.43	96.26	<b>97.49</b>
12	水域	76.9	59.9	49.51	79.32	97.37	<b>99.85</b>
13	小麦 1	59.13	40.18	82.51	91.83	<b>97.71</b>	97.23
14	小麦 2	45.27	46.52	64.23	80.16	<b>94.82</b>	94.22
15	小麦 3	75.74	43.69	73.65	<b>98.85</b>	97.05	98.06
OA		58.98	49.78	69.83	86.13	95.25	<b>96.36</b>
AA		54.15	27.36	67.64	85.94	94.7	<b>95.76</b>
Kappa		56.02	47.16	67.56	85.12	95.47	<b>96.58</b>

表 4-1 AIRSAR Flevoland 地区数据对称标签噪声下分类数值结果 (%)

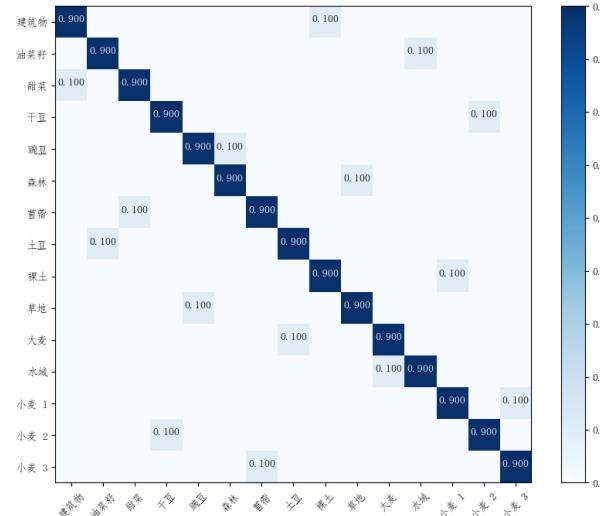


图 4-8 AIRSAR Flevoland 数据 10% 非对称噪声转移矩阵

结果图下方依次为 A、B、C 区域的局部放大图。图4-9(a)与图4-9(b)依然存在大量的错分情况，并且区域内部存在大量斑点状的错误区域。图4-9(c)展示了交叉熵损失下的 CNN 分类结果，由于训练集中油菜籽区域部分像素被标记为小麦，导致在分类结果中也存在相同的错分情况，这表明该分类方法在错误标记训练集上过拟

合，学习了错误的分类规则。图4-9(g)展示了 RSL 方法的分类结果，可以看出在油菜籽、大麦区域依然存在大块连续的错分区域，将大麦错分为苜蓿，这是因为 RSL 对大量的错误样本过滤性能有限。图4-9(h)与图4-9(i)展示了 BEL 与 BEL+DP 方法的分类结果，可以看到由于对称噪声标签的影响，在小麦、林地、油菜籽区域出现了一定的错分情况，但是在其他大部分区域分类结果较平滑，错分样本较少，以上结果证明了本章方法在非对称噪声标签下的有效性与优越性。

表4-2展示了各对比方法在非对称标签噪声下的分类数值结果。SVM 与 Wishart 作为经典的极化 SAR 分类方法，在非对称标签噪声下分类效果不理想，总体准确率分别为 56.48% 与 50.32%，这是因为基于 SVM 与 Wishart 的方法分类器模型简单，无法鉴别标签噪声的错误信息。基于交叉熵损失的 CNN 方法虽然整体有了提升，但是在建筑物区域准确率仅为 42.28%，这是因为 CNN 也不具备对标签噪声的鲁棒性能，学习了错误的分类准则。除了干豆、水域、大麦三个区域略低于 RSL 方法，本章方法在其他指标上均取得了最高值，尤其是建筑物区域获得了较大的提升，反映了本章提出的方法是有效且优越的。

表 4-2 AIRSAR Flevoland 地区数据非对称标签噪声下分类数值结果 (%)

序号	类别	SVM	Wishart	CNN	RSL	BEL	BEL + DP
1	建筑物	31.73	31.56	42.28	46.24	91.09	<b>96.16</b>
2	油菜籽	33.76	18.23	61.25	82.77	<b>92.34</b>	92.19
3	甜菜	73.98	10.56	74.86	95.23	96.68	<b>97.92</b>
4	干豆	16.23	12.97	85.41	<b>96.8</b>	91.01	94.6
5	豌豆	48.34	24.56	87.73	95.62	97.86	<b>97.39</b>
6	森林	64.28	40.08	82.19	91.36	96.68	<b>97.96</b>
7	苜蓿	60.72	18.23	79.2	79.8	94.43	<b>96.04</b>
8	土豆	52.01	22.14	81.69	<b>95.9</b>	95.68	94.41
9	裸土	64.58	14.2	81.32	98.04	94.01	<b>99.39</b>
10	草地	21.33	19.32	77.84	64.59	92.98	<b>92.4</b>
11	大麦	78.89	9.47	76.23	59.39	89.52	<b>97.24</b>
12	水域	75.42	58.14	68.04	<b>98.2</b>	97.35	97.7
13	小麦 1	57.6	42.18	80.37	<b>94.83</b>	93.97	93.87
14	小麦 2	44.32	44.25	65.17	86.95	83.83	<b>91.55</b>
15	小麦 3	74.36	45.84	70.35	94.2	94.72	<b>98.12</b>
OA		56.48	50.32	75.28	89.88	93.82	<b>96.02</b>
AA		53.17	27.45	74.26	88.91	91.48	<b>95.79</b>
Kappa		54.59	48.03	73.96	88.94	93.26	<b>95.22</b>

图4-10展示了各个对比方法在两种噪声类型下分类准确率随噪声比例的变化趋势。随着噪声比例增加，各个方法的分类性能均有不同程度下降。在对称标签

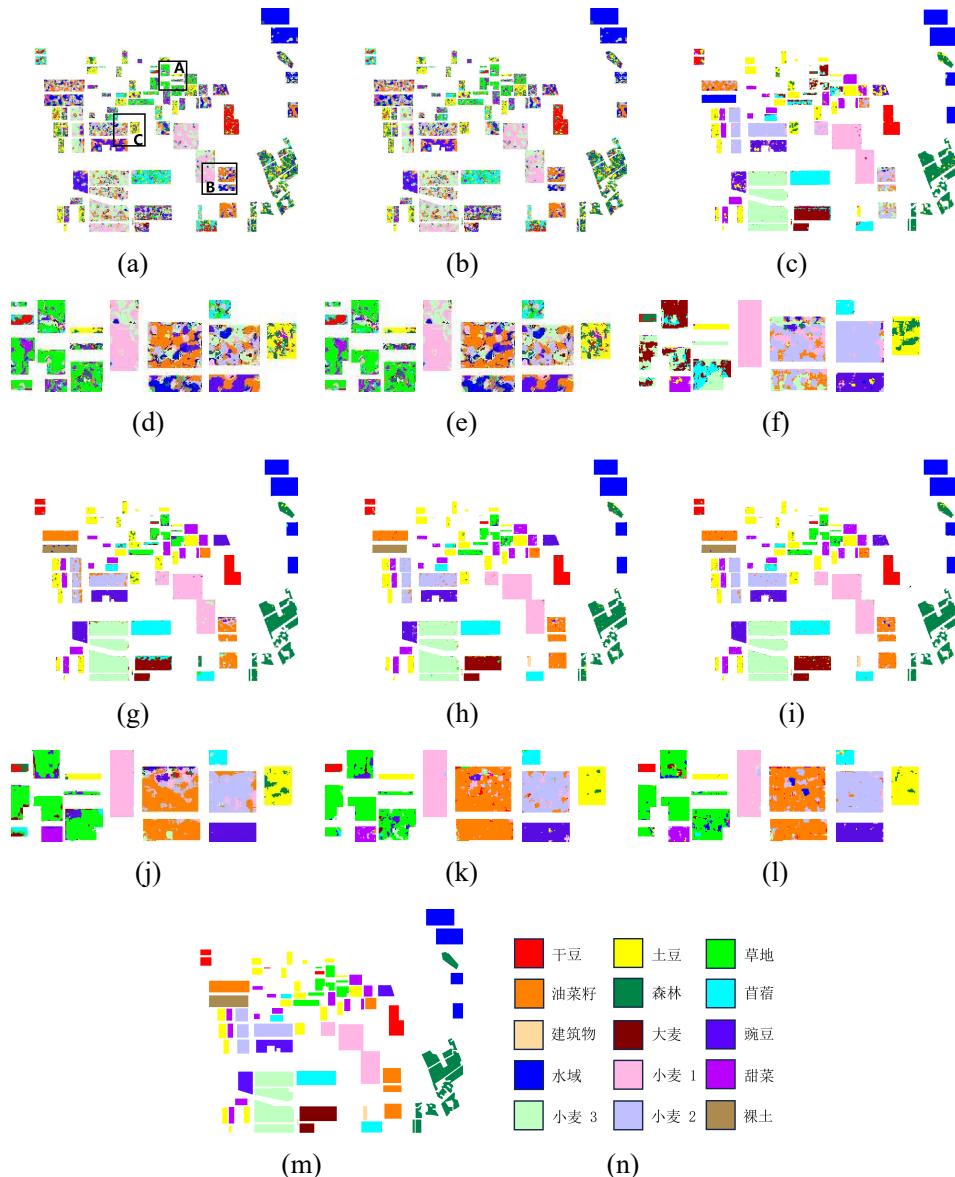


图 4-9 AIRSAR Flevoland 地区数据非对称标签噪声下分类可视化结果图。

(a)SVM; (b)Wishart; (c)CNN; (d)SVM 局部误差图; (e)Wishart 局部误差图;  
 (f)CNN 局部误差图; (g)RSL; (h)BEL; (i)BEL + DP; (j)RSL 局部误差图;  
 (k)BEL 局部误差图; (l)BEL + DP 局部误差图; (m) 地面真值; (n) 颜色与类  
 别对应关系

噪声场景下, SVM、Wishart、CNN 分类准确率显著降低, 当噪声比例从 10% 增至 50% 时, 总体准确率分别下降了 20.70%、19.91% 和 36.40%, 反映了标签噪声引入的误导信息对分类任务造成的显著负面效应。RSL 方法在相同的噪声比例增强区间内, 分类准确率下降了 28.59%, 在 50% 噪声比例下准确率保持在 60.46%, 显示出该方法在应对高噪声标签场景下的稳健性存在一定局限。相比之下, BEL

与 BEL+DP 方法表现出更强的抗噪能力，在噪声比例为 50% 时分类准确率分别为 79.42% 和 80.97%。此外，在相同噪声比例条件下，非对称噪声源相较于对称噪声源导致更低的分类准确度。在 50% 的非对称噪声源下，大面积的误标样本严重干扰了模型构建有效的分类边界，SVM、Wishart 分类方法的最差分类准确率已经低于 30%，RSL 方法的最差分类准确率降到了 40.32%，本章分类方法降到了 46.49%。本章所提方法在各噪声条件下的分类准确率仍然优于对照组。实验结果证实了本章方法在面对不同类型的噪声以及不同的噪声比例时，都具备优良的鲁棒性能。

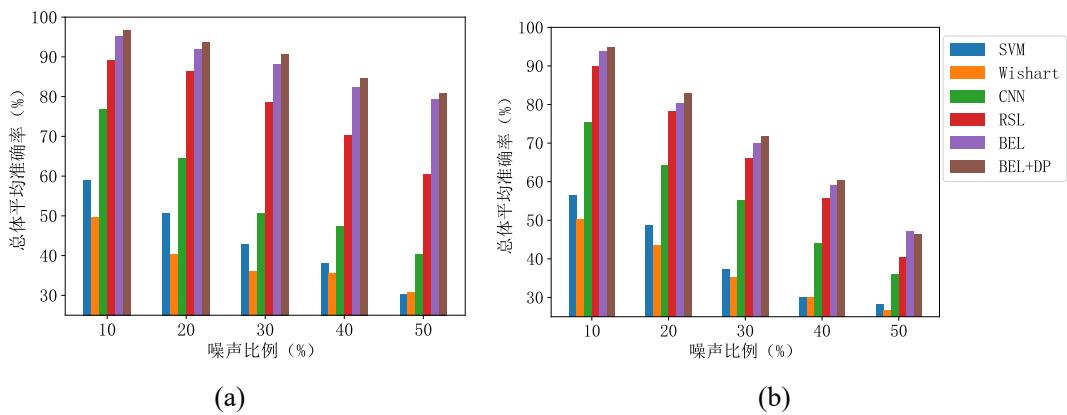


图 4-10 AIRSAR Flevoland 地区数据不同噪声比例下分类准确率结果。(a) 对称噪声源; (b) 非对称噪声源

### 4.4.3 E-SAR Oberpfaffenhofen 数据实验

#### 4.4.3.1 对称标签实验

图4-11展示了 10% 噪声比例下对称标签噪声的噪声转移矩阵，每个类别正确标记的概率为 90%，10% 的标签噪声均匀地分布在其他类别中。

图4-12展示了不同分类方法在 10% 对称标签噪声条件下的分类可视化图。根据图4-12(a)与4-12(b)展示的 Wishart 与 SVM 的分类结果，可以看出分类效果较差，尤其是在林地、建筑区域存在大量的错分样本，将建筑物区域错分为开放区，将林地区域错分为建筑区域，一方面是因为 Wishart 与 SVM 分类方法的分类性能有限，对散射特性复杂的极化 SAR 数据分类结果不理想，另一方面是因为将错误的标签噪声信息归为学习规则之一，学习到错误的分类规则，导致分类性能的进一步下降。根据图4-12(c)展示的在交叉熵损失函数优化的 CNN 分类器的分类结果，可以看到相比于 SVM 与 Wishart 的分类效果有了一定的提升，但是依然存在着错误分类情况，主要是将建筑物区域分类为开放区，这是因为建筑物区域的散射特性差异大，并且交叉熵损失函数的 CNN 会学习错误的标签信息，造成在训练集上

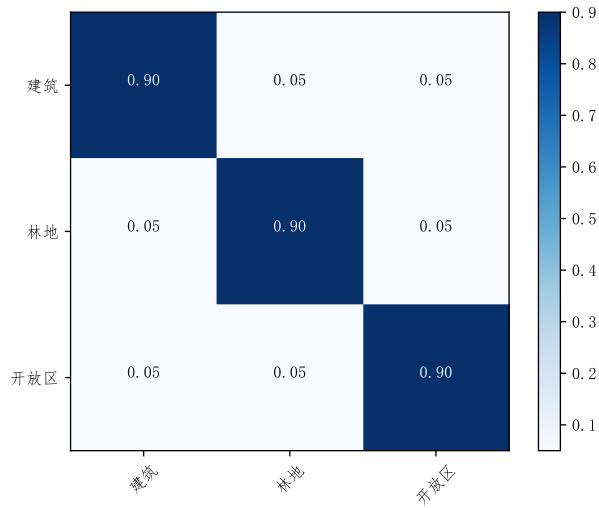


图 4-11 E-SAR Oberpfaffenhofen 数据 10% 对称噪声转移矩阵

过拟合，进而导致在测试集错分的情况。根据图4-12(d)展示的 RSL 方法的分类结果，经过对噪声标签概率估计后过滤可能是错误的信息的操作，可以看到分类效果直观好于 CNN 方法，但是依然在建筑区、林地区域存在少量的错误块，这可能是因为 RSL 直接丢弃了错误的样本，丢失了训练样本中的数据分布特征，导致分类性能有限。图4-12(e)与图4-12(f)展示的 BEL 与 BEL+DP 方法的分类结果，可以看到错分情况得到改善，在类别区域内部更加平滑，错分块数量减少，证明了本章方法的有效性与优越性。

表4-3展示了不同实验方法在 10% 比例对称标签噪声下的分类数值结果。其中，SVM 与 Wishart 分类方法虽然在开放区域的分类准确率取得了不错的效果，分别为 95.28% 和 95.21%，但是由于在建筑区域和林地区域分类效果均不理想，导致整体准确率、平均准确率、Kappa 系数三相指标都较低，这是因为噪声标签信息对该两个分类方法的影响，学习到错误的分类规则。RSL 方法在林地区域单向准确率取得了最高的分类准确率为 95.16%，相比于本章方法提高了 3.94%，这可能是因为林地区域散射特性差异大，极化信息提取器在该区域的提升性能不足，同时该区域训练样本充足，直接丢弃所有的可能为噪声的样本并未丢失关键的数据分布特征。RSL+DP 方法在综合指标方面均取得了最高值，分别为 93.55%、93.52% 和 90.66%，相比于其他方法分别提升了 3.76%、5.6% 和 1.23%。综上所述，本章方法在噪声标签条件下的数据集中具有更优越的分类性能。

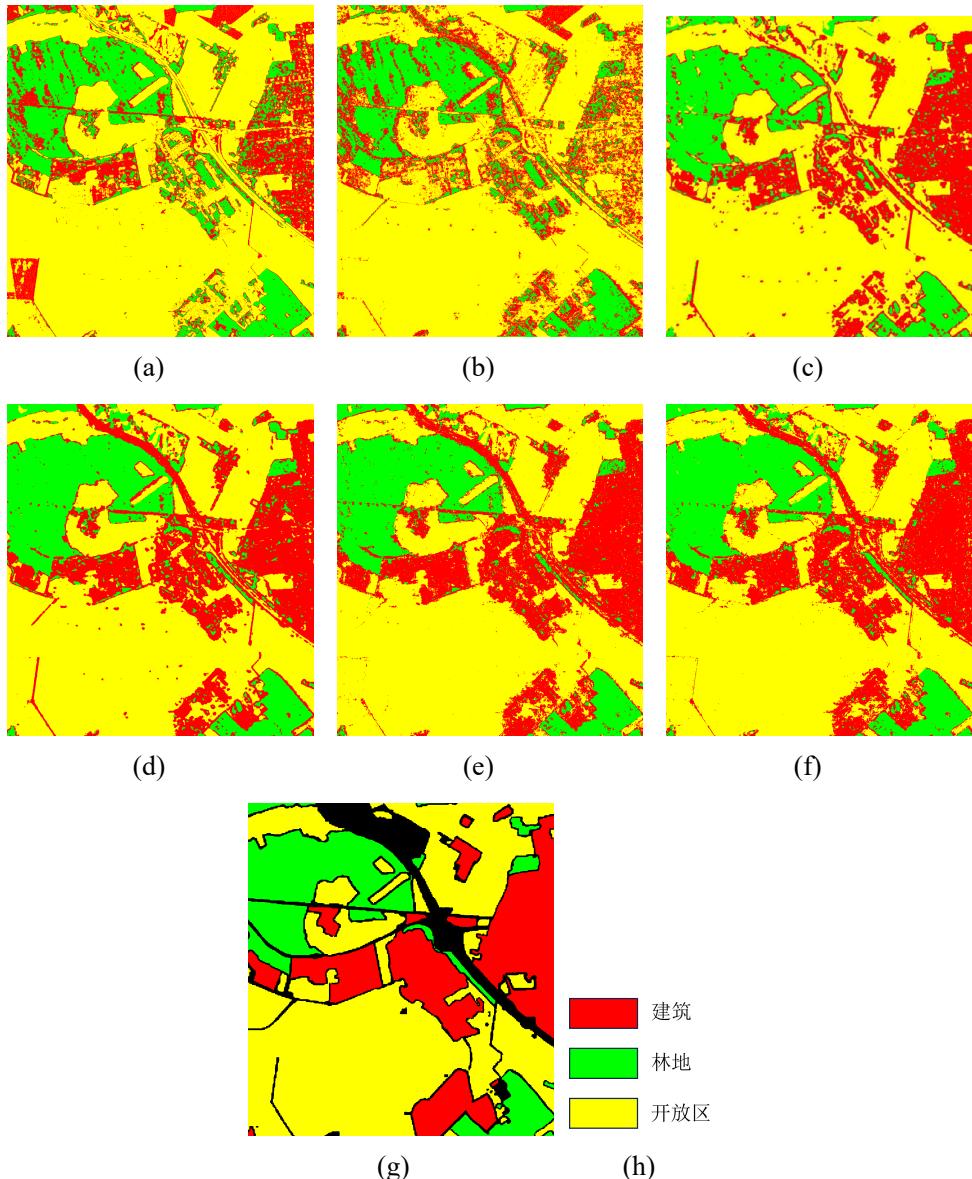


图 4-12 AIRSAR Flevoland 地区数据对称标签噪声下分类可视化结果图。

(a)SVM; (b)Wishart; (c)CNN; (d)RSL; (e)BEL; (f)BEL + DP; (g) 地面真值;  
(h) 颜色与类别对应关系

#### 4.4.3.2 非对称标签实验

图4-13展示了 10% 噪声比例下非对称标签噪声的噪声转移矩阵，每个类别正确标记的概率为 90%，10% 的标签噪声随机映射到另外的一个类别中。

图4-14展示了 10% 非对称标签噪声下不同分类方法的分类结果。图4-14(a)与图4-14(b)展示的 Wishart 与 SVM 的分类结果，可以在林地、建筑区域都存在较多的错误区域，分类效果差。图4-14(c)为交叉熵损失下的 CNN 分类结果，可以看

表 4-3 ESAR Oberpfaffenhofen 地区数据对称标签噪声下分类数值结果 (%)

序号	类别	SVM	Wishart	CNN	RSL	BEL	BEL+DP
1	建筑	75.19	61.35	81.25	75.32	89.98	<b>92.35</b>
2	林地	76.54	74.58	80.24	<b>95.16</b>	91.59	91.82
3	开放区域	95.28	95.21	85.82	93.28	93.39	<b>96.38</b>
	OA	79.07	83.05	83.67	89.79	92.56	<b>93.55</b>
	AA	82.33	77.04	82.44	87.92	91.65	<b>93.52</b>
	Kappa	77.25	70.45	79.14	89.43	89.68	<b>90.66</b>

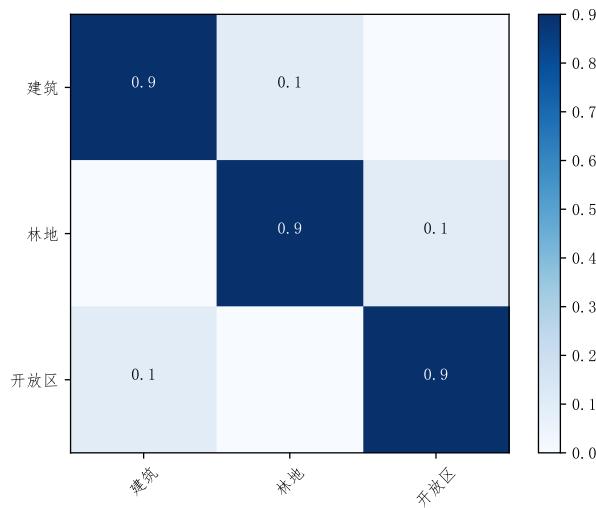


图 4-13 ESAR Oberpfaffenhofen 数据 10% 非对称噪声转移矩阵

到受到标签噪声影响，开放区域错分为建筑、建筑区域错分为林地的情况存在较多。图4-14(d)为 RSL 方法的分类结果，在建筑区域错分情况稍有改善，但是依然存在大量的错误标记样本，表明 RSL 方法对标签噪声具有有限的鲁棒性能。图4-14(e)与图4-14(f)为 BEL 与 BEL+DP 方法的分类结果，可以看出在建筑物区域和林地区域的错分情况减少，分类结果更加平滑。因此，证明了本章方法的有效性与优越性。

表4-4展示了非对称标签噪声下的分类数值结果。SVM、Wishart 以及 CNN 方法在建筑区域的分类准确率较低，导致总体准确率较低，分别为 76.58%，80.32%，82.49%，这是因为这三个方法均没有筛选错误样本的能力，学习错误的分类规则。本章方法除了林地区域，其他的分类指标均取得最高值，分类准确率均在 90% 以上，且总体分类准确率达到 93.32%，较其他方法提升了 1.74%，这也证明了本章方法具备应对非对称标签噪声的鲁棒性，进一步证明本章方法的有效性。

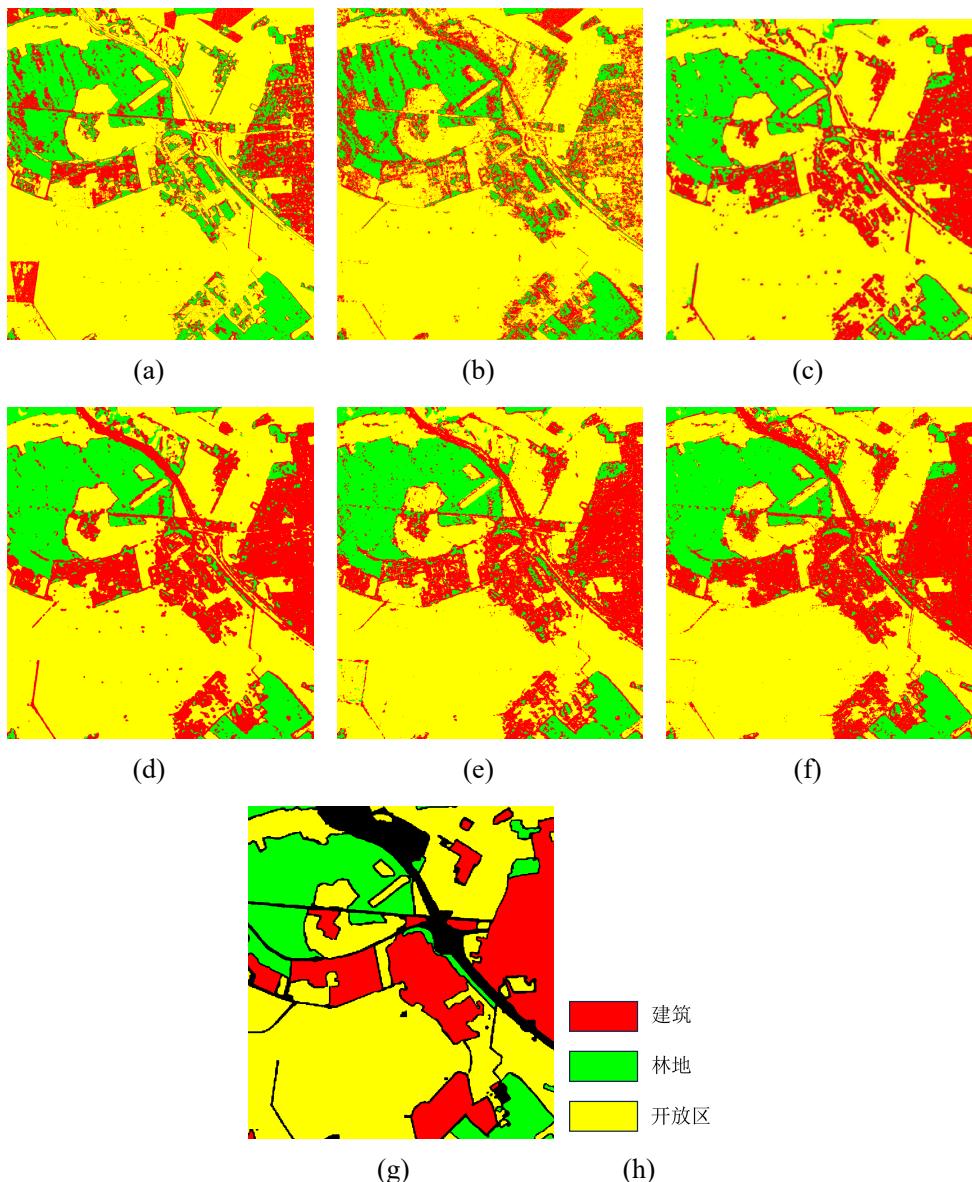


图 4-14 AIRSAR Flevoland 地区数据非对称标签噪声下分类可视化结果图。

(a)SVM; (b)Wishart; (c)CNN; (d)RSL; (e)BEL; (f)BEL + DP; (g) 地面真值;  
(h) 颜色与类别对应关系

图 4-15 显示了各种对比算法在对称噪声和非对称噪声条件下，分类精度随噪声比例变化的情况，其趋势与先前在 AIRSAR Flevoland 区域实验得到的结果一致，即随着噪声比例的增大，分类精度总体上呈下降态势，并且在非对称噪声环境下分类精度普遍低于对称噪声环境下的相应值。在非对称标签噪声背景下，未专门处理噪声标签影响的 SVM、Wishart 和 CNN 模型，随着噪声比例升高至 50%，分类准确性遭受显著恶化，分别降低至 48.43%、49.23% 和 55.37%。而采用 RSL 方法的分类准确率下降至 76.5%，表现出对标签噪声的鲁棒性能。相较之下，BEL 和

表 4-4 ESAR Oberpfaffenhofen 地区数据非对称标签噪声下分类数值结果 (%)

序号	类别	SVM	Wishart	CNN	RSL	BEL	BEL+DP
1	建筑	72.38	58.83	78.92	86.73	88.06	<b>90.48</b>
2	林地	74.54	72.43	81.32	<b>94.44</b>	89.44	90.83
3	开放区域	92.28	92.31	83.16	90.53	94.04	<b>97.18</b>
	OA	76.58	80.32	82.49	91.58	91.8	<b>93.32</b>
	AA	79.73	74.52	81.13	90.56	90.51	<b>92.83</b>
	Kappa	74.71	68.93	77.32	86.97	87.88	<b>90.31</b>

BEL+DP 方法的表现更为出色，分类准确率分别仅下降了 11.62% 和 12.08%，在承受 50% 噪声比例时，准确率依然在 80% 以上，充分彰显了这两种方法对抗标签噪声的良好鲁棒性。因此，本章方法在面临不同类型标签噪声和不同噪声比例时，展现出良好的抗噪声标签鲁棒性，能够更有效地降低标签噪声对分类性能的负面影响。

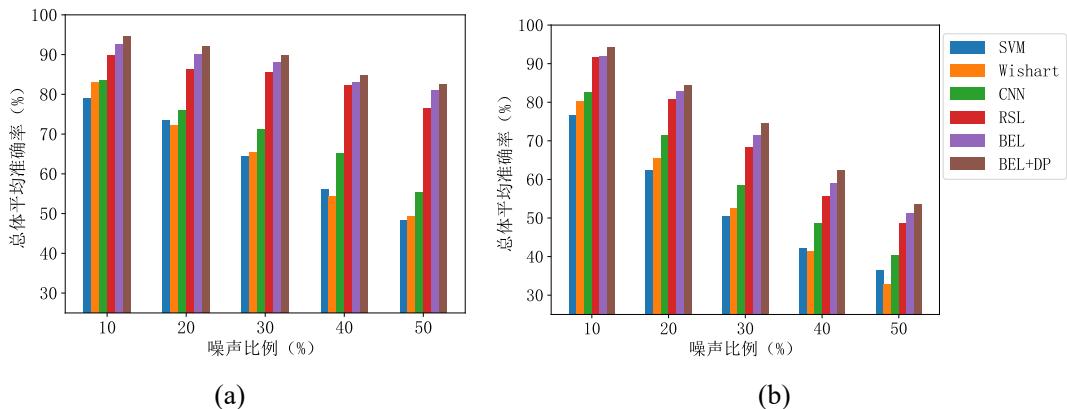


图 4-15 ESAR Oberpfaffenhofen 地区数据不同噪声比例下分类准确率结果。

(a) 对称噪声源 (b) 非对称噪声源

#### 4.4.4 本章小结

针对极化 SAR 图像中存在的标签噪声影响分类模型准确率的问题，本章研究了基于混合模型噪声估计的极化 SAR 目标分类方法。首先，介绍了有限混合模型，并导出了两种经典混合模型的理论原理。在此基础上，通过深度学习在包含标签噪声样本下训练损失分布存在差异，实现对训练样本损失分布的拟合。同时，为了增强模型对边界信息的感知能力，充分利用边界样本信息，对极化 SAR 的 Pauli 伪彩图使用 Sobel 算子提取边界并膨胀，对膨胀边界内样本进行损失增强。最后，提出了动态的自学习损失函数，通过噪声样本概率动态调整模型预测与真值标签

的依赖，实现模型的鲁棒性训练过程。本章通过在两个实测极化 SAR 数据集，对两种噪声源进行模拟实验，证明了本章方法的有效性。同时，还对不同噪声比例下各个方法的分类准确率进行了比较，进一步证明了本章方法的有效性。

## 第五章 全文总结与展望

### 5.1 全文总结

极化合成孔径雷达通过收发不同极化方式的电磁波对地物目标进行探测，提供了丰富的目标散射信息，广泛应用于军事、民事等领域中。极化 SAR 图像解译作为极化 SAR 应用的关键步骤，是当前研究的重点方向。本文以极化 SAR 图像目标分类为主要研究问题，展开了对多类型极化特征利用与标签噪声目标分类的研究，有效提高了极化 SAR 图像目标分类准确率与实用性，为极化 SAR 图像目标分类的理论研究和实践应用提供了支持。本文的研究成果如下：

(1) 本文研究了极化 SAR 相关理论基础，结合极化电磁波特性，介绍了针对目标散射特性的极化散射矩阵和二阶统计矩阵两种描述方法，然后对极化目标分解理论进行了详细阐述，重点介绍了几种经典的目标分解方法原理，并对不同极化参数进行了总结归纳，为后续的目标分类方法建立理论基础。

(2) 本文提出的双通道注意力极化 SAR 图像目标分类方法，基于极化散射特征与目标分解特征之间的差异性与互补性，构建了双通道注意力的网络结构，实现多类型特征间关键信息捕捉，提供更加全面的极化特征表征方式。实验结果表明，相比于仅散射特征、仅极化分解特征或直接堆叠极化特征，该方法有效提升了目标分类准确率，在两个实测数据集中分类准确率达到 98.47% 和 94.39%。

(3) 本文提出的混合模型噪声概率估计的极化 SAR 目标分类方法，基于混合模型理论，建立了噪声样本与准确样本混杂下的损失分布模型，获取样本的噪声概率，结合边界样本损失增强，使模型有效利用边缘知识增强边界性能。实验结果表明，该方法具备对标签噪声的优越鲁棒性能，有效提升了标签噪声下目标分类准确率，在两个实测数据集中 10% 标签噪声下分类准确率达到 96.36% 和 93.55%，提升了极化 SAR 的实用性。

### 5.2 后续工作展望

极化 SAR 图像信息提取与目标分类研究是一个设计多个跨学科交叉领域的遥感图像处理技术，包括雷达成像、微波遥感、模式识别和机器学习等。相关研究的创新方法层出不穷，一直都是研究的热点与难点。本文针对极化信息提取与标签噪声目标分类问题展开研究，提出一些新的解决思路与方案，但是依然存在许多问题亟待解决，有待在将来的工作中进一步完善，主要包括：

(1) 极化特征利用方面：

本文第三章针对极化 SAR 图像的散射特征和目标分解特征的综合利用展开了研究，旨在对不同类型的极化特征进行有效联合，利用双通道网络结构与注意力调整方法实现独立特征与联合特征的互信息捕捉。该方法尽管考虑了对散射特征与目标分解特征的差异与联系，而极化 SAR 图像中还存在空间特征、颜色特征、纹理特征等。因此，设计更加全面的极化信息提取器，构建全面、高效的极化信息融合方法，对于极化 SAR 图像解译具有支撑性作用。

(2) 目标分类方面：

本文提出的极化 SAR 目标分类方法是以单个像素为单位，而通常极化 SAR 数据集数量巨大，逐个对极化 SAR 像素进行分类可能会导致计算量大、计算时间长的问题。因此，在后面的工作中，可以在减小时间复杂度的方面考虑，设计更加快速、准确的极化 SAR 图像分类方法。

(3) 噪声标签分类方面：

本文第四章通过混合模型与边界增强，实现了对标签噪声具有鲁棒性的分类方法。但是该方法的分类损失模型仅是通过调整预测标签与真值标签的权衡，并没有完全消除标签噪声被学习的过程。因此，在明确标签噪声学习理论的基础上，构建更加高效的目标损失函数，对于提升标签噪声样本学习模型的性能具有重要意义。

## 致 谢

行文至此，意味着在成电三年的研究生时光即将画上句号。三年时光，如同一部精彩纷呈的交响乐，旋律中交织着喜悦与忧愁，欢乐与焦虑，每个音符都是我成长路上不可或缺的部分。

感谢杨建宇老师、武俊杰老师、李中余老师以及团队中每一位尊敬的导师。感谢你们的辛苦付出，让雷达探测成像团队形成了良好的科研环境与科研环境，让我们感受到来自团队的强大自信力。

感谢裴季方老师的耐心指导与支持。每当我在学术探索中遇到难题时，总能在百忙之中抽出宝贵时间，以无尽的耐心和细致的关怀，为我排疑解惑。他严谨治学精神和深厚的专业知识，不仅为我指明了科研的方向，更为我的个人成长树立了榜样。同时，感谢吴从文师兄的细心帮助与支持，他的建议和指导对我完成学术论文有着重要的影响。

感谢研究生阶段的所有好伙伴们。感谢你们在这段旅程中的陪伴与支持，我们一起经历风雨，一起分享快乐，你们的存在让这段时间更丰富多彩。愿我们的友谊历久弥新，未来无论身处何方，都能保持这份纯真与热情，共同描绘更加精彩的未来画卷。

感谢我的女朋友陈阳一路的鼓励与支持。你是我最坚强的后盾，在我遇到困难和挑战时，你总是给予我最坚定的支持和最温暖的鼓励，感谢你的陪伴与理解。你的陪伴是我人生旅途中最宝贵的财富，你的鼓励是我披荆斩棘的动力源泉。愿我们携手共进，共同书写未来的美好篇章。

感谢我的父母长期以往的无私帮助与鼓励。你们的一言一行、一点一滴的付出，构筑起了我成长的基础。从生活的细微照顾到精神上的激励引导，你们的爱如同阳光普照，让我在求学的路上勇往直前，始终保持坚韧与乐观。

最后，感谢各位评审专家的辛苦付出。

## 参考文献

- [1] 皮亦鸣, 杨建宇, 付毓生等. 合成孔径雷达成像原理 [M]. 成都: 电子科技大学出版社, 2007.
- [2] Pramudya F. S, Pan J, Devlin A. T. Estimation of significant wave height of near-range traveling ocean waves using sentinel-1 sar images[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2019, 12(4): 1067-1075.
- [3] Gao G, Gao S, He J, et al. Ship detection using compact polarimetric sar based on the notch filter[J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 56(9): 5380-5393.
- [4] Zhang L, Sun L, Zou B, et al. Fully polarimetric sar image classification via sparse representation and polarimetric features[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2014, 8(8): 3923-3932.
- [5] 刘高峰. 极化 sar 图像特征提取与分类方法研究 [D]. 西安: 西安电子科技大学, 2014, 10-14.
- [6] 丁尧. 基于多特征融合的高分辨率极化 sar 图像分类方法研究 [D]. 成都: 电子科技大学, 2017, 7-9.
- [7] 王贤圆. 极化合成孔径雷达图像特征表示与目标分类方法研究 [D]. 成都: 电子科技大学, 2022, 12-30.
- [8] Tu B, Kuang W, He W, et al. Robust learning of mislabeled training samples for remote sensing image scene classification[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2020, 13: 5623-5639.
- [9] Uhlmann S, Kiranyaz S. Integrating color features in polarimetric sar image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2013, 52(4): 2197-2216.
- [10] Liu H, Wang Y, Yang S, et al. Large polarimetric sar data semi-supervised classification with spatial-anchor graph[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2016, 9(4): 1439-1458.
- [11] Rignot E, Chellappa R, Dubois P. Unsupervised segmentation of polarimetric sar data using the covariance matrix[J]. IEEE Transactions on Geoscience and Remote Sensing, 1992, 30(4): 697-705.
- [12] Pierce L. E, Ulaby F. T, Sarabandi K, et al. Knowledge-based classification of polarimetric sar images[J]. IEEE Transactions on Geoscience and Remote Sensing, 1994, 32(5): 1081-1086.
- [13] Kong J. A. Identification of terrain cover using the optimal terrain classifier[J]. J. Electronmagn. Waves Applicat, 1988, 2.

- [14] Lee J.-S, Grunes M, Pottier E. Quantitative comparison of classification capability: fully polarimetric versus dual and single-polarization sar[J]. IEEE Transactions on Geoscience and Remote Sensing, 2001, 39(11): 2343-2351.
- [15] Huynen J. R. Phenomenological theory of radar target[J]. Ph. D. Dissertation, Technology University Delft, 1970.
- [16] Huynen J. R. Stokes matrix parameters and their interpretation in terms of physical target properties[C]. Polarimetry: Radar, infrared, visible, ultraviolet, and X-ray, 1990, 195-207.
- [17] Cloude S. R, Pottier E. A review of target decomposition theorems in radar polarimetry[J]. IEEE transactions on geoscience and remote sensing, 1996, 34(2): 498-518.
- [18] Krogager E. New decomposition of the radar target scattering matrix[J]. Electronics letters, 1990, 18(26): 1525-1527.
- [19] Cameron W. L, Leung L. K. Feature motivated polarization scattering matrix decomposition[C]. IEEE International Conference on Radar, 1990, 549-557.
- [20] Cloude S. R, Pottier E. An entropy based classification scheme for land applications of polarimetric sar[J]. IEEE transactions on geoscience and remote sensing, 1997, 35(1): 68-78.
- [21] Freeman A, Durden S. L. A three-component scattering model for polarimetric sar data[J]. IEEE transactions on geoscience and remote sensing, 1998, 36(3): 963-973.
- [22] Holm W. A, Barnes R. M. On radar polarization mixed target state decomposition techniques[C]. Proceedings of the 1988 IEEE national radar conference, 1988, 249-254.
- [23] Tu S. T, Chen J. Y, Yang W, et al. Laplacian eigenmaps-based polarimetric dimensionality reduction for sar image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2011, 50(1): 170-179.
- [24] Haralick R. M, Shanmugam K, Dinstein I. H. Textural features for image classification[J]. IEEE Transactions on systems, man, and cybernetics, 1973, 610-621.
- [25] Ji Y, Cheng J, Liu H, et al. An segmentation-based polsar image classification method via texture features and color features[C]. 2015 IEEE Radar Conference (RadarCon), 2015, 0083-0088.
- [26] Bi H, Sun J, Xu Z. A graph-based semisupervised deep learning model for polsar image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 57(4): 2116-2132.
- [27] Zyl J. J. V. Unsupervised classification of scattering behavior using radar polarimetry data[J]. IEEE Transactions on Geoscience and Remote Sensing, 1989, 27(1): 36-45.

- [28] Lee J.-S, Grunes M. R, Ainsworth T. L, et al. Unsupervised classification using polarimetric decomposition and the complex wishart classifier[J]. IEEE Transactions on Geoscience and Remote Sensing, 1999, 37(5): 2249-2258.
- [29] Ferro-Famil L, Pottier E, Lee J.-S. Unsupervised classification of multifrequency and fully polarimetric sar images based on the h/a/alpha-wishart classifier[J]. IEEE Transactions on Geoscience and Remote Sensing, 2001, 39(11): 2332-2342.
- [30] Kimura K, Yamaguchi Y, Yamada H. Pi-sar image analysis using polarimetric scattering parameters and total power[C]. IGARSS 2003. 2003 IEEE International Geoscience and Remote Sensing Symposium. Proceedings (IEEE Cat. No. 03CH37477), 2003, 425-427.
- [31] Lee J.-S, Grunes M. R, Pottier E, et al. Unsupervised terrain classification preserving polarimetric scattering characteristics[J]. IEEE Transactions on Geoscience and Remote Sensing, 2004, 42(4): 722-731.
- [32] Bi H, Sun J, Xu Z. Polsar image classification using discriminative clustering[C]. 2017 International Workshop on Remote Sensing with Intelligent Processing (RSIP), 2017, 1-4.
- [33] Lv Q, Dou Y, Niu X, et al. Classification of land cover based on deep belief networks using polarimetric radarsat-2 data[C]. 2014 IEEE Geoscience and Remote Sensing Symposium, 2014, 4679-4682.
- [34] Xie H, Wang S, Liu K, et al. Multilayer feature learning for polarimetric synthetic radar data classification[C]. 2014 IEEE Geoscience and Remote Sensing Symposium, 2014, 2818-2821.
- [35] Zhou Y, Wang H, Xu F, et al. Polarimetric sar image classification using deep convolutional neural networks[J]. IEEE Geoscience and Remote Sensing Letters, 2016, 13(12): 1935-1939.
- [36] Zhang Z, Wang H, Xu F, et al. Complex-valued convolutional neural network and its application in polarimetric sar image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 55(12): 7177-7188.
- [37] Hou B, Wu Q, Wen Z, et al. Robust semisupervised classification for polsar image with noisy labels[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 55(11): 6440-6455.
- [38] Geng J, Ma X, Fan J, et al. Semisupervised classification of polarimetric sar image via superpixel restrained deep neural network[J]. IEEE Geoscience and Remote Sensing Letters, 2017, 15(1): 122-126.
- [39] Liu M, Hu Y, Wang S, et al. Fully convolutional semi-supervised gan for polsar classification[C]. IGARSS 2018-2018 IEEE International Geoscience and Remote Sensing Symposium, 2018, 621-624.

- [40] Liu F, Jiao L, Tang X. Task-oriented gan for polsar image classification and clustering[J]. IEEE transactions on neural networks and learning systems, 2019, 30(9): 2707-2719.
- [41] Dumitru C. O, Schwarz G, Datcu M. Sar image land cover datasets for classification benchmarking of temporal changes[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2018, 11(5): 1571-1592.
- [42] Liu G, Zhang X, Meng J. A small ship target detection method based on polarimetric sar[J]. Remote Sensing, 2019, 11(24): 2938.
- [43] Dong H, Zhang L, Lu D, et al. Attention-based polarimetric feature selection convolutional network for polsar image classification[J]. IEEE Geoscience and Remote Sensing Letters, 2020, 19: 1-5.
- [44] Yang C, Hou B, Ren B, et al. Cnn-based polarimetric decomposition feature selection for polsar image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(11): 8796-8812.
- [45] Yang C, Hou B, Guo X, et al. Reconstruction error-based decomposition feature selection for polsar image[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-19.
- [46] 范璟. 电磁波的传播与接收 [EB/OL]. June 21, 2022, <https://enjoyphysics.cn/Article2828>.
- [47] 路宏敏,赵永久,朱满座等. 电磁场与电磁波基础 [M]. 科学出版社, 2006.
- [48] Sinclair G. The transmission and reception of elliptically polarized waves[J]. Proceedings of the IRE, 1950, 38(2): 148-151.
- [49] Guissard A. Mueller and kennaugh matrices in radar polarimetry[J]. IEEE Transactions on geoscience and remote sensing, 1994, 32(3): 590-597.
- [50] Lee J.-S, Pottier E. Polarimetric radar imaging: from basics to applications[M]. CRC press, 2017.
- [51] Huynen J. R. Extraction of target significant parameter from polarimetric data.[J]. Report no. 103, PQ RESEARCH, LOS ALTOS HILLS, 1988.
- [52] Yamaguchi Y, Moriyama T, Ishido M, et al. Four-component scattering model for polarimetric sar image decomposition[J]. IEEE Transactions on geoscience and remote sensing, 2005, 43(8): 1699-1706.
- [53] Zyl J. Jvan . Application of cloude's target decomposition theorem to polarimetric imaging radar data[C]. Radar polarimetry, 1993, 184-191.
- [54] Liu X, Jiao L, Tang X, et al. Polarimetric convolutional network for polsar image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 57(5): 3040-3054.

- [55] Ren B, Zhao Y, Hou B, et al. A mutual information-based self-supervised learning model for polsar land cover classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(11): 9224-9237.
- [56] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition, 2018, 7132-7141.
- [57] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [58] Nair V, Hinton G. E. Rectified linear units improve restricted boltzmann machines[C]. Proceedings of the 27th international conference on machine learning (ICML-10), 2010, 807-814.
- [59] Woo S, Park J, Lee J.-Y, et al. Cbam: Convolutional block attention module[C]. Proceedings of the European conference on computer vision (ECCV), 2018, 3-19.
- [60] Kyurkchiev N, Markov S. Sigmoid functions: some approximation and modelling aspects[J]. LAP LAMBERT Academic Publishing, Saarbrucken, 2015, 4.
- [61] Mao A, Mohri M, Zhong Y. Cross-entropy loss functions: Theoretical analysis and applications[C]. International Conference on Machine Learning, 2023, 23803-23828.
- [62] Xie W, Jiao L, Hou B, et al. Polsar image classification via wishart-ae model or wishart-cae model[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2017, 10(8): 3604-3615.
- [63] Chen S.-W, Tao C.-S. Polsar image classification using polarimetric-feature-driven deep convolutional neural network[J]. IEEE Geoscience and Remote Sensing Letters, 2018, 15(4): 627-631.
- [64] Maaten L. Vder , Hinton G. Visualizing data using t-sne.[J]. Journal of machine learning research, 2008, 9(11).
- [65] Ni J, Xiang D, Lin Z, et al. Dnn-based polsar image classification on noisy labels[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2022, 15: 3697-3713.
- [66] Guo Y, Jiao L, Qu R, et al. Adaptive fuzzy learning superpixel representation for polsar image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60(10): 1-18.
- [67] Yang C, Hou B, Ren B, et al. Cnn-based polarimetric decomposition feature selection for polsar image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(11): 8796-8812.
- [68] Arazo E, Ortego D, Albert P, et al. Unsupervised label noise modeling and loss correction[C]. International conference on machine learning, 2019, 312-321.

- [69] McLachlan G. J, Lee S. X, Rathnayake S. I. Finite mixture models[J]. Annual review of statistics and its application, 2019, 6: 355-378.
- [70] McLachlan G. J, Rathnayake S. On the number of components in a gaussian mixture model[J]. Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery, 2014, 4(5): 341-355.
- [71] Ma Z, Leijon A. Bayesian estimation of beta mixture models with variational inference[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2011, 33(11): 2160-2173.
- [72] Zhang C, Bengio S, Hardt M, et al. Understanding deep learning (still) requires rethinking generalization[J]. Communications of the ACM, 2021, 64(3): 107-115.
- [73] Zhang Z, Sabuncu M. Generalized cross entropy loss for training deep neural networks with noisy labels[J]. Advances in neural information processing systems, 2018, 31.
- [74] 赖裕平, 高宁, 何闻达等. 贝塔混合模型的变分贝叶斯学习及应用 [J]. 电子学报, 2018, 46(7): 1787-1792.
- [75] Lardeux C, Frison P.-L, Tison C, et al. Support vector machine for multifrequency sar polarimetric data classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2009, 47(12): 4143-4152.
- [76] Kong J, Swartz A, Yueh H, et al. Identification of terrain cover using the optimum polarimetric classifier[J]. Journal of Electromagnetic Waves and Applications, 1988, 2(2): 171-194.

## 攻读硕士学位期间取得的成果

### 已发表或录用的论文：

- [1] **Lin X**, Ma Y, et al. Beta Mixture Model And Boundary Amplification Guided Label Noise Mitigation For PolSAR Image Classification[C]. IEEE International Geoscience and Remote Sensing Symposium 2024 (IGARSS 2024). (已录用)